



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Anexos del Trabajo de Fin de Máster

Máster Universitario en Ingeniería Biomédica

**Modelización computacional de la interacción de
agentes de recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con proteínas plasmáticas
mediante acoplamiento molecular y aprendizaje
automático**

Presentado por Pablo Fuentes de Mateo

Universidad de Burgos

Julio de 2026

Tutores: Santiago Aparicio Martínez – Pedro Ángel Marcos
Villa

Tabla de contenidos

Tabla de contenidos	i
Apéndice A Planificación del proyecto	1
A.1. Fases de desarrollo	1
A.2. Infraestructura computacional	1
A.3. Software utilizado	1
Apéndice B Base de datos de ligandos, proteínas y nanopartículas	5
B.1. Ligandos estudiados	5
B.2. Proteínas plasmáticas utilizadas	7
B.3. Modelos de nanopartículas metálicas	7
Apéndice C Cálculos estructurales y variables de membrana	9
C.1. Optimización geométrica y frecuencias	9
C.2. Variables de membrana COSMOtherm/COSMOmic	10
C.3. Selección e integración de variables	11
C.4. Tratamiento de archivos y control de calidad	12
Apéndice D Docking ligando-proteína	14
D.1. Preparación de proteínas y ligandos	14
D.2. Parámetros generales del docking	14
D.3. Extracción de resultados y control de cálculos	15
D.4. Resumen de afinidades ligando-proteína	16
D.5. Uso de las afinidades en el modelo predictivo	16
Apéndice E Docking nanopartícula-proteína e Índice Contextual Nano-Bio	17

E.1. Docking nanopartícula-proteína	17
E.2. Cálculo del Índice Contextual Nano-Bio	18
E.3. Combinaciones mejor posicionadas	18
E.4. Interpretación del índice	19
Apéndice F Descriptores moleculares y modelos de aprendizaje automático	20
F.1. Construcción del dataset predictivo	20
F.2. Comparación de modelos	20
F.3. Modelo final	22
F.4. Rendimiento por proteína	22
F.5. Interpretación del papel de las variables	23
F.6. Uso predictivo del modelo	23
Apéndice G Análisis PLIP de complejos representativos	24
G.1. Selección de complejos	24
G.2. Interacciones detectadas	24
G.3. Residuos destacados	25
G.4. Limitaciones del análisis PLIP	25
G.5. Interpretación general	26
Apéndice H Aplicación Streamlit y código fuente	27
H.1. Estructura del repositorio	27
H.2. Scripts principales	28
H.3. Aplicación Streamlit	29
H.4. Ejecución de la aplicación	29
H.5. Archivos del modelo final	31
H.6. Predicción desde SMILES	31
H.7. Limitaciones de la aplicación	31

Apéndice A

Planificación del proyecto

A.1. Fases de desarrollo

El proyecto se organizó como un flujo computacional reproducible y modular. Varias fases se solaparon, ya que mientras algunos cálculos se ejecutaban en el entorno HPC se fueron preparando scripts de análisis, tablas, figuras y modelos predictivos. Esta organización permitió corregir errores de formato, completar cálculos pendientes y actualizar la memoria a medida que se generaban nuevos resultados.

A.2. Infraestructura computacional

Los cálculos y análisis se realizaron combinando recursos locales y recursos de computación de alto rendimiento. El entorno HPC se utilizó para las tareas de mayor coste computacional, mientras que el equipo local se empleó para análisis de datos, generación de figuras, entrenamiento de modelos, desarrollo de la aplicación y compilación de la memoria en Quarto.

A.3. Software utilizado

La tabla siguiente resume las herramientas principales empleadas durante el desarrollo del trabajo. Algunas se utilizaron directamente por línea de comandos y otras se integraron mediante scripts de Python, R o Quarto.

Tabla A.1: Planificación general del proyecto.

Fase	Periodo aproximado	Actividad principal
Fase 1	Inicio del trabajo	Revisión bibliográfica sobre nanopartículas metálicas, recubrimientos, proteínas plasmáticas, docking molecular, variables de membrana y aprendizaje automático.
Fase 2	Preparación inicial	Selección de ligandos, proteínas plasmáticas y modelos simplificados de nanopartículas. Organización de carpetas, formatos moleculares y scripts de trabajo.
Fase 3	Cálculos estructurales de ligandos	Optimización geométrica de ligandos y cálculo de frecuencias mediante TURBO-MOLE. Preparación de archivos compatibles con los pasos posteriores del flujo.
Fase 4	Variables de membrana	Extracción y organización de variables procedentes de COSMOtherm/COSMOmic, incluyendo partición, permeabilidad, distribución, difusión y perfiles asociados a una bicapa modelo de DMPC.
Fase 5	Docking ligando-proteína	Preparación de proteínas y ligandos, ejecución de docking molecular y extracción de energías de unión para cuatro proteínas plasmáticas.
Fase 6	Modelos predictivos	Cálculo de descriptores RDKit, construcción del dataset final, comparación de modelos de regresión multisalida y selección del modelo ExtraTrees final.
Fase 7	Capa nanopartícula-proteína	Docking nanopartícula-proteína, construcción del Índice Contextual Nano-Bio y priorización de combinaciones ligando-nanopartícula-proteína.
Fase 8	Cálculos nanopartícula-ligando	Preparación y cálculo exploratorio de complejos nanopartícula-ligando mediante ORCA, planteados como paso previo al docking completo del complejo nanopartícula-ligando-proteína.
Fase 9	Análisis final	Análisis PLIP de complejos representativos, desarrollo de la aplicación Streamlit, generación de figuras y redacción de memoria y anexos.

Tabla A.2: Infraestructura computacional empleada.

Recurso	Uso principal
Clúster HPC	Ejecución de cálculos estructurales, frecuencias, cálculos asociados a solutos y procesos de docking con mayor coste computacional.
Partición lusi2	Envío de cálculos con tiempos de ejecución prolongados, especialmente para sistemas más costosos o cálculos que no finalizaban correctamente en particiones de menor duración.
SLURM	Gestión de colas, envío de trabajos, control de tiempos máximos de ejecución y seguimiento de cálculos pendientes, completados o cancelados.
Equipo local	Análisis de datos, generación de tablas y figuras, entrenamiento de modelos, desarrollo de scripts, aplicación Streamlit y redacción en Quarto.
Entorno conda docking	Ejecución local de Python, RDKit, scripts de análisis, modelos de aprendizaje automático, aplicación y renderizado de documentos.
Quarto y LaTeX	Generación de la memoria y de los anexos en formato PDF a partir de archivos QMD.

Tabla A.3: Software utilizado en el proyecto.

Software	Uso principal
TURBOMOLE	Optimización geométrica de ligandos y cálculo de frecuencias vibracionales.
ORCA	Cálculos exploratorios de sistemas nanopartícula-ligando, planteados como paso previo a la preparación del docking del complejo nanopartícula-ligando-proteína.
COSMOtherm / COSMOmic	Obtención de variables de membrana, partición, permeabilidad, distribución y difusión en una bicapa modelo de DMPC.
AutoDock Vina	Acoplamiento molecular ligando-proteína y obtención de energías de docking.
AutoDockTools / MGLTools	Preparación de estructuras, conversión a formatos compatibles y asignación de parámetros para docking.
OpenBabel	Conversión entre formatos moleculares y preparación auxiliar de estructuras.
RDKit	Cálculo de descriptores moleculares y procesamiento de estructuras químicas.
Python	Automatización de cálculos, análisis de resultados, entrenamiento de modelos y desarrollo de la aplicación.
scikit-learn	Entrenamiento y comparación de modelos de aprendizaje automático.

Tabla A.3: Software utilizado en el proyecto. Continuación.

Software	Uso principal
R	Generación de tablas, figuras y análisis complementarios para la memoria.
PLIP	Identificación preliminar de interacciones proteína-ligando en complejos representativos.
Streamlit	Desarrollo de la aplicación interactiva de visualización y predicción desde SMILES.
Quarto	Redacción y compilación de la memoria y anexos en formato PDF.

Apéndice *B*

Base de datos de ligandos, proteínas y nanopartículas

B.1. Ligandos estudiados

La base de datos de ligandos incluyó agentes de recubrimiento y moléculas con interés biomédico. El conjunto recoge compuestos alifáticos, compuestos aromáticos, moléculas polares, moléculas con grupos tiol, ácidos carboxílicos y moléculas de mayor tamaño como ácido fólico, curcumina, ácido tánico aproximado y una aproximación estructural de doxorrubicina. Para cada ligando se calcularon descriptores moleculares RDKit y, cuando estaban disponibles, variables de membrana procedentes del análisis COSMOtherm/COSMOmic.

La tabla completa de ligandos se genera automáticamente a partir del dataset final de descriptores utilizado en el flujo de modelización. De esta forma se evita copiar manualmente nombres y valores numéricos.

Tabla B.1: Ligandos incluidos en el dataset de trabajo.

Ligando	MW	LogP	TPSA	HBD	HBA	Rot.
1-Butanethiol	90.2	1.72	0.0	1	1	3
1-Dodecanethiol	202.4	4.84	0.0	1	1	11
1-Hexanethiol	118.2	2.50	0.0	1	1	5
11-Mercaptoundecanesulfonic acid MUS	268.4	4.40	60.0	2	2	13
11-Mercaptoundecanoic acid MUA	218.4	3.51	37.3	2	3	11
2-Mercaptosuccinic acid	150.2	-0.30	74.6	3	5	4
3-Mercapto-1-propanesulfonic acid MPS	156.2	1.27	60.0	2	2	5
3-Mercaptopropionic acid	106.1	0.39	37.3	2	3	3
4-Aminothiophenol	125.2	1.56	26.0	2	2	2

Ligando	MW	LogP	TPSA	HBD	HBA	Rot.
4-Mercaptobenzoic acid	154.2	1.67	37.3	2	3	2
5-Fluorouracil	146.1	-1.03	75.1	2	3	1
6-Mercaptohexanoic acid	148.2	1.56	37.3	2	3	6
Arginine	174.2	-1.34	125.2	5	4	6
Biotin	244.3	0.80	78.4	3	4	5
Citric acid	192.1	-1.25	132.1	4	7	6
Curcumin	368.4	3.37	93.1	2	6	10
Cysteamine 2-aminoethanethiol	77.2	-0.13	26.0	2	2	3
D-Galactose	180.2	-3.22	110.4	5	6	6
D-Glucose	180.2	-3.22	110.4	5	6	6
Dihydrolipoic acid DHLA	220.4	2.83	37.3	1	4	6
Dithiothreitol DTT	182.3	-0.54	60.7	3	5	5
Doxorubicin proxy daunorubicin aglycone	356.3	0.70	124.3	4	7	5
Folic acid	586.5	-1.49	288.8	8	13	14
Gemcitabine	281.2	-1.15	110.6	3	6	5
Glutathione GSH	307.3	-2.21	158.8	6	8	11
HEPES	250.4	1.37	66.5	1	3	7
Histidine	155.2	-0.64	92.0	3	4	4
L-Cysteine	121.2	-0.67	63.3	3	4	4
L-Homocysteine	149.2	0.11	63.3	3	4	6
Lipoic acid thioctic acid	220.4	3.18	37.3	1	4	6
Lysine	146.2	-0.47	89.3	3	4	7
Mannose	180.2	-3.22	110.4	5	6	6
Mercaptoethanol 2-mercaptoethanol	78.1	-0.09	20.2	2	2	3
Methionine	149.2	0.15	63.3	2	4	5
Methotrexate	422.4	-2.18	220.3	5	10	10
mPEG-thiol n 3 methyl-capped	180.3	0.60	27.7	1	4	9
mPEG-thiol n 6 methyl-capped	312.4	0.65	55.4	1	7	18
PEG-amine n 3 proxy	177.2	0.01	53.7	1	4	10
PEG-dithiol n 3	226.4	0.90	27.7	2	5	12
PEG-thiol n 3	166.2	-0.06	38.7	2	4	9
PEG-thiol n 4	210.3	-0.04	47.9	2	5	12
PEG-thiol n 6	298.4	-0.01	66.4	2	7	18
Polyethyleneimine fragment ethylenediamine	60.1	-1.10	52.0	2	2	3
PVP monomer N-vinyl-2-pyrrolidone	125.2	0.79	20.3	0	2	1
RGD peptide Arg-Gly-Asp	346.3	-3.26	220.7	8	8	12
SDS dodecyl sulfate anion	265.4	4.68	68.9	0	1	12
Sodium citrate citrate3-	189.1	-1.63	131.1	1	4	6
Tannic acid approx	280.1	-0.03	151.3	3	9	3
TAT peptide fragment YGRKKK 6 aa	809.0	-3.59	389.2	15	14	36
Thioacetic acid	76.1	0.46	17.1	1	2	0
Thioglycolic acid mercaptoacetic acid	92.1	0.00	37.3	2	3	2
Thiomethyl PEG linker 2- 2-methoxyethoxy ethanethiol	136.2	0.58	18.5	1	3	6
Tris buffer Tris base	121.1	-2.34	86.7	4	4	7

MW: peso molecular; LogP: coeficiente de partici3n calculado; TPSA: superficie polar topol3gica; HBD: donadores de enlace de hidr3geno; HBA: aceptores de enlace de hidr3geno; Rot.: enlaces rotables.

Tabla B.2: Proteínas consideradas en el docking ligando-proteína.

Código PDB	Proteína	Variable objetivo
1ao6	Albumina sérica humana	y_1ao6
1hzh	Anticuerpo monoclonal humano IgG1 b12	y_1hzh
2hav	Transferrina sérica humana en forma apo	y_2hav
3ghg	Fibrinógeno humano	y_3ghg

B.2. Proteínas plasmáticas utilizadas

El docking ligando-proteína se realizó frente a cuatro estructuras identificadas por su código PDB. En el dataset final, cada proteína se correspondió con una variable objetivo de docking. Valores más negativos indican una interacción más favorable dentro del protocolo de docking empleado.

La albúmina sérica humana se consideró por su elevada abundancia en plasma y su papel en el transporte de sustancias como ácidos grasos y hormonas. La estructura 1hzh corresponde al anticuerpo monoclonal humano IgG1 b12, relacionado con la neutralización de cepas de VIH-1 mediante bloqueo del sitio de unión a CD4. La proteína 2hav corresponde a la forma apo de la transferrina sérica humana, principal proteína implicada en el transporte de hierro en sangre. La estructura 3ghg corresponde al fibrinógeno humano.

B.3. Modelos de nanopartículas metálicas

Además del docking ligando-proteína, se consideraron modelos simplificados de nanopartículas metálicas y de óxido metálico. Estos modelos se utilizaron para construir una capa contextual nanopartícula-proteína, separada del modelo principal de aprendizaje automático. Esta separación permitió integrar la afinidad ligando-proteína y la interacción nanopartícula-proteína sin tratarlas como una única energía física.

El docking nanopartícula-proteína se completó para 1ao6, 1hzh y 2hav. La proteína 3ghg se mantuvo en el análisis ligando-proteína y en el modelo predictivo, pero no se incluyó en la capa nanopartícula-proteína final por limitaciones técnicas asociadas al tamaño y preparación del sistema.

Tabla B.3: Modelos de nanopartículas considerados en el trabajo.

Modelo	Composición	Uso en el flujo
Ag_13	Clúster de plata	Docking nanopartícula-proteína y comparación contextual.
Au_13	Clúster de oro	Docking nanopartícula-proteína y comparación contextual.
ZnO_12_0	Modelo de óxido de zinc	Docking nanopartícula-proteína e Índice Contextual Nano-Bio.

Apéndice C

Cálculos estructurales y variables de membrana

C.1. Optimización geométrica y frecuencias

Las estructuras de los ligandos se prepararon antes de incorporarse al flujo de docking, cálculo de descriptores y análisis de membrana. La optimización geométrica permitió obtener conformaciones razonables para cada molécula, mientras que el cálculo de frecuencias se utilizó como control de estabilidad estructural. La ausencia de frecuencias imaginarias se interpretó como indicio de que la estructura optimizada correspondía a un mínimo local de la superficie de energía potencial.

La optimización geométrica de los ligandos y el cálculo de frecuencias se realizaron mediante TURBOMOLE. Estos cálculos generaron las estructuras optimizadas empleadas como punto de partida para etapas posteriores del flujo. Cuando fue necesario, se generaron también archivos de visualización o formatos intermedios para comprobar la geometría y facilitar la conversión entre programas.

Además, se iniciaron cálculos exploratorios de complejos nanopartícula-ligando mediante ORCA. Estos cálculos se plantearon como paso previo a la preparación de sistemas nanopartícula-ligando-proteína para docking. Para estos sistemas se empleó el mismo nivel teórico general descrito en la metodología: funcional B3LYP, corrección de dispersión DFT-D4 y base def2-TZVP. Debido al mayor coste computacional de estos complejos, esta parte se consideró una línea exploratoria y no se integró todavía como una capa completa dentro del modelo final.

Tabla C.1: Resumen de los archivos de variables de membrana.

Archivo	Número de entradas	Comentario
<code>membrana_features_corregido</code>	55	Archivo corregido con variables de membrana válidas para los solutos procesados.
<code>dataset_descriptores_membrana</code>	53	Dataset final cruzado con descriptores RDKit y energías de docking.
<code>dataset_descriptores_membrana</code> con variables de membrana no nulas	52	Ligandos del dataset final con información de membrana correctamente asociada.

C.2. Variables de membrana COSMOtherm/COSMOmic

Las variables de membrana se incorporaron como una capa fisicoquímica complementaria. Su objetivo no fue describir directamente la interacción ligando-proteína, sino caracterizar el comportamiento de los ligandos en un entorno de membrana simplificado. Para ello se empleó una bicapa modelo de DMPC y se extrajeron variables relacionadas con partición, permeabilidad, distribución, energía libre, entropía media y difusión.

El archivo corregido de variables de membrana, `membrana_features_corregido.csv`, contiene 55 solutos con variables de membrana válidas. Tras cruzar esta información con el dataset de docking y descriptores moleculares, el archivo `dataset_descriptores_membrana.csv` contiene 53 ligandos. De ellos, 52 presentan variables de membrana asociadas en el dataset integrado. El caso que no quedó integrado con variables de membrana completas fue SDS, debido a que no se obtuvo una optimización convergida válida para el sistema empleado en el flujo final. Por este motivo, aunque el ligando se mantuvo en el dataset de docking y descriptores, sus variables de membrana no se utilizaron como información completa en el bloque de membrana.

Estas variables se integraron posteriormente en el dataset de modelización junto con los descriptores RDKit y las afinidades de docking ligando-proteína. En los modelos finales, el bloque de membrana aportó información comple-

Tabla C.2: Familias de variables de membrana utilizadas.

Variable o familia	Interpretación en el flujo
<code>mem_logP</code>	Partición micela/agua o membrana/agua según la salida procesada.
<code>mem_logP_kg_l</code>	Versión normalizada de la partición considerando unidades de masa/volumen.
<code>mem_logPerm</code>	Estimación de permeabilidad a través de la membrana modelo.
<code>mem_distribution</code>	Perfil de distribución del soluto a lo largo de la bicapa.
<code>mem_free_energy</code>	Perfil de energía libre asociado a la posición del soluto en la membrana.
<code>mem_meanentropy</code>	Perfil de entropía media extraído del cálculo de membrana.
<code>mem_diffusion_E9</code>	Variables relacionadas con difusión en la bicapa modelo.

mentaria, pero no mejoró claramente el rendimiento predictivo frente al uso exclusivo de descriptores RDKit.

C.3. Selección e integración de variables

Para evitar introducir en los modelos información redundante o difícil de interpretar, las salidas de COSMOtherm/COSMOmic no se utilizaron como perfiles completos punto a punto, sino como variables resumen. Los perfiles de distribución, energía libre, entropía media y difusión se resumieron mediante estadísticos como media, mínimo, máximo, valor en el centro de la bicapa, posición del máximo, posición del mínimo, suma o barrera energética, según el tipo de variable.

La selección final mantuvo únicamente variables numéricas compatibles con el flujo de aprendizaje automático. Las variables de membrana se identificaron mediante el prefijo `mem_`, lo que permitió separarlas de los descriptores moleculares RDKit y de las variables objetivo de docking. Esta organización permitió comparar tres situaciones: modelos entrenados solo con descriptores RDKit, modelos entrenados solo con variables de membrana y modelos entrenados con la combinación de ambos bloques.

Esta selección permitió estudiar si la información de membrana añadía capacidad predictiva frente a los descriptores moleculares convencionales. Los

Tabla C.3: Criterios aplicados para integrar las variables de membrana en el dataset final.

Criterio	Aplicación en el flujo
Identificación por prefijo	Las variables procedentes de membrana se conservaron con el prefijo <code>mem_</code> .
Variables numéricas	Se mantuvieron únicamente variables numéricas utilizables por los modelos de regresión.
Resumen de perfiles	Los perfiles de membrana se transformaron en estadísticos resumen para evitar usar directamente todos los puntos de profundidad.
Separación de bloques	Las variables RDKit y las variables de membrana se analizaron por separado y también de forma combinada.
Control de valores ausentes	Se revisaron los ligandos sin variables de membrana completas antes de construir los modelos.

resultados mostraron que las variables de membrana describen propiedades fisicoquímicas relevantes, pero no mejoraron de forma clara la predicción de las afinidades ligando-proteína frente al bloque RDKit solo. Por ello, en la interpretación final se consideraron como una capa complementaria de caracterización, no como el bloque principal del modelo predictivo.

C.4. Tratamiento de archivos y control de calidad

El flujo de membrana requirió revisar nombres de solutos, rutas de archivos y etiquetas de salida para evitar errores de parseo. Los resultados se exportaron a archivos CSV para facilitar su integración con el resto del proyecto. Las variables finales se incorporaron con prefijo `mem_`, lo que permitió distinguirlas de los descriptores RDKit y de las variables objetivo de docking.

Durante el control de calidad se comprobó que las variables principales de membrana estuvieran disponibles en el archivo corregido. En particular, las variables `mem_logP`, `mem_logP_kg_l`, `mem_logPerm`, `mem_distribution`, `mem_free_energy` y `mem_diffusion_E9` se encontraron para los solutos del

archivo de membrana corregido. La integración con el dataset de modelización redujo el número de ligandos con información completa de membrana a 52 debido a la falta de una optimización convergida válida para SDS en el flujo final.

Esta comprobación permitió mantener separadas dos cifras: el número de solutos con variables de membrana calculadas y el número de ligandos finalmente cruzados con el dataset de docking y descriptores. Esta distinción es importante porque el modelo predictivo se entrenó sobre el dataset integrado, no directamente sobre el archivo aislado de membrana.

Apéndice D

Docking ligando-proteína

D.1. Preparación de proteínas y ligandos

El docking ligando-proteína se planteó como la fuente principal de las variables objetivo del modelo predictivo. Las proteínas se prepararon en formato compatible con AutoDock Vina y los ligandos se convirtieron a formato PDBQT. Para cada par ligando-proteína se conservó la mejor energía de docking obtenida en el cálculo, interpretada como una puntuación comparativa dentro del protocolo empleado.

El resultado final de esta fase fue una tabla con una fila por ligando y cuatro variables objetivo: `y_1ao6`, `y_1hzh`, `y_2hav` e `y_3ghg`. Estas cuatro salidas se utilizaron posteriormente en el entrenamiento de modelos de regresión multisalida.

D.2. Parámetros generales del docking

El acoplamiento molecular se realizó con AutoDock Vina. Para cada proteína se empleó una caja de búsqueda específica, definida por su centro geométrico y por unas dimensiones de $28 \times 28 \times 28$ Å. Las cajas finales se construyeron a partir de una pose de referencia, tomando las coordenadas del `MODEL 1` y calculando el centro medio de sus átomos. Esta estrategia permitió utilizar una región de búsqueda centrada en la zona de interés para cada proteína.

Los parámetros de ejecución fueron comunes para las cuatro proteínas. Se utilizó una exhaustividad de 16, se guardaron 10 modos de unión por

Tabla D.1: Centros y dimensiones de las cajas de docking ligando-proteína.

Proteína	center_x	center_y	center_z	size_x	size_y	size_z
1ao6	16.768	14.044	-9.326	28	28	28
1hzh	77.249	91.959	103.938	28	28	28
2hav	-35.939	2.393	2.218	28	28	28
3ghg	4.438	-25.182	-78.548	28	28	28

Tabla D.2: Parámetros comunes de AutoDock Vina utilizados en el docking ligando-proteína.

Parámetro	Valor
exhaustiveness	16
num_modes	10
energy_range	4
cpu	6
seed	12345

cálculo, se fijó un rango de energía de 4 kcal/mol, se emplearon 6 CPUs y se estableció una semilla fija para favorecer la reproducibilidad del flujo.

La mejor pose de cada cálculo se utilizó para construir el dataset final de afinidades ligando-proteína. Estas energías no deben interpretarse como afinidades experimentales absolutas, sino como puntuaciones computacionales dependientes del protocolo de docking.

D.3. Extracción de resultados y control de cálculos

Los resultados de AutoDock Vina se procesaron automáticamente a partir de los archivos de salida. Para cada cálculo se extrajo la afinidad correspondiente al primer modo de unión, es decir, la mejor energía reportada por Vina. Además, se registró el estado del cálculo para diferenciar dockings completados correctamente de cálculos fallidos o con errores de formato.

Posteriormente, los resultados de docking se transformaron desde formato largo a formato ancho. En el formato largo cada fila correspondía a un par proteína-ligando; en el formato ancho cada fila correspondía a un ligando y las columnas `y_1ao6`, `y_1hzh`, `y_2hav` e `y_3ghg` contenían las afinidades

Tabla D.3: Resumen estadístico de energías de docking ligando-proteína.

Proteína	Media	Mín.	Máx.	DE
1ao6	-4.80	-9.21	-2.57	1.51
1hzh	-4.71	-8.75	-2.52	1.45
2hav	-5.15	-10.09	-2.68	1.69
3ghg	-4.42	-7.96	-2.19	1.39

frente a cada proteína. Los ligandos sin las cuatro salidas completas se descartaron antes de construir el dataset multisalida final.

D.4. Resumen de afinidades ligando-proteína

El resumen estadístico de las afinidades se genera automáticamente a partir del mismo dataset final empleado en el Anexo B. Esto permite comprobar rápidamente los rangos de energía utilizados para entrenar los modelos.

Valores más negativos indican una interacción más favorable dentro del protocolo de docking. La tabla anterior resume la distribución de las energías utilizadas como variables objetivo en los modelos predictivos.

D.5. Uso de las afinidades en el modelo predictivo

Las energías de docking se organizaron en formato multisalida, con una única fila por ligando y una columna objetivo por proteína. Esta estructura permitió entrenar modelos capaces de predecir simultáneamente el perfil de afinidad de cada ligando frente a las cuatro proteínas plasmáticas consideradas.

El uso de un único dataset integrado facilitó combinar las afinidades de docking con los descriptores moleculares RDKit y las variables de membrana. De esta forma se pudieron comparar distintos bloques de información: modelos entrenados solo con descriptores RDKit, modelos entrenados con variables de membrana, modelos combinados y modelos con reducción dimensional. Esta organización permitió evaluar qué tipo de información explicaba mejor la variabilidad observada en las puntuaciones de docking.

Apéndice *E*

Docking nanopartícula-proteína e Índice Contextual Nano-Bio

E.1. Docking nanopartícula-proteína

La interacción nanopartícula-proteína se analizó como una capa contextual independiente. Esta decisión metodológica evitó incorporar directamente información de nanopartículas como si fuera una propiedad intrínseca del ligando. En su lugar, las energías nanopartícula-proteína se combinaron posteriormente con las energías ligando-proteína mediante un índice normalizado.

Las energías más negativas corresponden a interacciones más favorables dentro del protocolo utilizado. En los tres casos evaluados, ZnO_12_0 presentó energías claramente más negativas que Ag_13 y Au_13, por lo que tuvo un peso importante en las combinaciones mejor posicionadas del análisis contextual. La proteína 3ghg no se incluyó en esta capa nanopartícula-proteína final por limitaciones técnicas asociadas al tamaño y preparación del sistema.

Tabla E.1: Energías de docking nanopartícula-proteína utilizadas en la capa contextual.

Nanopartícula	1ao6	1hzh	2hav
Ag_13	-2.24	-2.13	-2.17
Au_13	-2.34	-2.12	-2.34
ZnO_12_0	-7.76	-7.38	-8.44

E.2. Cálculo del Índice Contextual Nano-Bio

El Índice Contextual Nano-Bio se definió como una métrica comparativa para priorizar combinaciones ligando-nanopartícula-proteína. Para evitar sumar energías de naturaleza distinta como si fuesen una magnitud física absoluta, se trabajó con puntuaciones normalizadas por proteína. La afinidad ligando-proteína y la energía nanopartícula-proteína se transformaron en puntuaciones donde valores mayores representan interacciones más favorables:

$$S_{i,p}^{LP} = -z_p(E_{i,p}^{LP})$$

$$S_{n,p}^{NP} = -z_p(E_{n,p}^{NP})$$

A partir de estas dos contribuciones se calculó una puntuación contextual media:

$$S_{i,n,p}^{\text{contexto}} = \frac{S_{i,p}^{LP} + S_{n,p}^{NP}}{2}$$

Finalmente, las puntuaciones se reescalaron a una escala 0–100 para facilitar su interpretación como índice de priorización:

$$ICNB_{i,n,p} = 100 \cdot \frac{S_{i,n,p}^{\text{contexto}} - S_{\text{mín}}^{\text{contexto}}}{S_{\text{máx}}^{\text{contexto}} - S_{\text{mín}}^{\text{contexto}}}$$

El ICNB no representa una energía física de un complejo completo, sino una métrica comparativa para ordenar candidatos dentro del conjunto estudiado.

E.3. Combinaciones mejor posicionadas

LP: ligando-proteína; NP: nanopartícula-proteína. Las mejores combinaciones estuvieron dominadas por ZnO_12_0 y ácido fólico. Este resultado se explica por la combinación de una afinidad ligando-proteína favorable y una contribución nanopartícula-proteína especialmente negativa para ZnO_12_0.

Tabla E.2: Top 10 combinaciones según el Índice Contextual Nano-Bio.

Ligando	NP	Prot	ICNB	ICNB prot.	E LP	E NP
Ácido fólico	ZnO_12_0	2hav	100.00	100.00	-10.09	-8.44
Ácido fólico	ZnO_12_0	1ao6	99.83	100.00	-9.21	-7.76
Ácido fólico	ZnO_12_0	1hzh	97.78	100.00	-8.75	-7.38
Doxo. proxy	ZnO_12_0	1ao6	91.22	91.36	-8.36	-7.76
Curcumina	ZnO_12_0	2hav	89.46	89.44	-8.93	-8.44
Doxo. proxy	ZnO_12_0	1hzh	89.24	91.27	-7.94	-7.38
Doxo. proxy	ZnO_12_0	2hav	85.59	85.56	-8.50	-8.44
Curcumina	ZnO_12_0	1ao6	84.96	85.08	-7.74	-7.76
Ácido tánico	ZnO_12_0	1hzh	84.86	86.79	-7.52	-7.38
Ácido tánico	ZnO_12_0	2hav	84.00	83.97	-8.33	-8.44

E.4. Interpretación del índice

El ICNB permitió integrar en una misma escala la información procedente del docking ligando-proteína y del docking nanopartícula-proteína. Esta integración fue útil para priorizar combinaciones, pero no debe interpretarse como una simulación explícita del complejo nanopartícula-ligando-proteína. En este trabajo, el índice se utilizó como una herramienta de cribado comparativo, orientada a identificar combinaciones prometedoras para estudios posteriores.

La dominancia de ZnO_12_0 en las primeras posiciones se debe a sus energías nanopartícula-proteína más negativas frente a las proteínas evaluadas. Por otro lado, el ácido fólico destacó por sus afinidades ligando-proteína favorables, lo que explica que sus combinaciones con ZnO_12_0 ocupen las primeras posiciones del ranking. Este comportamiento sugiere que el ácido fólico es uno de los agentes de recubrimiento más interesantes dentro del conjunto estudiado, especialmente cuando se considera junto con el modelo de óxido de zinc.

Descriptores moleculares y modelos de aprendizaje automático

F.1. Construcción del dataset predictivo

El dataset predictivo se construyó con una fila por ligando y cuatro salidas de docking ligando-proteína. Las variables de entrada incluyeron descriptores moleculares RDKit y variables de membrana. Las salidas del modelo fueron `y_1ao6`, `y_1hzh`, `y_2hav` e `y_3ghg`, correspondientes a las energías de docking frente a las cuatro proteínas plasmáticas consideradas.

Los descriptores RDKit se calcularon a partir de las estructuras moleculares preparadas en formato SDF. El conjunto incluyó descriptores 2D básicos, como peso molecular, LogP, TPSA, donadores y aceptores de enlace de hidrógeno, enlaces rotables, número de átomos pesados, fracción de carbonos `sp3`, número de anillos y carga formal. Además, cuando la estructura contenía conformación tridimensional, se calcularon descriptores 3D como asfericidad, excentricidad, factores de inercia, momentos principales de inercia, radio de giro e índice de esfericidad.

F.2. Comparación de modelos

Se evaluaron diferentes modelos de regresión multisalida para predecir simultáneamente las cuatro afinidades de docking. La comparación incluyó modelos lineales, modelos basados en árboles, reducción dimensional median-

Tabla F.1: Bloques de variables evaluados en los modelos.

Bloque	Descripción
RDKit_solo	Descriptores moleculares 2D/3D calculados con RDKit. Incluye variables de tamaño, polaridad, lipofilia, flexibilidad, topología y geometría.
Membrana_solo	Variables COSMOtherm/COSMOmic relacionadas con partición, permeabilidad, distribución, energía libre y difusión en una bicapa modelo de DMPC.
RDKit+membrana	Combinación de descriptores RDKit y variables de membrana.
PCA	Representación reducida de los bloques de variables mediante componentes principales.
PLSRegression	Modelo basado en variables latentes que combina reducción dimensional supervisada y regresión.

te PCA y regresión PLS. El objetivo fue comprobar si los descriptores RDKit eran suficientes para explicar las afinidades de docking o si la incorporación de variables de membrana mejoraba el rendimiento predictivo.

La tabla completa de modelos se genera automáticamente a partir del CSV de métricas exportado durante el análisis.

Tabla F.2: Resultados completos de la comparación de modelos de regresión multisalida.

Bloque	Modelo	N	Variables	CV RMSE	MAE test	RMSE test	R2 test
RDKit_solo	ExtraTrees	52	26	0.510	0.319	0.412	0.884
RDKit_membrana_seleccionada	ExtraTrees	52	49	0.512	0.339	0.412	0.886
RDKit_membrana_filtrada_auto	ExtraTrees	52	49	0.512	0.339	0.412	0.886
RDKit_solo	PLSRegression	52	26	0.400	0.317	0.426	0.886
RDKit_solo	PCA_Ridge	52	26	0.391	0.347	0.467	0.865
RDKit_membrana_seleccionada	PLSRegression	52	49	0.343	0.359	0.470	0.852
RDKit_membrana_filtrada_auto	PLSRegression	52	49	0.343	0.359	0.470	0.852
RDKit_membrana_seleccionada	Ridge	52	49	0.337	0.374	0.486	0.844
RDKit_membrana_filtrada_auto	Ridge	52	49	0.337	0.374	0.486	0.844
RDKit_membrana_filtrada_auto	PCA_Ridge	52	49	0.332	0.390	0.493	0.839
RDKit_membrana_seleccionada	PCA_Ridge	52	49	0.332	0.390	0.493	0.839
RDKit_solo	Ridge	52	26	0.420	0.348	0.539	0.816
RDKit_solo	RandomForest	52	26	0.638	0.476	0.595	0.764
RDKit_membrana_filtrada_auto	RandomForest	52	49	0.653	0.519	0.626	0.741
RDKit_membrana_seleccionada	RandomForest	52	49	0.653	0.519	0.626	0.741
Membrana_solo	RandomForest	52	23	0.795	0.621	0.731	0.650
Membrana_solo	ExtraTrees	52	23	0.767	0.620	0.744	0.641
Membrana_solo	Ridge	52	23	0.825	0.693	0.860	0.521
Membrana_solo	PCA_Ridge	52	23	0.768	0.900	1.175	0.101

Tabla F.3: Resumen del modelo final seleccionado.

Bloque	Modelo	N	Variables	MAE test	RMSE test	R ² test		
RDKit_solo	ExtraTrees	52	26	0.319	0.412	0.884		
Membrana_solo	PLSRegression	52	23	0.759	0.957	1.351	-0.188	

El mejor rendimiento en test se obtuvo con ExtraTrees utilizando únicamente descriptores RDKit. PLSRegression presentó un comportamiento competitivo, especialmente en validación cruzada, mientras que las configuraciones con PCA no mejoraron el rendimiento final. La incorporación de variables de membrana produjo resultados muy similares al bloque RDKit_solo, pero no redujo claramente el error de predicción.

F.3. Modelo final

El modelo seleccionado como modelo final fue ExtraTrees entrenado con el bloque RDKit_solo. Este modelo obtuvo un RMSE test de aproximadamente 0.412 kcal/mol, un MAE test de 0.319 kcal/mol y un R² test de 0.884. Estos valores indican una buena concordancia entre las afinidades predichas y las afinidades de docking utilizadas como referencia.

Aunque el modelo RDKit+membrana obtuvo un R² test ligeramente superior, su error no mejoró de forma clara frente al modelo RDKit_solo. Por ello, se seleccionó el modelo RDKit_solo + ExtraTrees como modelo final, al ser más simple y presentar un rendimiento equivalente o superior en términos de error.

F.4. Rendimiento por proteína

Además de las métricas globales, se evaluó el rendimiento del modelo final para cada una de las cuatro proteínas plasmáticas. Esta comparación permitió identificar si alguna proteína presentaba una predicción más difícil que las demás.

El rendimiento no fue idéntico para todas las proteínas. La salida asociada a 2hav presentó el menor RMSE, mientras que 1hzh mostró el mayor error relativo dentro del modelo final. Estas diferencias pueden deberse a la variabilidad de afinidades de cada proteína, a la forma de sus regiones de interacción o al tamaño limitado del dataset.

Tabla F.4: Métricas del modelo final por proteína.

Proteína	MAE	RMSE	R2
1ao6	0.294	0.378	0.917
1hzh	0.408	0.540	0.783
2hav	0.241	0.277	0.959
3ghg	0.332	0.408	0.878
media	0.319	0.412	0.884

F.5. Interpretación del papel de las variables

El resultado principal de la comparación fue que los descriptores RDKit explicaron gran parte de la variabilidad de las afinidades de docking. Esto es coherente con la naturaleza del problema, ya que las energías ligando-proteína dependen en gran medida de características estructurales del ligando, como tamaño, polaridad, superficie, flexibilidad, geometría y capacidad de establecer interacciones no covalentes.

Las variables de membrana aportaron información fisicoquímica complementaria, pero no mejoraron claramente el error de predicción. Esta observación no implica que sean irrelevantes, sino que describen un fenómeno distinto: el comportamiento del ligando en una bicapa modelo de DMPC, no la interacción directa con una proteína plasmática. Por ello, en el trabajo se interpretaron como una capa adicional de caracterización, no como el bloque principal para predecir afinidad de docking.

F.6. Uso predictivo del modelo

El modelo final se integró en la aplicación Streamlit para estimar afinidades de nuevos ligandos a partir de su SMILES. La aplicación calcula los descriptores RDKit necesarios, los organiza en el mismo formato que el dataset de entrenamiento y aplica el modelo ExtraTrees final para obtener las cuatro predicciones de afinidad.

La predicción debe entenderse como un cribado preliminar dentro del dominio químico del dataset. No sustituye al docking explícito ni a la validación experimental, pero permite priorizar moléculas antes de realizar cálculos más costosos.

Apéndice G

Análisis PLIP de complejos representativos

G.1. Selección de complejos

Como análisis estructural complementario, se aplicó PLIP a complejos proteína-ligando representativos. La selección se realizó a partir de los mejores complejos de docking para cada proteína, tomando los ligandos con energías más favorables dentro del dataset final. El objetivo fue complementar la puntuación de docking con una descripción cualitativa de los contactos no covalentes presentes en las estructuras generadas.

El flujo se automatizó mediante un script específico que seleccionó los tres mejores ligandos por proteína, localizó los archivos estructurales correspondientes, generó complejos proteína-ligando en formato PDB y preparó los comandos de ejecución de PLIP. Cuando PLIP estuvo disponible en el entorno, se generaron los reportes en formato TXT y XML dentro de la carpeta de resultados. De esta forma, el análisis PLIP quedó integrado como una capa estructural complementaria dentro del flujo del trabajo.

G.2. Interacciones detectadas

En 11 de los 12 complejos se detectaron interacciones proteína-ligando. El único sistema sin interacciones detectadas fue ácido tánico aproximado frente a 1hzh. El ácido fólico presentó el patrón de interacción más completo, combinando contactos hidrofóbicos y puentes de hidrógeno frente a 1ao6, 1hzh y 2hav.

Tabla G.1: Resumen del análisis PLIP en complejos proteína-ligando representativos.

Proteína	Ligando	Hidrofóbicos	Puentes H	Total
1ao6	Curcumina	18	0	18
1ao6	Doxo. proxy	18	0	18
1ao6	Ácido fólico	19	7	26
1hzh	Doxo. proxy	12	0	12
1hzh	Ácido fólico	13	8	21
1hzh	Ácido tánico	0	0	0
2hav	Curcumina	13	0	13
2hav	Doxo. proxy	10	0	10
2hav	Ácido fólico	18	4	22
3ghg	Curcumina	13	0	13
3ghg	Doxo. proxy	10	0	10
3ghg	Ácido fólico	12	0	12

G.3. Residuos destacados

Los reportes PLIP permitieron identificar residuos recurrentes en los complejos representativos. Entre los residuos destacados se observaron LYS137, ARG186, LEU115 y LEU182 en 1ao6; GLN166, PHE83, GLU165 y LYS103 en 1hzh; LYS591, ARG590, LEU228 y LEU134 en 2hav; y MET78, ILE79, VAL132 y ALA101 en 3ghg.

Estos residuos se interpretaron como una primera aproximación a las regiones de contacto proteína-ligando en los complejos mejor posicionados. En particular, la presencia de puentes de hidrógeno en los complejos con ácido fólico sugiere una interacción más específica que la observada en complejos dominados únicamente por contactos hidrofóbicos.

G.4. Limitaciones del análisis PLIP

El análisis PLIP debe considerarse preliminar. Aunque PLIP se ejecutó correctamente sobre los complejos representativos, los archivos PDB utilizados procedían de salidas de docking de Vina que contenían varios modos de unión. En la preparación de los complejos no se aisló explícitamente solo el MODEL 1; por ello, algunos archivos presentaron un número de átomos de ligando compatible con la inclusión de varias poses en un mismo complejo.

Esta limitación afecta principalmente a la interpretación cuantitativa de los contactos. Por tanto, los recuentos de interacciones se interpretan de forma cualitativa, como apoyo estructural al docking y al Índice Contextual Nano-Bio, y no como una cuantificación definitiva de interacciones para una única conformación ligando-proteína.

Una mejora directa del flujo consistiría en extraer exclusivamente el `MODEL 1` de cada salida de Vina, generar de nuevo los complejos PDB y repetir el análisis PLIP sobre esas estructuras depuradas. De esta forma se obtendrían recuentos de interacción asociados a una única pose de docking.

G.5. Interpretación general

El análisis PLIP aportó una lectura estructural complementaria a las puntuaciones de docking. Mientras que Vina proporciona una energía de unión estimada, PLIP permite identificar el tipo de contactos implicados en la estabilización de la pose. En este trabajo, los contactos hidrofóbicos fueron los más frecuentes, aunque los complejos con ácido fólico destacaron por combinar contactos hidrofóbicos y puentes de hidrógeno.

Estos resultados son coherentes con la posición del ácido fólico entre los ligandos mejor clasificados en el análisis ICNB. Su comportamiento no parece depender únicamente de una energía de docking favorable, sino también de la presencia de interacciones específicas con varias proteínas plasmáticas. Aun así, debido a las limitaciones comentadas, esta interpretación debe entenderse como exploratoria y orientada a priorizar sistemas para análisis estructurales más detallados.

Apéndice *H*

Aplicación Streamlit y código fuente

H.1. Estructura del repositorio

El proyecto se organizó en carpetas separadas para datos, scripts, resultados, aplicación y documentos. Esta estructura facilita reproducir el flujo completo y localizar los archivos generados en cada etapa.

```
TFM_Docking/  
|-- datasets/  
|-- scripts/  
|   |-- modelos/  
|   |-- membrana/  
|   |-- nanoparticulas/  
|   |-- interacciones/  
|   |-- tablas/  
|-- resultados/  
|   |-- modelos/  
|   |-- nanoparticulas/  
|   |-- diagnosticos/  
|   |-- tablas_generadas/  
|   |-- figuras_generadas/  
|   |-- plip/  
|-- app/  
|-- qmd/
```

```
-- memoria.qmd
-- anexos.qmd
```

La separación entre carpetas permitió mantener diferenciados los datos de entrada, los scripts de procesamiento, los resultados generados, la aplicación interactiva y los documentos Quarto. Esta organización también facilitó la actualización progresiva del trabajo a medida que se incorporaron nuevas capas de análisis, como el ICNB, PLIP y la predicción desde SMILES.

H.2. Scripts principales

El código del proyecto se organizó en módulos funcionales. En lugar de depender de un único script, el flujo se dividió en bloques dedicados a modelización, variables de membrana, análisis nanopartícula-proteína, PLIP y generación de resultados. Esta organización permitió ejecutar y depurar cada parte del trabajo de forma independiente.

Tabla H.1: Módulos principales del código fuente.

Módulo	Función principal
<code>scripts/modelos/</code>	Entrenamiento y comparación de modelos predictivos. Incluye el entrenamiento inicial, la comparación entre bloques RDKit, membrana, RDKit+membrana, PCA y PLS, y el entrenamiento del modelo final ExtraTrees con descriptores RDKit.
<code>scripts/membrana/</code>	Extracción, corrección, diagnóstico e integración de variables de membrana procedentes de COSMOtherm/COSMOmic. Este módulo permitió generar el bloque de variables con prefijo <code>mem_</code> e incorporarlo al dataset final.
<code>scripts/nanoparticulas/</code>	Procesamiento de resultados de docking nanopartícula-proteína, construcción del dataset contextual ligando-nanopartícula-proteína y cálculo del Índice Contextual Nano-Bio.
<code>scripts/interacciones/</code>	Selección de complejos proteína-ligando representativos, generación de complejos PDB y preparación de la ejecución de PLIP para analizar contactos no covalentes.
<code>scripts/tablas/</code>	Generación de tablas, figuras y salidas gráficas utilizadas en la memoria y en los anexos. Incluye scripts de análisis en R y generación de figuras finales.

Tabla H.1: Módulos principales del código fuente. Continuación.

Módulo	Función principal
app/	Aplicación Streamlit para visualizar resultados, explorar modelos y realizar predicciones de afinidad para nuevos ligandos introducidos mediante SMILES.

Los scripts auxiliares de cada módulo se mantuvieron separados para facilitar la depuración. Por ejemplo, el bloque de membrana incluyó scripts específicos para extraer variables, corregir valores de partición y unir los resultados con el dataset final. De forma similar, el bloque de nanopartículas separó la extracción de resultados, la corrección de tablas y el cálculo del ICNB. Esta división permitió modificar una parte del flujo sin tener que rehacer todo el análisis.

H.3. Aplicación Streamlit

La aplicación Streamlit se desarrolló como herramienta auxiliar de visualización y exploración de resultados. Inicialmente permitió consultar el dataset, comparar modelos predictivos, revisar métricas por proteína, visualizar predicciones real-predicho, explorar variables de membrana, analizar resultados de docking nanopartícula-proteína y consultar el ranking contextual.

Posteriormente se añadió una pestaña de predicción desde SMILES. Esta función permite introducir una nueva molécula, calcular sus descriptores RDKit y estimar su perfil de afinidad frente a las cuatro proteínas plasmáticas mediante el modelo ExtraTrees final. De esta forma, la aplicación no solo sirve como visor de resultados, sino también como herramienta de cribado preliminar de posibles agentes de recubrimiento.

H.4. Ejecución de la aplicación

Desde la raíz del proyecto, la aplicación puede ejecutarse con Streamlit dentro del entorno conda utilizado durante el trabajo:

```
conda activate docking
streamlit run app\app_tfm_con_prediccion.py
```

El archivo principal de la aplicación es:

Tabla H.2: Funciones principales de la aplicación Streamlit.

Sección de la aplicación	Función
Resumen	Presentación general del proyecto, número de ligandos, variables, proteínas objetivo y mejor modelo detectado.
Modelos	Visualización de la comparación de modelos y ranking por RMSE en test.
Métricas por proteína	Consulta del rendimiento del modelo final para cada salida de docking.
Predicciones	Comparación entre valores reales y predichos en el conjunto de test.
Membrana	Exploración de variables COSMOtherm/COSMOmic y visualización de propiedades de membrana.
Nanopartículas	Consulta de resultados de docking nanopartícula-proteína y mapas de calor.
Ranking contextual	Filtrado y visualización del ranking ligando-nanopartícula-proteína.
Predicción nuevo ligando	Introducción de un SMILES, cálculo de descriptores RDKit y predicción de afinidades.
Figuras generadas	Visualización de figuras exportadas para memoria y anexos.
Dataset	Consulta del dataset integrado completo.
Archivos y rutas	Comprobación de rutas detectadas y disponibilidad de archivos necesarios.

`app/app_tfm_con_prediccion.py`

La aplicación está preparada para detectar rutas de forma robusta. Para ello busca automáticamente la raíz del proyecto y localiza los archivos principales en carpetas como `datasets/`, `resultados/modelos/`, `resultados/nanoparticulas/`, `resultados/tablas_generadas/` y `resultados/figuras_generadas/`. Si algún archivo no se encuentra, la propia aplicación muestra un aviso para facilitar la depuración.

H.5. Archivos del modelo final

La pestaña de predicción desde SMILES requiere que estén disponibles el modelo entrenado y la lista de variables utilizadas durante el entrenamiento. En el flujo final, los archivos esperados son:

```
resultados/modelos/modelo_final_rdkit/modelo_final_extratrees_rdkit.joblib
resultados/modelos/modelo_final_rdkit/features_modelo_final.csv
```

El archivo `modelo_final_extratrees_rdkit.joblib` contiene el modelo ExtraTrees entrenado con el bloque RDKit. El archivo `features_modelo_final.csv` contiene la lista de descriptores que deben calcularse para que una nueva molécula pueda introducirse en el modelo con el mismo formato que el dataset de entrenamiento.

Si estos archivos no existen, debe ejecutarse de nuevo el script de entrenamiento del modelo final:

```
python scripts\modelos\entrenar_modelo_final.py
```

H.6. Predicción desde SMILES

La predicción desde SMILES sigue un flujo interno sencillo. Primero, el usuario introduce una cadena SMILES y un nombre opcional para la molécula. Después, RDKit interpreta la estructura química y calcula los descriptores necesarios. A continuación, la aplicación ordena esos descriptores según la lista utilizada durante el entrenamiento y aplica el modelo ExtraTrees final para obtener cuatro afinidades predichas: `y_1ao6`, `y_1hzh`, `y_2hav` e `y_3ghg`.

Los resultados se muestran en una tabla y en una gráfica de barras. Además, la aplicación permite descargar las predicciones en formato CSV. Esta funcionalidad permite utilizar el modelo como una herramienta de cribado preliminar, útil para comparar nuevas moléculas antes de realizar cálculos de docking explícitos.

H.7. Limitaciones de la aplicación

La aplicación no recalcula docking molecular ni sustituye a una simulación estructural completa. Las predicciones desde SMILES dependen del modelo

entrenado y, por tanto, del dominio químico del dataset utilizado. Moléculas muy alejadas de los ligandos incluidos en el trabajo pueden quedar fuera del rango de aplicabilidad del modelo.

Por este motivo, los resultados de la aplicación deben interpretarse como una ayuda para priorizar candidatos, no como afinidades experimentales ni como sustituto de validación mediante docking explícito, simulación molecular o ensayos experimentales.