



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Trabajo de Fin de Máster

Máster universitario en Ingeniería Biomédica

**Modelización computacional de la interacción
de agentes de recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con proteínas
plasmáticas mediante acoplamiento molecular
y aprendizaje automático**

Presentado por Pablo Fuentes de Mateo

Tutores: Santiago Aparicio – Pedro A. Marcos

Universidad de Burgos

Burgos, julio de 2026



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Santiago Aparicio, profesor del departamento de química D. Pedro A. Marcos, profesor del departamento de física

Expone/n:

Que el/la alumno/a D. Pablo Fuentes de Mateo, con DNI 71566685T, ha realizado el Trabajo final del Master en Ingeniería Biomédica titulado *Modelización computacional de la interacción de agentes de recubrimiento de nanopartículas metálicas (Au, Ag, ZnO) con proteínas plasmáticas mediante acoplamiento molecular y aprendizaje automático*.

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección del/los que suscribe/n.

En Burgos, a 6 de julio de 2026

D. Santiago Aparicio

D. Pedro A. Marcos

Agradecimientos

Quiero agradecer a mis tutores, Santiago Aparicio Martínez y Pedro A. Marcos Villa, su orientación, seguimiento y ayuda durante el desarrollo de este Trabajo de Fin de Máster.

También quiero agradecer a Sergio de la Huerta Sainz, investigador del Departamento de Química, su ayuda desinteresada durante distintas etapas del trabajo. Su disponibilidad, apoyo y colaboración han sido muy importantes para poder avanzar y resolver varias partes del proyecto.

Agradezco al CENITS, Centro Extremeño de Investigación, Innovación Tecnológica y Supercomputación, el acceso a los recursos de supercomputación utilizados durante el desarrollo de parte de los cálculos de este trabajo.

Agradezco igualmente a la Universidad de Burgos y al Máster Universitario en Ingeniería Biomédica la formación recibida y los recursos puestos a disposición para la realización del trabajo.

Por último, quiero agradecer especialmente a mi familia su apoyo incondicional, su paciencia y su confianza. Les debo todo lo que soy y lo que he conseguido; sin ellos, nada de esto habría sido posible.

Resumen

Este Trabajo de Fin de Máster desarrolla un flujo computacional para estudiar la interacción de agentes de recubrimiento de nanopartículas metálicas con proteínas plasmáticas mediante acoplamiento molecular y aprendizaje automático. Se integraron resultados de docking ligando-proteína frente a cuatro proteínas plasmáticas, descriptores moleculares RDKit 2D/3D, variables de membrana procedentes de cálculos COSMOtherm/COSMOmic y resultados de docking nanopartícula-proteína para sistemas de Au, Ag y ZnO. A partir de estos datos se entrenaron modelos de regresión multisalida para predecir afinidades de docking y se compararon distintos bloques de variables, incluyendo descriptores RDKit, propiedades de membrana y reducción dimensional mediante PCA.

El mejor rendimiento predictivo se obtuvo con un modelo ExtraTrees utilizando descriptores RDKit, mientras que la incorporación de variables de membrana no produjo una mejora clara del error de predicción. Los resultados nanopartícula-proteína se analizaron como una capa contextual independiente y se reformularon mediante el Índice Contextual Nano-Bio (ICNB), que permitió priorizar combinaciones ligando-nanopartícula-proteína. Las mejores combinaciones estuvieron dominadas por $(\text{ZnO})_{12}$ y ácido fólico. Además, se realizó un análisis estructural preliminar mediante PLIP sobre complejos representativos, observándose contactos hidrofóbicos y puentes de hidrógeno en los sistemas mejor posicionados. Finalmente, se desarrolló una aplicación Streamlit para visualizar resultados y predecir afinidades de nuevos ligandos a partir de SMILES.

Descriptores

Nanopartículas metálicas, oro, plata, óxido de zinc, agentes de recubrimiento, docking molecular, proteínas plasmáticas, COSMOtherm, membrana, aprendizaje automático, regresión multisalida, ICNB, PLIP.

Abstract

This Master’s Thesis develops a computational workflow to study the interaction of nanoparticle coating agents with plasma proteins using molecular docking and machine learning. Ligand-protein docking results against four plasma proteins were integrated with RDKit 2D/3D molecular descriptors, COSMOtherm/COSMOmic-derived membrane variables and nanoparticle-protein docking results for Au, Ag and ZnO systems. Multi-output regression models were trained to predict docking affinities and different feature blocks were compared, including RDKit descriptors, membrane properties and PCA-based dimensionality reduction.

The best predictive performance was obtained with an ExtraTrees model using RDKit descriptors, whereas the inclusion of membrane variables did not clearly improve the prediction error. Nanoparticle-protein docking results were analysed as an independent contextual layer and reformulated through the Nano-Bio Contextual Index (NBCI), enabling the prioritisation of ligand-nanoparticle-protein combinations. The highest-ranked combinations were dominated by (ZnO)₁₂ and folic acid. In addition, a preliminary PLIP structural analysis was performed on representative complexes, revealing hydrophobic contacts and hydrogen bonds in the best-ranked systems. Finally, a Streamlit application was developed to visualise results and predict affinities for new ligands from SMILES.

Keywords

Metallic nanoparticles, gold nanoparticles, silver nanoparticles, zinc oxide nanoparticles, coating agents, molecular docking, plasma proteins, COSMOtherm, membrane, machine learning, multi-output regression, NBCI, PLIP.

Índice general

Agradecimientos	4
Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
Objetivos	2
Metodología	3
3.1. Diseño general del flujo computacional	3
3.2. Sistemas estudiados	3
3.3. Preparación y validación estructural de ligandos y nanopartículas	3
3.4. Preparación de receptores y docking ligando-proteína	4
3.5. Cálculo de descriptores moleculares RDKit	4
3.6. Variables de membrana COSMOtherm/COSMOmic	4
3.7. Construcción del dataset final	4
3.8. Modelos de aprendizaje automático	5
3.9. Comparación de bloques de variables	5
3.10. Docking nanopartícula-proteína	5
3.11. Análisis estructural de complejos representativos	6
3.12. Índice Contextual Nano-Bio	6
3.13. Generación de tablas, figuras y aplicación de visualización	6
Resultados	7
4.1. Comparación de modelos predictivos	7
4.2. Rendimiento por proteína	8
4.3. Predicción real frente a predicción estimada	8
4.4. Variables relevantes	9
4.5. Docking nanopartícula-proteína	10
4.6. Índice Contextual Nano-Bio	11
4.7. Análisis complementarios: PLIP y variables de membrana	11
4.8. Aplicación de visualización y predicción	11
Discusión	12
Conclusiones	14
Líneas futuras	15
Bibliografía	16

Índice de figuras

4.1. Comparación de modelos por RMSE en test.	7
4.2. Mejor RMSE por bloque de variables.	8
4.3. Rendimiento por proteína del mejor modelo: RMSE y R^2	8
4.4. Comparación real vs predicho para las cuatro proteínas.	9
4.5. Variables más correlacionadas con las afinidades.	10
4.6. Mapa de calor de docking nanopartícula-proteína.	10

Índice de tablas

4.1. Top 10 combinaciones según el Índice Contextual Nano-Bio.	11
--	----

Introducción

La nanomedicina constituye una de las áreas con mayor proyección dentro de la ingeniería biomédica, al permitir el diseño de sistemas de tamaño nanométrico orientados al diagnóstico, tratamiento y seguimiento de enfermedades. Estos sistemas presentan dimensiones comparables a estructuras biológicas fundamentales y propiedades fisicoquímicas ajustables mediante cambios en tamaño, forma, composición y química superficial. Entre los nanomateriales más estudiados destacan las nanopartículas metálicas y metal-óxido, como las nanopartículas de oro, plata y óxido de zinc, debido a su interés en aplicaciones de diagnóstico, terapia, administración dirigida de fármacos, biosensado, imagen biomédica y terapias fototérmicas o fotodinámicas ([Zahdeh et al., 2025](#), [Fatima et al. \(2022\)](#)).

Sin embargo, la eficacia biomédica de una nanopartícula no depende únicamente de sus propiedades sintéticas iniciales. Al entrar en contacto con fluidos biológicos, como el plasma sanguíneo, la superficie del nanomaterial se recubre rápidamente de proteínas, lípidos y otras biomoléculas, formando la denominada corona biomolecular o corona proteica ([Monopoli et al., 2012](#)). Esta corona modifica la identidad biológica de la nanopartícula, de modo que las células y tejidos no interactúan con la superficie original diseñada en el laboratorio, sino con una interfaz híbrida formada por el nanomaterial, sus agentes de recubrimiento y las biomoléculas adsorbidas ([Monopoli et al., 2012](#), [Walkey and Chan \(2012\)](#)). Como consecuencia, la corona proteica puede alterar parámetros críticos como el tamaño hidrodinámico, la carga superficial, la estabilidad coloidal, la biodistribución, la captación celular, el aclaramiento por el sistema mononuclear fagocítico, la inmunogenicidad y la toxicidad ([Walkey and Chan, 2012](#), [Monopoli et al. \(2013\)](#)).

Las características fisicoquímicas de la nanopartícula, de su recubrimiento y del entorno biológico condicionan qué proteínas plasmáticas se adsorben sobre su superficie, lo que finalmente influye en su interacción con el sistema inmune y circulatorio ([Walkey and Chan, 2012](#), [Monopoli et al. \(2013\)](#)). Por ello, comprender cómo los recubrimientos superficiales de nanopartículas interactúan con proteínas plasmáticas resulta esencial para el diseño racional de nanomateriales más seguros y eficaces.

El recubrimiento previo de la nanopartícula con agentes químicos permite modular su estabilidad, solubilidad, funcionalización superficial y comportamiento biológico. No obstante, evaluar experimentalmente todas las combinaciones posibles de nanopartículas, recubrimientos y proteínas resulta lento y costoso. Por este motivo, las aproximaciones computacionales constituyen una herramienta útil para guiar la selección de candidatos y acelerar las etapas iniciales de investigación ([Dridi et al., 2024](#)).

La combinación de técnicas de acoplamiento molecular, o docking, con aprendizaje automático permite integrar información estructural, fisicoquímica y predictiva para estudiar interacciones nano-bio de forma sistemática. En este contexto, el docking molecular permite estimar afinidades relativas entre ligandos y proteínas, mientras que los modelos de aprendizaje automático pueden relacionar esas afinidades con descriptores moleculares y propiedades complementarias. Esta estrategia facilita la priorización de agentes de recubrimiento antes de abordar etapas de validación experimental ([Findlay et al., 2018](#), [Ban et al. \(2020\)](#)).

Objetivos

El objetivo general de este Trabajo Fin de Máster es desarrollar y aplicar una metodología computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas humanas, combinando acoplamiento molecular, descriptores moleculares, variables de membrana y aprendizaje automático.

De forma específica, se plantean los siguientes objetivos:

1. Seleccionar y preparar una biblioteca de agentes de recubrimiento representativos de nanopartículas metálicas y metal-óxido.
2. Optimizar las estructuras moleculares de los ligandos y validar las geometrías mediante análisis de frecuencias vibracionales.
3. Preparar las estructuras de las proteínas plasmáticas diana y organizar los cálculos de docking ligando-proteína.
4. Construir una matriz de afinidades ligando-proteína para cuatro proteínas plasmáticas.
5. Calcular descriptores moleculares 2D/3D mediante RDKit y combinarlos con los resultados de docking.
6. Extraer variables de membrana procedentes de cálculos COSMOtherm/COSMOmic en DMPC y evaluar su utilidad como información complementaria.
7. Desarrollar modelos de regresión multisalida para predecir afinidades de docking frente a las proteínas estudiadas.
8. Comparar bloques de variables RDKit, membrana y combinaciones de ambos, incluyendo modelos lineales, PLS, métodos de árboles y reducción dimensional mediante PCA.
9. Analizar los resultados de docking nanopartícula-proteína como una capa contextual independiente.
10. Generar un ranking exploratorio de combinaciones ligando-nanopartícula-proteína mediante puntuaciones normalizadas.
11. Automatizar la generación de tablas, figuras y una aplicación de visualización para facilitar la trazabilidad y reproducibilidad del flujo de trabajo.
12. Desarrollar una aplicación interactiva en Streamlit para visualizar los resultados obtenidos y estimar afinidades de nuevos ligandos a partir de su SMILES mediante el modelo predictivo final.

Metodología

3.1. Diseño general del flujo computacional

El trabajo se estructuró como un flujo computacional reproducible basado en archivos CSV, scripts de Python/R y una plantilla Quarto para la generación de memoria y anexos. La unidad principal del modelo predictivo fue el ligando, entendido como agente de recubrimiento o molécula funcional asociable a nanopartículas. Para cada ligando se integraron descriptores moleculares, variables de membrana y cuatro valores de afinidad de docking ligando-proteína.

El flujo se dividió en seis bloques: preparación y validación estructural de ligandos, docking ligando-proteína, cálculo de descriptores RDKit, extracción de variables de membrana, entrenamiento de modelos de aprendizaje automático y análisis contextual de docking nanopartícula-proteína. Esta separación evitó mezclar directamente entidades distintas dentro de un mismo modelo: el modelo principal trabaja con filas de ligando, mientras que la información nanopartícula-proteína se analiza como una capa independiente.

3.2. Sistemas estudiados

La biblioteca de trabajo incluyó agentes de recubrimiento y moléculas con interés biomédico, abarcando compuestos pequeños, grupos con afinidad por superficies metálicas, moléculas polares, moléculas aromáticas y algunos fármacos o aproximaciones estructurales de fármacos. Las proteínas plasmáticas se identificaron mediante sus códigos estructurales: 1AO6 (sérum albúmina humana), 1HZH (anticuerpo humano intacto IgG1 b12), 2HAV (Apo-humana de la transferrina) y 3GHG (fibrinógeno humano).

Las nanopartículas se consideraron mediante modelos simplificados de oro, plata y óxido de zinc. Para el análisis nanopartícula-proteína se emplearon los sistemas (Ag)₁₃, (Au)₁₃ y (ZnO)₁₂.

3.3. Preparación y validación estructural de ligandos y nanopartículas

Las estructuras moleculares de los ligandos fueron preparadas y optimizadas antes de su uso en el flujo de docking y cálculo de descriptores. La optimización geométrica se complementó con cálculos de frecuencias vibracionales. La ausencia de frecuencias imaginarias se utilizó como criterio de validación de mínimo local, de forma que las frecuencias actuaron como control de estabilidad estructural y no como variables principales del modelo predictivo.

La optimización geométrica de los ligandos y el cálculo de frecuencias se realizaron mediante TURBOMOLE ([TURBOMOLE GmbH, 2023](#)), empleando el funcional híbrido B3LYP con corrección de dispersión DFT-D4 ([Grimme et al., 2010](#)) y la base def2-TZVP ([Weigend and Ahlrichs, 2005](#)). Estos cálculos generaron estructuras optimizadas compatibles con los pasos posteriores del flujo y, cuando fue necesario, archivos de tipo Molden para inspección estructural y conversión de formatos.

De forma complementaria, se iniciaron cálculos exploratorios de complejos nanopartícula-ligando mediante ORCA ([Neese, 2022](#)), empleando el mismo nivel teórico general. Estos cálculos se plantearon como paso previo a la preparación de sistemas nanopartícula-ligando-proteína para docking, pero no se llegaron a incluir como una capa completa dentro del modelo final debido a problemas técnicos ajenos a nuestra responsabilidad.

3.4. Preparación de receptores y docking ligando-proteína

El acoplamiento molecular ligando-proteína se realizó con AutoDock Vina, empleando estructuras de proteínas preparadas en formato PDBQT y ligandos también convertidos a PDBQT. AutoDock Vina explora poses del ligando en la región de búsqueda definida y estima una afinidad de unión aproximada mediante su función de puntuación (Trott and Olson, 2010). La versión moderna de Vina permite automatizar cálculos en modo *batch* y facilita la integración en flujos de cribado mediante interfaces de scripting (Eberhardt et al., 2021).

Para cada combinación ligando-proteína se conservó la mejor afinidad calculada por docking. Los valores se almacenaron en una tabla final con una fila por ligando y una columna objetivo por proteína. Dado que las cuatro salidas son continuas y se predicen de forma simultánea, el problema de aprendizaje automático se formuló como una regresión multisalida.

3.5. Cálculo de descriptores moleculares RDKit

A partir de las estructuras moleculares de los ligandos se calcularon descriptores con RDKit (RDKit Developers, 2026). Esta herramienta permite, a partir de una representación molecular como SMILES o de una estructura química, obtener variables numéricas asociadas a distintas propiedades fisicoquímicas.

Estos descriptores se incorporaron al dataset como variables de entrada del modelo predictivo. De esta forma, cada ligando quedó representado por un vector numérico comparable, que posteriormente se relacionó con las afinidades calculadas mediante docking.

3.6. Variables de membrana COSMOtherm/COSMOmic

Las variables de membrana se extrajeron a partir de cálculos en una bicapa de dimiristoilfosfatidilcolina (DMPC) en agua a 37 °C. El fundamento teórico se basa en COSMO-RS, que utiliza densidades de carga de apantallamiento obtenidas a partir de cálculos cuánticos para predecir propiedades termodinámicas en fase líquida (Klamt, 1995). Para entornos anisótropos como micelas y biomembranas, COSMOmic permite describir perfiles dependientes de la profundidad en la membrana y calcular propiedades como partición membrana/agua y distribuciones internas (Klamt et al., 2008; Jakobtorweihen et al., 2013; Ingram et al., 2013).

El análisis permitió reducir datos complejos de membrana a un conjunto de indicadores clave, como coeficientes de partición y permeabilidad, junto con resúmenes estadísticos de cómo varían propiedades energéticas, distribución y difusión desde la superficie hasta el centro de la bicapa.

Las variables de membrana se incorporaron como bloque complementario al dataset de ligandos. Su objetivo fue evaluar si la información relacionada con partición, permeabilidad y comportamiento en membrana aportaba mejora predictiva frente a los descriptores RDKit. Metodológicamente, se mantuvieron separadas para poder comparar modelos entrenados solo con RDKit, solo con variables de membrana y con la combinación de ambos bloques.

3.7. Construcción del dataset final

El dataset final se construyó mediante la unión de tres fuentes de información: descriptores moleculares RDKit, variables de membrana y afinidades de docking ligando-proteína. La tabla principal mantuvo una fila por ligando. Las columnas `y_1ao6`, `y_1hzh`, `y_2hav` y `y_3ghg` se

definieron como variables objetivo del modelo y representan la mejor energía de docking obtenida para cada ligando frente a las proteínas 1ao6, 1hzh, 2hav y 3ghg, respectivamente.

Antes del entrenamiento se sustituyeron valores infinitos por valores perdidos y se aplicó imputación por la mediana dentro del flujo de modelado. Las variables de varianza nula se eliminaron mediante un filtro de varianza. En los modelos lineales y en PCA se aplicó escalado estándar para evitar que variables con distinta magnitud dominaran el ajuste. En los modelos basados en árboles no fue necesario escalar las variables, aunque se mantuvo un flujo homogéneo de preprocesado para asegurar comparaciones reproducibles.

3.8. Modelos de aprendizaje automático

Se compararon distintos modelos de regresión multisalida usando scikit-learn ([Pedregosa et al., 2011](#)). Los modelos evaluados fueron Ridge, PLSRegression, RandomForestRegressor, ExtraTreesRegressor y PCA seguido de Ridge. Ridge se incluyó como modelo lineal regularizado; PLSRegression como modelo útil en escenarios con variables correlacionadas y tamaño muestral reducido; Random Forest y ExtraTrees como métodos no lineales basados en ensamblados de árboles; y PCA_Ridge como estrategia de reducción dimensional previa al ajuste lineal.

El modelo ExtraTrees se basa en árboles extremadamente aleatorizados, que incrementan la aleatoriedad tanto en la selección de variables como en los puntos de corte, pudiendo reducir varianza y mejorar generalización en problemas tabulares ([Geurts et al., 2006](#)). Random Forest se incluyó como referencia de ensamblado basado en árboles de decisión entrenados sobre subconjuntos y agregados por promediado ([Breiman, 2001](#)).

La evaluación se realizó mediante partición entrenamiento-test y validación cruzada en el conjunto de entrenamiento. Para comparar de forma justa los bloques de variables, se mantuvieron la misma partición, las mismas salidas y las mismas métricas entre modelos. Las métricas principales fueron el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación R^2 . Estas métricas se calcularon de forma global y por proteína.

3.9. Comparación de bloques de variables

La comparación se organizó por bloques de entrada:

- `RDKit_solo`: únicamente descriptores moleculares RDKit.
- `RDKit_membrana_seleccionada`: descriptores RDKit más variables de membrana con señal fisicoquímica clara.
- `Membrana_solo`: únicamente variables COSMOtherm/COSMOmic.
- `RDKit_membrana_filtrada_auto`: combinación RDKit+membrana con filtrado automático de variables no informativas.

Esta organización permitió responder a una pregunta metodológica central: si las variables de membrana mejoraban la predicción de afinidad proteína-ligando o si actuaban principalmente como caracterización fisicoquímica complementaria. Dado el tamaño reducido del dataset, la interpretación se basó en el conjunto de métricas y no en una única cifra aislada.

3.10. Docking nanopartícula-proteína

Los resultados de docking nanopartícula-proteína se obtuvieron mediante AutoDock 4.2.6, empleando archivos de salida DLG generados por el programa y herramientas de preparación

compatibles con AutoDockTools/MGLTools (Morris et al., 2009; Sanner, 2011). Para cada archivo se extrajeron las energías detectadas y se generó una tabla con nanopartícula, proteína, energía mínima y número de energías identificadas. Estos cálculos se trataron como un análisis independiente del modelo ligando-proteína, considerándolos como capa contextual para construir rankings exploratorios, pero no como variable del modelo principal.

3.11. Análisis estructural de complejos representativos

Como complemento al docking ligando-proteína, se seleccionaron complejos representativos para su análisis estructural mediante PLIP. La selección se realizó tomando los tres ligandos con mejor energía de docking para cada una de las cuatro proteínas, generando un conjunto de 12 complejos proteína-ligando.

Para cada complejo seleccionado se preparó una estructura proteína-ligando en formato PDB compatible con PLIP. Posteriormente, se analizaron las interacciones no covalentes detectadas por el programa, principalmente contactos hidrofóbicos y puentes de hidrógeno. Este análisis se planteó como una descripción cualitativa de las poses mejor puntuadas, no como una cuantificación definitiva de una única conformación.

3.12. Índice Contextual Nano-Bio

Para integrar de forma exploratoria la información de docking ligando-proteína y nanopartícula-proteína se definió el Índice Contextual Nano-Bio (ICNB). Este índice no representa una energía física absoluta, sino una métrica de priorización comparativa que combina dos contribuciones normalizadas: la afinidad ligando-proteína y la interacción nanopartícula-proteína.

En primer lugar, las energías de docking ligando-proteína y nanopartícula-proteína se transformaron en puntuaciones normalizadas dentro de cada proteína. Dado que valores más negativos indican interacciones más favorables, se invirtió el signo de las puntuaciones normalizadas:

$$S_{i,p}^{\text{LP}} = -z_p(E_{i,p}^{\text{LP}}), \quad S_{n,p}^{\text{NP}} = -z_p(E_{n,p}^{\text{NP}})$$

donde LP corresponde a la contribución ligando-proteína, NP a la contribución nanopartícula-proteína, i al ligando, n a la nanopartícula y p a la proteína considerada.

El ICNB se obtuvo promediando ambas puntuaciones normalizadas y reescalando el resultado final a un intervalo 0–100. Valores altos de ICNB indican combinaciones ligando-nanopartícula-proteína más favorables dentro del conjunto analizado.

3.13. Generación de tablas, figuras y aplicación de visualización

Los resultados finales se organizaron mediante scripts de R para generar tablas en CSV y figuras en PNG. Las figuras incluyeron comparación de modelos por RMSE, rendimiento por proteína, gráficos real-predicho, correlaciones de variables, mapas de calor nanopartícula-proteína, ranking contextual y relaciones entre variables de membrana.

Además, se desarrolló una aplicación Streamlit para revisar de forma interactiva los CSV generados. La aplicación permite explorar modelos, métricas, predicciones, variables de membrana, docking nanopartícula-proteína y ranking contextual. Esta aplicación se considera una herramienta auxiliar de visualización, mientras que los análisis reproducibles quedan definidos por los scripts y los archivos CSV generados.

Resultados

4.1. Comparación de modelos predictivos

La comparación de modelos permitió evaluar el efecto de distintos bloques de variables sobre la predicción de afinidades de docking ligando-proteína. En este apartado se analizan únicamente las energías obtenidas para los ligandos frente a las cuatro proteínas plasmáticas; los resultados de docking nanopartícula-proteína se tratan más adelante como una capa contextual independiente. La Figura 4.1 muestra el ranking de modelos ordenado por RMSE en el conjunto de test. El mejor resultado global correspondió a ExtraTrees utilizando únicamente descriptores RDKit, con un RMSE de test de 0,4117, un MAE de 0,3188 y un R^2 medio de 0,8840. El modelo equivalente con descriptores RDKit y variables de membrana seleccionadas obtuvo un RMSE prácticamente idéntico, de 0,4117, aunque con un MAE ligeramente superior.




Figura 4.1: Comparación de modelos por RMSE en test.

La comparación por bloques de variables se resume en la Figura 4.2. Este análisis permite valorar de forma directa si la inclusión de variables de membrana mejora el modelo frente al uso exclusivo de descriptores RDKit. La diferencia entre `RDKit_solo` y `RDKit+membrana` fue mínima, mientras que el bloque `Membrana_solo` presentó un error claramente superior. Por tanto, las variables de membrana contienen información fisicoquímica útil, pero no suficiente para sustituir a los descriptores moleculares estructurales en la predicción de afinidades proteína-ligando.




Figura 4.2: Mejor RMSE por bloque de variables.

4.2. Rendimiento por proteína

El rendimiento por proteína del mejor modelo se evaluó mediante RMSE y R^2 . La Figura 4.3 muestra la variabilidad de rendimiento entre las cuatro proteínas. El error no fue homogéneo en todas las salidas: y_{2hav} presentó el menor RMSE, mientras que y_{1hzh} mostró el mayor error relativo. Aun así, los valores de R^2 se mantuvieron elevados para las cuatro proteínas, lo que indica que el modelo capturó una parte importante de la variabilidad de las afinidades de docking.




Figura 4.3: Rendimiento por proteína del mejor modelo: RMSE y R^2 .

4.3. Predicción real frente a predicción estimada

La concordancia entre valores reales de docking ligando-proteína y valores predichos se inspeccionó mediante diagramas de dispersión proteína a proteína. La Figura 4.4 reúne las cuatro salidas del modelo, correspondientes a los ligandos frente a las proteínas 1ao6, 1hzh, 2hav y 3ghg. En general, los puntos se distribuyen próximos a la diagonal, especialmente para y_{2hav} y y_{1ao6} . Las desviaciones observadas en algunos ligandos indican que el modelo mantiene limitaciones para casos concretos, previsiblemente asociados a moléculas con tamaños, polaridades o geometrías menos representadas en el conjunto de entrenamiento.





1ao6**1hzh****2hav****3ghg**

Figura 4.4: Comparación real vs predicho para las cuatro proteínas.

4.4. Variables relevantes

La Figura 4.5 muestra las variables más correlacionadas con las afinidades de docking ligando-proteína. Este análisis se utilizó como exploración descriptiva, no como criterio único de selección de variables. Las variables más correlacionadas fueron principalmente descriptores RDKit relacionados con tamaño molecular, número de átomos pesados, peso molecular, superficie y forma molecular. También aparecieron variables de membrana, especialmente relacionadas con difusión y entropía, lo que indica que estas propiedades contienen señal asociada a características fisicoquímicas generales de los ligandos.




Figura 4.5: Variables más correlacionadas con las afinidades.

4.5. Docking nanopartícula-proteína

Los resultados nanopartícula-proteína se resumen en la Figura 4.6. Las energías más negativas indican interacciones más favorables dentro del protocolo de docking utilizado. El análisis se completó para tres proteínas plasmáticas, ya que la proteína 3ghg no se incluyó en esta capa final por limitaciones técnicas asociadas al tamaño y a la preparación del sistema. El modelo $(\text{ZnO})_{12}$ presentó energías de interacción mucho más negativas que Ag_{13} y Au_{13} frente a las tres proteínas evaluadas, especialmente frente a 2hav.




Figura 4.6: Mapa de calor de docking nanopartícula-proteína.

Tabla 4.1: Top 10 combinaciones según el Índice Contextual Nano-Bio.

Ligando	NP	Prot	ICNB global	ICNB proteína	E_{LP} (kcal/mol)	E_{NP} (kcal/mol)
Ácido fólico	(ZnO) ₁₂	2hav	100.00	100.00	-10.09	-8.44
Ácido fólico	(ZnO) ₁₂	1ao6	99.83	100.00	-9.21	-7.76
Ácido fólico	(ZnO) ₁₂	1hzh	97.78	100.00	-8.75	-7.38
Doxorrubicina proxy	(ZnO) ₁₂	1ao6	91.22	91.36	-8.36	-7.76
Curcumina	(ZnO) ₁₂	2hav	89.46	89.44	-8.93	-8.44
Doxorrubicina proxy	(ZnO) ₁₂	1hzh	89.24	91.27	-7.94	-7.38
Doxorrubicina proxy	(ZnO) ₁₂	2hav	85.59	85.56	-8.50	-8.44
Curcumina	(ZnO) ₁₂	1ao6	84.96	85.08	-7.74	-7.76
Ácido tánico	(ZnO) ₁₂	1hzh	84.86	86.79	-7.52	-7.38
Ácido tánico	(ZnO) ₁₂	2hav	84.00	83.97	-8.33	-8.44

4.6. Índice Contextual Nano-Bio

El ranking contextual se reformuló como Índice Contextual Nano-Bio (ICNB), expresado en una escala 0–100. Este índice permitió priorizar combinaciones ligando-nanopartícula-proteína integrando, de forma normalizada, la afinidad ligando-proteína y la interacción nanopartícula-proteína.

Como se observa en la Tabla 4.1, las combinaciones con mayor ICNB estuvieron dominadas por (ZnO)₁₂, especialmente en combinación con ácido fólico, que fue el ligando mejor posicionado en las tres proteínas evaluadas. La preferencia por (ZnO)₁₂ está claramente relacionada con sus energías de interacción nanopartícula-proteína, que variaron entre -8,44 y -7,38 kcal/mol. En comparación, Ag₁₃ presentó valores entre -2,24 y -2,13 kcal/mol, y Au₁₃ entre -2,34 y -2,12 kcal/mol, cantidades claramente menos favorables dentro del protocolo de docking empleado.

4.7. Análisis complementarios: PLIP y variables de membrana

Como apoyo estructural al ranking ICNB, se realizó un análisis PLIP cualitativo preliminar de los complejos proteína-ligando mejor posicionados. El ácido fólico mostró el patrón de interacción más completo, combinando contactos hidrofóbicos y puentes de hidrógeno en varias proteínas. El detalle completo se recoge en el Anexo G.

Las variables de membrana se analizaron como capa fisicoquímica complementaria. Aunque aportaron información sobre partición, permeabilidad y comportamiento en una bicapa modelo de DMPC, no mejoraron claramente el rendimiento predictivo frente al bloque RDKit. Su descripción detallada se recoge en el Anexo C.

4.8. Aplicación de visualización y predicción

También se desarrolló una aplicación Streamlit para facilitar la exploración de los resultados, que permite revisar la comparación de modelos, las métricas por proteína, las predicciones del conjunto de test, las variables de membrana, los resultados nanopartícula-proteína y el ICNB.

Como ampliación del flujo, la aplicación incorporó una pestaña de predicción de nuevos ligandos a partir de SMILES. En esta sección, el usuario puede introducir una molécula, calcular sus descriptores RDKit y aplicar el modelo ExtraTrees final para estimar su perfil de afinidad frente a las cuatro proteínas plasmáticas.

Discusión

Los resultados obtenidos muestran que el flujo computacional desarrollado permite estudiar de forma integrada la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas. Una decisión metodológica importante fue mantener separadas las distintas capas de información: docking ligando-proteína, variables de membrana, modelos predictivos, docking nanopartícula-proteína, análisis PLIP y aplicación de visualización. Esta separación permitió evitar la mezcla directa de magnitudes procedentes de unidades de análisis distintas. En particular, el modelo principal se construyó con una fila por ligando y cuatro salidas de afinidad ligando-proteína, mientras que los resultados nanopartícula-proteína se analizaron como una capa contextual independiente.

El mejor rendimiento predictivo se obtuvo con ExtraTrees utilizando únicamente descriptores RDKit. Este resultado indica que las propiedades estructurales y fisicoquímicas de los ligandos contienen una señal suficiente para reproducir gran parte de la variabilidad observada en las puntuaciones de docking. Variables relacionadas con tamaño molecular, superficie, polaridad, forma y flexibilidad son especialmente relevantes en este contexto, ya que condicionan la capacidad del ligando para establecer contactos con la proteína. No obstante, debe recordarse que el modelo predice resultados computacionales de docking, no afinidades experimentales absolutas. Por tanto, sus predicciones deben interpretarse como tendencias comparativas dentro del protocolo empleado.

La comparación entre modelos también mostró que PLSRegression presentó un comportamiento competitivo, especialmente en validación cruzada. Esto sugiere que parte de la relación entre estructura molecular y afinidad puede explicarse mediante combinaciones latentes de descriptores correlacionados. Sin embargo, ExtraTrees fue seleccionado como modelo final por su menor error en test y por su capacidad para capturar relaciones no lineales en datos tabulares.

La incorporación de variables de membrana COSMOtherm/COSMOmic no produjo una mejora clara frente al uso exclusivo de descriptores RDKit. Esta observación es razonable, ya que dichas variables describen el comportamiento de los ligandos en una bicapa modelo de DMPC, mientras que el modelo predictivo intenta estimar interacciones con proteínas plasmáticas. Por tanto, su valor principal no fue mejorar la predicción de afinidad, sino aportar una caracterización fisicoquímica complementaria. En un contexto biomédico, esta información sigue siendo relevante, ya que un agente de recubrimiento no solo debe interactuar con proteínas, sino también presentar un comportamiento compatible con entornos lipídicos y membranas celulares.

El rendimiento por proteína no fue completamente homogéneo. Algunas salidas fueron predichas con menor error que otras, lo que puede estar relacionado con diferencias en la accesibilidad de las regiones de unión, la distribución de afinidades de cada proteína o la diversidad química de los ligandos estudiados. Las gráficas de valores reales frente a predichos mostraron una concordancia general razonable, aunque con desviaciones en algunos compuestos. Estas desviaciones son esperables en un dataset de tamaño limitado y refuerzan la necesidad de interpretar el modelo como una herramienta de priorización, no como una sustitución del docking explícito ni de la validación experimental.

El análisis nanopartícula-proteína mostró diferencias claras entre los modelos inorgánicos evaluados. El modelo de óxido de zinc, representado como $(\text{ZnO})_{12}$, presentó energías más favorables que los modelos $(\text{Ag})_{13}$ y $(\text{Au})_{13}$ frente a las proteínas analizadas. Esto explica su

peso dominante en el Índice Contextual Nano-Bio. Sin embargo, esta parte debe interpretarse con cautela, ya que las nanopartículas se representaron mediante modelos simplificados.

El ICNB permitió integrar de forma comparativa la afinidad ligando-proteína y la interacción nanopartícula-proteína sin interpretar la combinación como una energía física absoluta. Su utilidad principal es ordenar candidatos dentro del conjunto estudiado, combinando dos contribuciones normalizadas en una escala común. En este ranking, el ácido fólico destacó como el ligando mejor posicionado de forma consistente, especialmente en combinación con (ZnO)₁₂. Este resultado no debe entenderse como una prueba definitiva de mayor afinidad experimental, sino como una señal computacional que permite seleccionar combinaciones prometedoras para estudios posteriores.

El análisis PLIP aportó una interpretación estructural complementaria al ranking. Mientras que el docking proporciona una puntuación de afinidad, PLIP permite identificar los tipos de contactos implicados en las poses mejor puntuadas. En los complejos analizados predominaron los contactos hidrofóbicos, aunque el ácido fólico mostró un patrón más completo al combinar contactos hidrofóbicos y puentes de hidrógeno en varias proteínas. Este comportamiento refuerza su posición destacada en el ICNB, ya que su resultado no parece depender únicamente de una puntuación favorable de docking, sino también de interacciones estructurales identificables. Aun así, el análisis PLIP debe considerarse exploratorio. Los complejos utilizados proceden de salidas de docking y pueden contener varias poses de Vina en un mismo archivo estructural.

La aplicación Streamlit desarrollada permitió reunir los resultados principales del flujo en una herramienta de consulta y predicción. La pestaña de predicción desde SMILES amplía su utilidad, ya que permite calcular descriptores RDKit de una nueva molécula y estimar su perfil de afinidad frente a las cuatro proteínas plasmáticas mediante el modelo ExtraTrees final. Sin embargo, estas predicciones deben interpretarse dentro del dominio químico del dataset utilizado. Moléculas muy alejadas de los ligandos estudiados en tamaño, carga, funcionalidad o geometría podrían quedar fuera del rango de aplicabilidad del modelo.

La principal limitación del trabajo es el tamaño del dataset. Aunque permitió entrenar modelos con rendimiento razonable, sigue siendo reducido para aprendizaje automático y limita la generalización a moléculas alejadas del dominio químico estudiado. Además, las afinidades utilizadas proceden de docking molecular, por lo que representan puntuaciones computacionales aproximadas y no medidas experimentales. La ausencia de validación experimental impide confirmar directamente las tendencias observadas.

Otra limitación importante es que no se dispone todavía del docking completo nanopartícula-ligando-proteína para todas las combinaciones. Por este motivo, el ICNB debe entenderse como una métrica contextual y exploratoria, no como una energía real de complejos nano-bio completos. Para avanzar en esta línea sería necesario preparar sistemas completos que incluyan simultáneamente el núcleo inorgánico, el agente de recubrimiento y la proteína plasmática, además de validar las tendencias mediante datos experimentales de adsorción proteica, formación de corona, estabilidad coloidal o interacción proteína-nanopartícula.

A pesar de estas limitaciones, el flujo desarrollado es modular, trazable y ampliable. Los resultados muestran que los descriptores RDKit son el bloque más útil para predecir afinidades de docking ligando-proteína, que las variables de membrana aportan información complementaria, que el modelo (ZnO)₁₂ domina la capa nanopartícula-proteína y que el ICNB permite priorizar combinaciones de forma clara sin confundirlas con energías físicas absolutas.

Conclusiones

1. Se desarrolló un flujo computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas, integrando docking molecular, descriptores RDKit, variables de membrana COSMOtherm/COSMOmic, modelos de aprendizaje automático y análisis nanopartícula-proteína.
2. El mejor rendimiento se obtuvo con ExtraTrees utilizando únicamente descriptores RDKit, con un RMSE medio en test de 0,412 y un R^2 medio de 0,884.
3. La incorporación de variables de membrana no produjo una mejora clara del rendimiento predictivo frente al uso exclusivo de descriptores RDKit. No obstante, estas variables aportaron información fisicoquímica complementaria sobre partición, permeabilidad y comportamiento de los ligandos en una bicapa modelo de DMPC.
4. Los resultados nanopartícula-proteína mostraron que $(\text{ZnO})_{12}$ presentó energías de interacción más negativas que $(\text{Ag})_{13}$ y $(\text{Au})_{13}$ frente a las proteínas evaluadas. Por ello, $(\text{ZnO})_{12}$ tuvo un peso dominante en las combinaciones mejor posicionadas del análisis contextual.
5. El ácido fólico es el ligando con comportamiento más consistente dentro del análisis contextual, y $(\text{ZnO})_{12}$ es la nanopartícula que más favorece el índice en el conjunto estudiado.
6. El análisis estructural mediante PLIP aporta una interpretación estructural complementaria al docking y reforzó la relevancia del ácido fólico como ligando destacado.
7. La incorporación de una pestaña en la aplicación Streamlit basada en SMILES permitió calcular descriptores RDKit de nuevos ligandos y estimar su perfil de afinidad mediante el modelo ExtraTrees final.

Líneas futuras

Puesto que los resultados de este TFM deben considerarse como una primera aproximación, una continuación natural sería realizar el docking completo de los sistemas nanopartícula-ligando-proteína. En este trabajo el modelo principal se centró en la interacción ligando-proteína, mientras que el docking nanopartícula-proteína se trató como una capa contextual independiente. Esta decisión fue metodológicamente necesaria para no mezclar unidades de análisis distintas dentro del mismo modelo. Sin embargo, disponer de complejos completos permitiría evaluar de forma más realista el efecto combinado del núcleo inorgánico, el agente de recubrimiento y la proteína plasmática.

Otra línea de mejora sería ampliar el número de ligandos estudiados. El tamaño del dataset condiciona de forma importante la capacidad de generalización de los modelos de aprendizaje automático. Aunque los modelos evaluados mostraron un rendimiento aceptable, un conjunto de datos mayor permitiría entrenar algoritmos más robustos, reducir la dependencia de la partición entrenamiento-test y explorar con mayor seguridad relaciones no lineales entre estructura química y afinidad de docking. Esto también permitiría ampliar el conjunto de descriptores moleculares utilizados, como fingerprints moleculares, descriptores Mordred, descriptores cuánticos derivados de los cálculos de optimización y frecuencias, o variables relacionadas con las propiedades electrónicas de las nanoestructuras.

También sería conveniente profundizar en las variables de membrana. En el presente trabajo las propiedades COSMOtherm/COSMOmic se utilizaron como bloque complementario y no produjeron una mejora clara del rendimiento predictivo frente a los descriptores RDKit. Sin embargo, estas variables pueden ser relevantes para interpretar el comportamiento global de los recubrimientos en entornos biológicos, especialmente en procesos relacionados con permeabilidad, partición lipídica o interacción con membranas celulares.

Desde el punto de vista del modelado, un aumento del número de moléculas permitiría explorar métodos más complejos, como gradient boosting, modelos basados en kernels, redes neuronales o enfoques de aprendizaje profundo molecular. También sería posible plantear estrategias de validación externa, división por familias químicas y análisis de dominio de aplicabilidad.

Bibliografía

- Ban, Z. et al. (2020). Machine learning predicts the functional composition of the protein corona and the cellular recognition of nanoparticles. *Proceedings of the National Academy of Sciences*, 117(19):10492–10499.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45:5–32.
- Dridi, N., Jin, Z., Perng, W., et al. (2024). Probing protein corona formation around gold nanoparticles: Effects of surface coating. *ACS Nano*, 18(12).
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). Autodock vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Fatima, H., Jin, Z. Y., Shao, Z., Chen, X. J., et al. (2022). Recent advances in zno-based photosensitizers: Synthesis, modification, and applications in photodynamic cancer therapy. *Journal of Colloid and Interface Science*, 621:440–463.
- Findlay, M. R., Freitas, D. N., Mobed-Miremadi, M., and Wheeler, K. E. (2018). Machine learning provides predictive analysis into silver nanoparticle protein corona formation from physicochemical properties. *Environmental Science: Nano*, 5:64–71.
- Geurts, P., Ernst, D., and Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63:3–42.
- Grimme, S., Antony, J., Ehrlich, S., and Krieg, H. (2010). A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H-Pu. *The Journal of Chemical Physics*, 132(15):154104.
- Ingram, T. et al. (2013). Prediction of micelle/water and liposome/water partition coefficients based on molecular dynamics simulations, cosmo-rs, and cosmomic. *Langmuir*, 29(11):3527–3537.
- Jakobtorweihen, S., Ingram, T., and Smirnova, I. (2013). Combination of cosmomic and molecular dynamics simulations for the calculation of membrane-water partition coefficients. *Journal of Computational Chemistry*, 34(15):1332–1340.
- Klamt, A. (1995). Conductor-like screening model for real solvents: A new approach to the quantitative calculation of solvation phenomena. *Journal of Physical Chemistry*, 99(7):2224–2235.
- Klamt, A., Huniar, U., Spycher, S., and Keldenich, J. (2008). Cosmomic: A mechanistic approach to the calculation of membrane-water partition coefficients and internal distributions within membranes and micelles. *Journal of Physical Chemistry B*, 112(38):12148–12157.
- Monopoli, M. P., Åberg, C., Salvati, A., and Dawson, K. A. (2012). Biomolecular coronas provide the biological identity of nanosized materials. *Nature Nanotechnology*, 7(12):779–786.
- Monopoli, M. P., Pitek, A. S., Lynch, I., and Dawson, K. A. (2013). Formation and characterization of the nanoparticle-protein corona. *Methods in Molecular Biology*, 1025:137–155.

- Morris, G. M., Huey, R., Lindstrom, W., Sanner, M. F., Belew, R. K., Goodsell, D. S., and Olson, A. J. (2009). Autodock4 and autodocktools4: Automated docking with selective receptor flexibility. *Journal of Computational Chemistry*, 30(16):2785–2791.
- Neese, F. (2022). Software update: The orca program system–version 5.0. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, 12(5):e1606.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- RDKit Developers (2026). RDKit: Open-source cheminformatics software. Zenodo software release. Version 2026.03.3.
- Sanner, M. F. (2011). Mgltools. Molecular Graphics Laboratory, The Scripps Research Institute.
- Trott, O. and Olson, A. J. (2010). Autodock vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461.
- TURBOMOLE GmbH (2023). TURBOMOLE v7.8.1. A development of University of Karlsruhe and Forschungszentrum Karlsruhe GmbH. Available from <http://www.turbomole.com>.
- Walkey, C. D. and Chan, W. C. W. (2012). Understanding and controlling the interaction of nanomaterials with proteins in a physiological environment. *Chemical Society Reviews*, 41:2780–2799.
- Weigend, F. and Ahlrichs, R. (2005). Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7(18):3297–3305.
- Zahdeh, M. et al. (2025). Gold nanoparticles in biomedical applications: Synthesis, properties, functionalization, and clinical potential. *International Journal of Molecular Sciences*.