



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Trabajo de Fin de Máster

Máster universitario en Ingeniería Biomédica

**Modelización computacional de la interacción de
agentes de recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con proteínas
plasmáticas mediante acoplamiento molecular y
aprendizaje automático**

Presentado por Pablo Fuentes de Mateo

Universidad de Burgos

Tutores: Santiago Aparicio – Pedro A. Marcos



UNIVERSIDAD
DE BURGOS

Escuela Politécnica Superior

Grado en Ingeniería de la Salud

D. Santiago Aparicio, profesor/a del departamento de física y química D.
Pedro A. Marcos, profesor/a del departamento de física y química

Expone/n:

Que el/la alumno/a D. Pablo Fuentes de Mateo, con DNI 71566685T,
ha realizado el Trabajo final del Master en Ingeniería Biomédica titulado
*Modelización computacional de la interacción de agentes de recubrimiento de
nanopartículas metálicas (Au, Ag, ZnO) con proteínas plasmáticas mediante
acoplamiento molecular y aprendizaje automático.*

Y que dicho trabajo ha sido realizado por el/la alumno/a bajo la dirección
del/los que suscribe/n.

En Burgos, a 4 de julio de 2026

D. Santiago Aparicio

D. Pedro A. Marcos

Resumen

Este Trabajo de Fin de Máster desarrolla un flujo computacional para estudiar la interacción de agentes de recubrimiento de nanopartículas metálicas con proteínas plasmáticas mediante acoplamiento molecular y aprendizaje automático. Se integraron resultados de docking ligando-proteína frente a cuatro proteínas plasmáticas, descriptores moleculares RDKit 2D/3D, variables de membrana procedentes de cálculos COSMOtherm/COSMOmic y resultados de docking nanopartícula-proteína para sistemas de Au, Ag y ZnO. A partir de estos datos se entrenaron modelos de regresión multisalida para predecir afinidades de docking y se compararon distintos bloques de variables, incluyendo descriptores RDKit, propiedades de membrana y reducción dimensional mediante PCA.

El mejor rendimiento predictivo se obtuvo con un modelo Extra-Trees utilizando descriptores RDKit, mientras que la incorporación de variables de membrana no produjo una mejora clara del error de predicción. Los resultados nanopartícula-proteína se analizaron como una capa contextual independiente y se reformularon mediante el Índice Contextual Nano-Bio (ICNB), que permitió priorizar combinaciones ligando-nanopartícula-proteína. Las mejores combinaciones estuvieron dominadas por ZnO_12_0 y ácido fólico. Además, se realizó un análisis estructural preliminar mediante PLIP sobre complejos representativos, observándose contactos hidrofóbicos y puentes de hidrógeno en los sistemas mejor posicionados. Finalmente, se desarrolló una aplicación Streamlit para visualizar resultados y predecir afinidades de nuevos ligandos a partir de SMILES.

Descriptores

Nanopartículas metálicas, oro, plata, óxido de zinc, agentes de recubrimiento, docking molecular, proteínas plasmáticas, COSMOtherm, membrana, aprendizaje automático, regresión multisalida, ICNB, PLIP.

Abstract

This Master’s Thesis develops a computational workflow to study the interaction of nanoparticle coating agents with plasma proteins using molecular docking and machine learning. Ligand-protein docking results against four plasma proteins were integrated with RDKit 2D/3D molecular descriptors, COSMOtherm/COSMOmic-derived membrane variables and nanoparticle-protein docking results for Au, Ag and ZnO systems. Multi-output regression models were trained to predict docking affinities and different feature blocks were compared, including RDKit descriptors, membrane properties and PCA-based dimensionality reduction.

The best predictive performance was obtained with an ExtraTrees model using RDKit descriptors, whereas the inclusion of membrane variables did not clearly improve the prediction error. Nanoparticle-protein docking results were analysed as an independent contextual layer and reformulated through the Nano-Bio Contextual Index (NBCI), enabling the prioritisation of ligand-nanoparticle-protein combinations. The highest-ranked combinations were dominated by ZnO_12_0 and folic acid. In addition, a preliminary PLIP structural analysis was performed on representative complexes, revealing hydrophobic contacts and hydrogen bonds in the best-ranked systems. Finally, a Streamlit application was developed to visualise results and predict affinities for new ligands from SMILES.

Keywords

Metallic nanoparticles, gold nanoparticles, silver nanoparticles, zinc oxide nanoparticles, coating agents, molecular docking, plasma proteins, COSMOtherm, membrane, machine learning, multi-output regression, NBCI, PLIP.

Índice general

Índice general	iii
Índice de figuras	v
Introducción	1
Objetivos	3
Metodología	4
3.1. Diseño general del flujo computacional	4
3.2. Sistemas estudiados	4
3.3. Preparación y validación estructural de ligandos	4
3.4. Preparación de receptores y docking ligando-proteína	5
3.5. Cálculo de descriptores moleculares RDKit	5
3.6. Variables de membrana COSMOtherm/COSMOmic	6
3.7. Construcción del dataset final	6
3.8. Modelos de aprendizaje automático	7
3.9. Comparación de bloques de variables	7
3.10. Docking nanopartícula-proteína	8
3.11. Análisis estructural de complejos representativos	8
3.12. Índice Contextual Nano-Bio	9
3.13. Generación de tablas, figuras y aplicación de visualización	10
Resultados	11
4.1. Comparación de modelos predictivos	11
4.2. Rendimiento por proteína	12
4.3. Predicción real frente a predicción estimada	13
4.4. Variables relevantes	14
4.5. Docking nanopartícula-proteína	14
4.6. Índice Contextual Nano-Bio	15
4.7. Análisis PLIP de complejos representativos	16
4.8. Propiedades de membrana	18
4.9. Aplicación de visualización y predicción	18
Discusión	20
Conclusiones	24

Líneas futuras	25
Bibliografía	26

Índice de figuras

4.1. Comparación de modelos por RMSE en test.	11
4.2. Mejor RMSE por bloque de variables.	12
4.3. Rendimiento por proteína del mejor modelo: RMSE y R^2	12
4.4. Comparación real vs predicho para las cuatro proteínas.	13
4.5. Variables más correlacionadas con las afinidades.	14
4.6. Mapa de calor de docking nanopartícula-proteína.	15
4.7. Relación entre mem_logP y mem_logPerm.	18

Introducción

La nanomedicina constituye una de las áreas con mayor proyección dentro de la ingeniería biomédica, al permitir el diseño de sistemas con dimensiones comparables a estructuras biológicas fundamentales y con propiedades fisicoquímicas ajustables mediante cambios en tamaño, forma, composición y química superficial. Entre los nanomateriales más estudiados destacan las nanopartículas metálicas y metal-óxido, como las nanopartículas de oro, plata y óxido de zinc, debido a su interés en aplicaciones de diagnóstico, terapia, administración dirigida de fármacos, biosensado, imagen biomédica y terapias fototérmicas o fotodinámicas ([Zahdeh et al., 2025](#), [Fatima et al. \(2022\)](#)).

Sin embargo, la eficacia biomédica de una nanopartícula no depende únicamente de sus propiedades sintéticas iniciales. Al entrar en contacto con fluidos biológicos, como el plasma sanguíneo, la superficie del nanomaterial se recubre rápidamente de proteínas, lípidos y otras biomoléculas, formando la denominada corona biomolecular o corona proteica ([Monopoli et al., 2012](#)). Esta corona modifica la “identidad biológica” de la nanopartícula, de modo que las células y tejidos no interactúan con la superficie original diseñada en el laboratorio, sino con una interfaz híbrida formada por el nanomaterial, sus agentes de recubrimiento y las biomoléculas adsorbidas ([Monopoli et al., 2012](#), [Walkey and Chan \(2012\)](#)). Como consecuencia, la corona proteica puede alterar parámetros críticos como el tamaño hidrodinámico, la carga superficial, la estabilidad coloidal, la biodistribución, la captación celular, el aclaramiento por el sistema mononuclear fagocítico, la inmunogenicidad y la toxicidad ([Walkey and Chan, 2012](#), [Monopoli et al. \(2013\)](#)).

La composición de la corona proteica depende de múltiples factores, incluyendo las propiedades intrínsecas de la nanopartícula —tamaño, forma, composición, curvatura y carga superficial—, la naturaleza química de los agentes de recubrimiento y las condiciones del medio biológico, como concentración proteica, fuerza iónica, pH y tiempo de exposición ([Walkey and Chan, 2012](#), [Monopoli et al. \(2013\)](#)). En el caso de aplicaciones intravenosas, las proteínas plasmáticas desempeñan un papel especialmente relevante. La albúmina sérica humana, proteína más abundante del plasma, presenta múltiples sitios de unión para moléculas endógenas y exógenas, por lo que puede participar de forma importante en las primeras etapas de adsorción sobre nanomateriales. Otras proteínas, como fibrinógeno, transferrina e inmunoglobulinas, están asociadas a procesos de coagulación, transporte de hierro o reconocimiento inmunitario. Por ello, comprender cómo los recu-

brimientos superficiales de nanopartículas interactúan con estas proteínas resulta esencial para el diseño racional de nanomateriales más seguros y eficaces.

Los agentes de recubrimiento o capping agents constituyen un elemento clave, se emplean habitualmente para estabilizar nanopartículas, modular su solubilidad, controlar su carga superficial o introducir funciones de direccionamiento biológico. No obstante, estos mismos grupos químicos condicionan las interacciones iniciales con las proteínas plasmáticas y, por tanto, la composición final de la corona. Estudios recientes han mostrado que variaciones en la química superficial de nanopartículas de oro modifican de forma significativa la formación de corona proteica, lo que confirma la necesidad de analizar de forma sistemática la relación entre recubrimiento, afinidad proteica y respuesta biológica (Dridi et al., 2024). El estudio experimental de la corona proteica proporciona información directa y de gran valor, pero suele requerir técnicas costosas y laboriosas, como espectrometría de masas, electroforesis, dispersión dinámica de luz, microscopía electrónica, resonancia de plasmones superficiales o calorimetría. Además, la enorme diversidad de combinaciones posibles entre nanomateriales, recubrimientos, proteínas y condiciones biológicas dificulta una exploración puramente experimental. Por este motivo, los métodos computacionales se han consolidado como herramientas complementarias para estudiar interacciones nano-bio, priorizar candidatos y generar hipótesis mecanísticas antes de la validación experimental.

Dentro de estas aproximaciones, el acoplamiento o docking molecular permite estimar modos de unión y afinidades relativas entre ligandos y proteínas, identificando residuos implicados en interacciones de hidrógeno, contactos hidrofóbicos, interacciones electrostáticas o apilamiento aromático. La integración de docking molecular con descriptores fisicoquímicos y técnicas de aprendizaje automático ofrece una vía prometedora para modelizar de forma predictiva las interacciones entre recubrimientos de nanopartículas y proteínas plasmáticas. A partir de propiedades como peso molecular, polaridad, carga, LogP, área de superficie polar, número de donadores y aceptores de enlaces de hidrógeno, flexibilidad molecular y fingerprints estructurales, es posible entrenar modelos que relacionen la estructura química de los ligandos con su afinidad estimada por proteínas relevantes. Estudios recientes han demostrado que el aprendizaje automático puede contribuir a predecir la composición y abundancia relativa de proteínas en la corona a partir de propiedades de nanopartículas y condiciones experimentales (Findlay et al., 2018, Ban et al. (2020)).

Objetivos

El objetivo general de este Trabajo Fin de Máster es desarrollar y aplicar una metodología computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas humanas, combinando acoplamiento molecular, descriptores moleculares, variables de membrana y aprendizaje automático.

De forma específica, se plantean los siguientes objetivos:

1. Seleccionar y preparar una biblioteca de agentes de recubrimiento representativos de nanopartículas metálicas y metal-óxido.
2. Optimizar las estructuras moleculares de los ligandos y validar las geometrías mediante análisis de frecuencias vibracionales.
3. Preparar las estructuras de las proteínas plasmáticas diana y organizar los cálculos de docking ligando-proteína.
4. Construir una matriz de afinidades ligando-proteína para cuatro proteínas plasmáticas.
5. Calcular descriptores moleculares 2D/3D mediante RDKit y combinarlos con los resultados de docking.
6. Extraer variables de membrana procedentes de cálculos COSMOtherm/COSMOmic en DMPC y evaluar su utilidad como información complementaria.
7. Desarrollar modelos de regresión multisalida para predecir afinidades de docking frente a las proteínas estudiadas.
8. Comparar bloques de variables RDKit, membrana y combinaciones de ambos, incluyendo modelos lineales, PLS, métodos de árboles y reducción dimensional mediante PCA.
9. Analizar los resultados de docking nanopartícula-proteína como una capa contextual independiente.
10. Generar un ranking exploratorio de combinaciones ligando-nanopartícula-proteína mediante puntuaciones normalizadas.
11. Automatizar la generación de tablas, figuras y una aplicación de visualización para facilitar la trazabilidad y reproducibilidad del flujo de trabajo.

Metodología

3.1. Diseño general del flujo computacional

El trabajo se estructuró como un flujo computacional reproducible basado en archivos CSV, scripts de Python/R y una plantilla Quarto para la generación de memoria y anexos. La unidad principal del modelo predictivo fue el ligando, entendido como agente de recubrimiento o molécula funcional asociable a nanopartículas. Para cada ligando se integraron descriptores moleculares, variables de membrana y cuatro valores de afinidad de docking ligando-proteína.

El flujo se dividió en seis bloques: preparación y validación estructural de ligandos, docking ligando-proteína, cálculo de descriptores RDKit, extracción de variables de membrana, entrenamiento de modelos de aprendizaje automático y análisis contextual de docking nanopartícula-proteína. Esta separación evitó mezclar directamente entidades distintas dentro de un mismo modelo: el modelo principal trabaja con filas de ligando, mientras que la información nanopartícula-proteína se analiza como una capa independiente.

3.2. Sistemas estudiados

La biblioteca de trabajo incluyó agentes de recubrimiento y moléculas con interés biomédico, abarcando compuestos pequeños, grupos con afinidad por superficies metálicas, moléculas polares, moléculas aromáticas y algunos fármacos o aproximaciones estructurales de fármacos. Las proteínas plasmáticas se identificaron mediante sus códigos estructurales: 1ao6, 1hzh, 2hav y 3ghg. Los resultados de docking ligando-proteína se almacenaron como cuatro variables objetivo: y_1ao6, y_1hzh, y_2hav y y_3ghg.

Las nanopartículas se consideraron mediante modelos simplificados de oro, plata y óxido de zinc. Para el análisis nanopartícula-proteína se emplearon los sistemas Ag_13, Au_13 y ZnO_12_0. Estos resultados no se añadieron al dataset de ligandos como variables ordinarias, ya que representan interacciones nanopartícula-proteína y no propiedades intrínsecas del ligando.

3.3. Preparación y validación estructural de ligandos

Las estructuras moleculares de los ligandos fueron preparadas y optimizadas antes de su uso en el flujo de docking y cálculo de descriptores. La optimización geométrica se complementó con cálculos de frecuencias

vibracionales. La ausencia de frecuencias imaginarias se utilizó como criterio de validación de mínimo local, de forma que las frecuencias actuaron como control de estabilidad estructural y no como variables principales del modelo predictivo.

La optimización geométrica de los ligandos y el cálculo de frecuencias se realizaron mediante TURBOMOLE ([TURBOMOLE GmbH, 2023](#)), empleando el funcional híbrido B3LYP con corrección de dispersión DFT-D4 ([Grimme et al., 2010](#)) y la base def2-TZVP ([Weigend and Ahlrichs, 2005](#)). Estos cálculos generaron estructuras optimizadas compatibles con los pasos posteriores del flujo y, cuando fue necesario, archivos de tipo Molden para inspección estructural y conversión de formatos.

De forma complementaria, se iniciaron cálculos exploratorios de complejos nanopartícula-ligando mediante ORCA ([Neese, 2022](#)), empleando el mismo nivel teórico general. Estos cálculos se plantearon como paso previo a la preparación de sistemas nanopartícula-ligando-proteína para docking, pero no se integraron todavía como una capa completa dentro del modelo final.

3.4. Preparación de receptores y docking ligando-proteína

El acoplamiento molecular ligando-proteína se realizó con AutoDock Vina, empleando estructuras de proteínas preparadas en formato PDBQT y ligandos también convertidos a PDBQT. AutoDock Vina explora poses del ligando en la región de búsqueda definida y estima una afinidad de unión aproximada mediante su función de puntuación ([Trott and Olson, 2010](#)). La versión moderna de Vina permite automatizar cálculos en modo *batch* y facilita la integración en flujos de cribado mediante interfaces de scripting ([Eberhardt et al., 2021](#)).

Para cada combinación ligando-proteína se conservó la mejor afinidad calculada por docking. Los valores se almacenaron en una tabla final con una fila por ligando y una columna objetivo por proteína. Dado que las cuatro salidas son continuas y se predicen de forma simultánea, el problema de aprendizaje automático se formuló como una regresión multisalida.

3.5. Cálculo de descriptores moleculares RDKit

A partir de las estructuras optimizadas se calcularon descriptores moleculares con RDKit ([RDKit Developers, 2026](#)). El bloque RDKit incluyó variables de tamaño y composición, como `MolWt`, `ExactMolWt`, `NumHeavyAtoms`

y NumAtoms; variables de polaridad y capacidad de interacción, como TPSA, NumHDonors y NumHAcceptors; variables de lipofilia, como MolLogP; variables de flexibilidad, como NumRotatableBonds; y descriptores topológicos y geométricos, como Chi0n, Chi1n, Kappa1, Kappa2, LabuteASA, momentos principales de inercia, radio de giro y esfericidad.

Estos descriptores permitieron transformar cada ligando en un vector numérico comparable. El uso de variables interpretables facilita relacionar propiedades como tamaño, polaridad, hidrofobicidad o forma molecular con las afinidades calculadas por docking.

3.6. Variables de membrana COSMOtherm/COSMOmic

Las variables de membrana se extrajeron a partir de cálculos en una bicapa de dimiristoilfosfatidilcolina (DMPC) en agua a 37 °C. El fundamento teórico se basa en COSMO-RS, que utiliza densidades de carga de apantallamiento obtenidas a partir de cálculos cuánticos para predecir propiedades termodinámicas en fase líquida (Klamt, 1995). Para entornos anisótropos como micelas y biomembranas, COSMOmic permite describir perfiles dependientes de la profundidad en la membrana y calcular propiedades como partición membrana/agua y distribuciones internas (Klamt et al., 2008; Jakobtorweihen et al., 2013; Ingram et al., 2013).

Del archivo de permeabilidad se extrajeron variables globales y estadísticos resumen. Entre las variables globales se incluyeron mem_logP, correspondiente al logaritmo de partición micela/agua; mem_logP_kg_l, versión ajustada en unidades kg/L; y mem_logPerm, asociado a la permeabilidad de membrana. Además, se resumieron perfiles dependientes de la profundidad para energía libre, distribución, entropía media y difusión. Para cada perfil se calcularon estadísticos como media, mínimo, máximo, valor en la zona central de la membrana y, cuando procedía, profundidad asociada a máximos o mínimos.

Las variables de membrana se incorporaron como bloque complementario al dataset de ligandos. Su objetivo fue evaluar si la información de partición y permeabilidad aportaba mejora predictiva frente a los descriptores RDKit. Metodológicamente, se mantuvieron separadas para poder comparar modelos RDKit-solo, membrana-solo y RDKit+membrana.

3.7. Construcción del dataset final

El dataset final se construyó mediante la unión de tres fuentes: descriptores RDKit, variables de membrana y afinidades de docking ligando-proteína. La tabla principal mantuvo una fila por ligando. Las columnas objetivo fueron `y_1ao6`, `y_1hzh`, `y_2hav` y `y_3ghg`.

Antes del entrenamiento se sustituyeron valores infinitos por valores perdidos y se aplicó imputación por la mediana dentro del flujo de modelado. Las variables de varianza nula se eliminaron mediante un filtro de varianza. En los modelos lineales y en PCA se aplicó escalado estándar para evitar que variables con distinta magnitud dominaran el ajuste. En los modelos basados en árboles no fue necesario escalar las variables, aunque se mantuvo un flujo homogéneo de preprocesado para asegurar comparaciones reproducibles.

3.8. Modelos de aprendizaje automático

Se compararon distintos modelos de regresión multisalida usando scikit-learn ([Pedregosa et al., 2011](#)). Los modelos evaluados fueron Ridge, PLS-Regression, RandomForestRegressor, ExtraTreesRegressor y PCA seguido de Ridge. Ridge se incluyó como modelo lineal regularizado; PLSRegression como modelo útil en escenarios con variables correlacionadas y tamaño muestral reducido; Random Forest y ExtraTrees como métodos no lineales basados en ensamblados de árboles; y PCA_Ridge como estrategia de reducción dimensional previa al ajuste lineal.

El modelo ExtraTrees se basa en árboles extremadamente aleatorizados, que incrementan la aleatoriedad tanto en la selección de variables como en los puntos de corte, pudiendo reducir varianza y mejorar generalización en problemas tabulares ([Geurts et al., 2006](#)). Random Forest se incluyó como referencia de ensamblado basado en árboles de decisión entrenados sobre subconjuntos y agregados por promediado ([Breiman, 2001](#)).

La evaluación se realizó mediante partición entrenamiento-test y validación cruzada en el conjunto de entrenamiento. Para comparar de forma justa los bloques de variables, se mantuvieron la misma partición, las mismas salidas y las mismas métricas entre modelos. Las métricas principales fueron el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación R^2 . Estas métricas se calcularon de forma global y por proteína.

3.9. Comparación de bloques de variables

La comparación se organizó por bloques de entrada:

- `RDKit_solo`: únicamente descriptores moleculares RDKit.
- `RDKit_membrana_seleccionada`: descriptores RDKit más variables de membrana con señal fisicoquímica clara.
- `Membrana_solo`: únicamente variables COSMOtherm/COSMOmic.
- `RDKit_membrana_filtrada_auto`: combinación RDKit+membrana con filtrado automático de variables no informativas.

Esta organización permitió responder a una pregunta metodológica central: si las variables de membrana mejoraban la predicción de afinidad proteína-ligando o si actuaban principalmente como caracterización fisicoquímica complementaria. Dado el tamaño reducido del dataset, la interpretación se basó en el conjunto de métricas y no en una única cifra aislada.

3.10. Docking nanopartícula-proteína

Los resultados de docking nanopartícula-proteína se obtuvieron a partir de archivos DLG. Para cada archivo se extrajeron las energías detectadas y se generó una tabla con nanopartícula, proteína, energía mínima y número de energías identificadas. Estos cálculos se trataron como un análisis independiente del modelo ligando-proteína.

La razón es que una energía nanopartícula-proteína no varía por ligando, sino por combinación nanopartícula-proteína. Incluirla directamente como descriptor en una tabla donde cada fila representa un ligando generaría una mezcla de unidades de análisis. Por ello, se utilizó como capa contextual para construir rankings exploratorios, pero no como variable del modelo principal.

3.11. Análisis estructural de complejos representativos

Como ampliación interpretativa del análisis de docking, se seleccionaron los complejos ligando-proteína mejor posicionados para cada proteína y se prepararon estructuras proteína-ligando en formato PDB. La selección se realizó tomando los tres ligandos con afinidad de docking más favorable frente a cada proteína, generando un conjunto de 12 complejos representativos.

Los complejos seleccionados incluyeron principalmente ácido fólico, curcumina, el proxy de doxorrubicina/daunorrubicina aglicona y ácido tánico aproximado, que fueron los ligandos con mejores energías de docking en las proteínas estudiadas. Esta selección permitió definir un *case study* estructural centrado en los candidatos más relevantes del cribado ligando-proteína.

El objetivo de esta etapa fue preparar los complejos para un análisis posterior de interacciones no covalentes mediante herramientas como PLIP (*Protein-Ligand Interaction Profiler*), que permite identificar de forma automática puentes de hidrógeno, contactos hidrofóbicos, puentes salinos, interacciones aromáticas y otros contactos proteína-ligando. En el presente flujo, esta etapa se consideró una ampliación estructural del docking, orientada a validar químicamente las poses mejor puntuadas y a interpretar si las afinidades más favorables se deben a interacciones específicas o a efectos más generales como tamaño, polaridad o superficie molecular.

3.12. Índice Contextual Nano-Bio

Para integrar de forma exploratoria la información de docking ligando-proteína y nanopartícula-proteína se definió el Índice Contextual Nano-Bio (ICNB). Este índice no representa una energía física absoluta, sino una métrica de priorización comparativa que combina dos contribuciones normalizadas: la afinidad ligando-proteína y la interacción nanopartícula-proteína.

En primer lugar, las energías de docking ligando-proteína y nanopartícula-proteína se transformaron en puntuaciones normalizadas dentro de cada proteína. Dado que valores más negativos indican interacciones más favorables, se invirtió el signo de las puntuaciones normalizadas:

$$S_{i,p}^{LP} = -z_p(E_{i,p}^{LP})$$

$$S_{n,p}^{NP} = -z_p(E_{n,p}^{NP})$$

donde $(E^{\{LP\}\{i,p\}})$ representa la energía de docking del ligando (i) frente a la proteína (p), $(E^{\{NP\}\{n,p\}})$ la energía de docking de la nanopartícula (n) frente a la proteína (p), y (z_p) el z-score calculado dentro de cada proteína.

A continuación, se calculó una puntuación contextual media:

$$S_{i,n,p}^{contexto} = \frac{S_{i,p}^{LP} + S_{n,p}^{NP}}{2}$$

Finalmente, esta puntuación se reescaló a un intervalo 0–100 para facilitar su interpretación, obteniendo el ICNB. Valores altos de ICNB indican combinaciones ligando-nanopartícula-proteína más favorables dentro del

conjunto analizado. Esta formulación permitió integrar la contribución del ligando y de la nanopartícula sin mezclar directamente energías procedentes de unidades de análisis distintas.

3.13. Generación de tablas, figuras y aplicación de visualización

Los resultados finales se organizaron mediante scripts de R para generar tablas en CSV y figuras en PNG. Las figuras incluyeron comparación de modelos por RMSE, rendimiento por proteína, gráficos real-predicho, correlaciones de variables, mapas de calor nanopartícula-proteína, ranking contextual y relaciones entre variables de membrana.

Además, se desarrolló una aplicación Streamlit para revisar de forma interactiva los CSV generados. La aplicación permite explorar modelos, métricas, predicciones, variables de membrana, docking nanopartícula-proteína y ranking contextual. Esta aplicación se considera una herramienta auxiliar de visualización, mientras que los análisis reproducibles quedan definidos por los scripts y los archivos CSV generados.

Resultados

4.1. Comparación de modelos predictivos

La comparación de modelos permitió evaluar el efecto de distintos bloques de variables sobre la predicción de afinidades de docking. La Figura 4.1 muestra el ranking de modelos ordenado por RMSE en el conjunto de test. El mejor resultado global correspondió a ExtraTrees utilizando únicamente descriptores RDKit, con un RMSE de test de 0,4117, un MAE de 0,3188 y un R^2 medio de 0,8840. El modelo equivalente con descriptores RDKit y variables de membrana seleccionadas obtuvo un RMSE prácticamente idéntico, de 0,4117, aunque con un MAE ligeramente superior.




Figura 4.1: Comparación de modelos por RMSE en test.

La comparación por bloques de variables se resume en la Figura 4.2. Este análisis permite valorar de forma directa si la inclusión de variables de membrana mejora el modelo frente al uso exclusivo de descriptores RDKit. La diferencia entre RDKit_solo y RDKit+membrana fue mínima, mientras que el bloque Membrana_solo presentó un error claramente superior. Por tanto, las variables de membrana contienen información fisicoquímica útil, pero no suficiente para sustituir a los descriptores moleculares estructurales en la predicción de afinidades proteína-ligando.





Figura 4.2: Mejor RMSE por bloque de variables.

4.2. Rendimiento por proteína

El rendimiento por proteína del mejor modelo se evaluó mediante RMSE y R^2 . La Figura 4.3 muestra la variabilidad de rendimiento entre las cuatro proteínas. El error no fue homogéneo en todas las salidas: **y_2hav** presentó el menor RMSE, mientras que **y_1hzh** mostró el mayor error relativo. Aun así, los valores de R^2 se mantuvieron elevados para las cuatro proteínas, lo que indica que el modelo capturó una parte importante de la variabilidad de las afinidades de docking.



(a) RMSE por proteína.

(b) R^2 por proteína.

Figura 4.3: Rendimiento por proteína del mejor modelo: RMSE y R^2 .

4.3. Predicción real frente a predicción estimada

La concordancia entre valores reales de docking y valores predichos se inspeccionó mediante diagramas de dispersión proteína a proteína. La Figura 4.4 reúne las cuatro salidas en una única representación para facilitar la comparación visual. En general, los puntos se distribuyen próximos a la diagonal, especialmente para y_2hav y y_1ao6. Las desviaciones observadas en algunos ligandos indican que el modelo mantiene limitaciones para casos concretos, previsiblemente asociados a moléculas con tamaños, polaridades o geometrías menos representadas en el conjunto de entrenamiento.




Figura 4.4: Comparación real vs predicho para las cuatro proteínas.

4.4. Variables relevantes

La Figura 4.5 muestra las variables más correlacionadas con las afinidades de docking. Este análisis se utilizó como exploración descriptiva, no como criterio único de selección de variables. Las variables más correlacionadas fueron principalmente descriptores RDKit relacionados con tamaño molecular, número de átomos pesados, peso molecular, superficie y forma molecular. También aparecieron variables de membrana, especialmente relacionadas con difusión y entropía, lo que indica que estas propiedades contienen señal asociada a características fisicoquímicas generales de los ligandos.




Figura 4.5: Variables más correlacionadas con las afinidades.

4.5. Docking nanopartícula-proteína

Los resultados nanopartícula-proteína se resumen en la Figura 4.6. Las energías más negativas indican interacciones más favorables dentro del protocolo de docking utilizado. Zn0_12_0 presentó energías de interacción mucho más negativas que Ag_13 y Au_13 frente a las tres proteínas evaluadas, especialmente frente a 2hav. Esta diferencia sugiere que, dentro de los modelos simplificados considerados, la nanopartícula de óxido de zinc muestra una mayor tendencia a interaccionar con las proteínas plasmáticas analizadas.




Figura 4.6: Mapa de calor de docking nanopartícula-proteína.

4.6. Índice Contextual Nano-Bio

El ranking contextual se reformuló como Índice Contextual Nano-Bio (ICNB), expresado en una escala 0–100. Este índice permitió priorizar combinaciones ligando-nanopartícula-proteína integrando, de forma normalizada, la afinidad ligando-proteína y la interacción nanopartícula-proteína.

Los resultados mostraron una dominancia clara de la nanopartícula ZnO_12_0 en las combinaciones mejor puntuadas. Esto se debe a que ZnO_12_0 presentó energías nanopartícula-proteína mucho más negativas que Ag_13 y Au_13 frente a las tres proteínas evaluadas en el docking nanopartícula-proteína. Como consecuencia, las primeras posiciones del ICNB estuvieron ocupadas por combinaciones que incluyen ZnO_12_0.

La mejor combinación global fue Folic_acid–ZnO_12_0–2hav, con un ICNB global de 100. También alcanzaron valores máximos dentro de cada proteína las combinaciones Folic_acid–ZnO_12_0–1ao6 y Folic_acid–ZnO_12_0–1hzh. En conjunto, el ácido fólico apareció como el ligando mejor posicionado de forma consistente en las tres proteínas con datos nanopartícula-proteína.

Como se observa en la Tabla 4.1, las combinaciones con mayor ICNB estuvieron dominadas por ZnO_12_0, especialmente en combinación con ácido fólico.

Tabla 4.1: Top 10 combinaciones según el Índice Contextual Nano-Bio.

Ligando	NP	Prot	ICNB global	ICNB proteína	E LP	E NP
Ácido fólico	ZnO-12-0	2hav	100.00	100.00	-10.09	-8.44
Ácido fólico	ZnO-12-0	1ao6	99.83	100.00	-9.21	-7.76
Ácido fólico	ZnO-12-0	1hzh	97.78	100.00	-8.75	-7.38
Doxorrubicina proxy	ZnO-12-0	1ao6	91.22	91.36	-8.36	-7.76
Curcumina	ZnO-12-0	2hav	89.46	89.44	-8.93	-8.44
Doxorrubicina proxy	ZnO-12-0	1hzh	89.24	91.27	-7.94	-7.38
Doxorrubicina proxy	ZnO-12-0	2hav	85.59	85.56	-8.50	-8.44
Curcumina	ZnO-12-0	1ao6	84.96	85.08	-7.74	-7.76
Ácido tánico	ZnO-12-0	1hzh	84.86	86.79	-7.52	-7.38
Ácido tánico	ZnO-12-0	2hav	84.00	83.97	-8.33	-8.44

Debe remarcarse que el ICNB no es una energía de unión total ni una magnitud termodinámica. Su utilidad es comparativa: permite priorizar combinaciones que reúnen simultáneamente ligandos con buena afinidad frente a proteínas plasmáticas y nanopartículas con interacción favorable frente a esas mismas proteínas.

4.7. Análisis PLIP de complejos representativos

Como ampliación estructural del análisis de docking, se analizaron mediante PLIP los complejos proteína-ligando mejor posicionados. Se seleccionaron los tres ligandos con mejor energía de docking para cada una de las cuatro proteínas, generando un conjunto de 12 complejos representativos. Para evitar interferencias de otros ligandos presentes en algunos receptores, la interpretación se centró en la entrada **LIG** correspondiente al ligando de interés.

El análisis PLIP permitió identificar contactos no covalentes entre ligando y proteína, principalmente contactos hidrofóbicos y puentes de hidrógeno. En 11 de los 12 complejos se detectaron interacciones proteína-ligando. El único sistema sin contactos detectados para **LIG** fue **Tannic_acid_approx** frente a **1hzh**. En conjunto, los resultados muestran que las poses mejor puntuadas no dependen únicamente de la energía de docking, sino que presentan contactos estructurales identificables con residuos de las proteínas.

Para mantener una interpretación conservadora, la tabla resume los contactos hidrofóbicos y los puentes de hidrógeno, que fueron las categorías más robustas en los reportes. Las interacciones metálicas detectadas en algunos complejos con ácido fólico no se utilizaron para el recuento total,

Tabla 4.2: Resumen del análisis PLIP en complejos proteína-ligando representativos.

Proteína	Ligando	Hidrofóbicos	Puentes H	Total
1ao6	Curcumina	18	0	18
1ao6	Doxorrubicina proxy	18	0	18
1ao6	Ácido fólico	19	7	26
1hzh	Doxorrubicina proxy	12	0	12
1hzh	Ácido fólico	13	8	21
1hzh	Ácido tánico	0	0	0
2hav	Curcumina	13	0	13
2hav	Doxorrubicina proxy	10	0	10
2hav	Ácido fólico	18	4	22
3ghg	Curcumina	13	0	13
3ghg	Doxorrubicina proxy	10	0	10
3ghg	Ácido fólico	12	0	12

ya que pueden estar influenciadas por la preparación estructural y por la presencia de varias poses en el archivo de docking.

La Tabla 4.2 resume los contactos detectados por PLIP en los complejos representativos.

El ácido fólico fue el ligando que presentó el patrón de interacción más completo. En 1ao6 mostró 26 interacciones consideradas, incluyendo 19 contactos hidrofóbicos y 7 puentes de hidrógeno. En 1hzh presentó 21 interacciones, con 13 contactos hidrofóbicos y 8 puentes de hidrógeno, mientras que en 2hav presentó 22 interacciones, con 18 contactos hidrofóbicos y 4 puentes de hidrógeno. Este comportamiento es coherente con su posición destacada en el ICNB.

Los residuos con mayor número de contactos acumulados fueron LYS137, ARG186, LEU115 y LEU182 en 1ao6; GLN166, PHE83, GLU165 y LYS103 en 1hzh; LYS591, ARG590, LEU228 y LEU134 en 2hav; y MET78, ILE79, VAL132 y ALA101 en 3ghg. Estos residuos definen regiones de interacción recurrentes en las poses mejor puntuadas y aportan una interpretación estructural complementaria a la energía de docking.

Debe señalarse que este análisis PLIP se considera preliminar, ya que los complejos proceden de archivos de salida de docking y pueden contener varias poses de Vina en un mismo archivo estructural. Por ello, los recuentos

de interacciones se interpretan de forma cualitativa, como apoyo estructural al ranking de docking, y no como una cuantificación definitiva de contactos para una única pose.

4.8. Propiedades de membrana

Las variables de membrana se analizaron como información fisicoquímica complementaria. La Figura 4.7 muestra la relación entre partición y permeabilidad derivadas de COSMOtherm/COSMOmic. Se observó una relación positiva general entre `mem_logP` y `mem_logPerm`, aunque con dispersión considerable. Esto indica que la partición en el entorno lipídico contribuye a la permeabilidad estimada, pero no la determina de forma exclusiva. La información de membrana resultó útil para caracterizar el comportamiento de los ligandos en un entorno lipídico modelo, aunque no produjo una mejora clara del modelo predictivo de afinidad proteína-ligando.




Figura 4.7: Relación entre `mem_logP` y `mem_logPerm`.

4.9. Aplicación de visualización y predicción

Además de las tablas y figuras generadas automáticamente, se desarrolló una aplicación Streamlit para facilitar la exploración de los resultados. La aplicación permite revisar la comparación de modelos, las métricas por

proteína, las predicciones del conjunto de test, las variables de membrana, los resultados nanopartícula-proteína y el ICNB.

Como ampliación del flujo, la aplicación incorporó una pestaña de predicción de nuevos ligandos a partir de SMILES. En esta sección, el usuario puede introducir una molécula, calcular sus descriptores RDKit y aplicar el modelo ExtraTrees final para estimar su perfil de afinidad frente a las cuatro proteínas plasmáticas. Esta funcionalidad convierte la app en una herramienta de cribado preliminar, aunque sus predicciones deben interpretarse dentro del dominio químico del dataset de entrenamiento.

Discusión

Los resultados obtenidos muestran que el flujo computacional desarrollado permite integrar de forma reproducible docking molecular, descriptores moleculares, variables de membrana, aprendizaje automático, docking nanopartícula-proteína, análisis PLIP y una aplicación interactiva de visualización y predicción. Una decisión metodológica importante fue mantener separadas las distintas capas de información. El modelo principal se construyó con una fila por ligando y cuatro salidas correspondientes a las afinidades ligando-proteína, mientras que los resultados nanopartícula-proteína se analizaron como una capa contextual independiente. Esta separación evita mezclar directamente magnitudes que proceden de entidades distintas y permite interpretar cada resultado dentro de su nivel de aproximación.

El mejor rendimiento predictivo se obtuvo con ExtraTrees utilizando únicamente descriptores RDKit. Este resultado es coherente con la naturaleza del problema, ya que la afinidad de docking ligando-proteína depende en gran medida de propiedades como tamaño, polaridad, superficie molecular, forma, flexibilidad y capacidad de establecer interacciones no covalentes. El buen rendimiento del modelo indica que los descriptores moleculares calculados contienen información suficiente para reproducir gran parte de la variabilidad observada en las afinidades de docking. No obstante, debe recordarse que el modelo predice la salida del protocolo de docking, no una afinidad experimental real. Por tanto, los valores deben interpretarse como tendencias comparativas dentro del flujo computacional utilizado.

PLSRegression también presentó un rendimiento competitivo, especialmente en validación cruzada. Esto sugiere que parte de la señal predictiva puede explicarse mediante combinaciones latentes de descriptores correlacionados. Sin embargo, ExtraTrees fue seleccionado como modelo final porque obtuvo el menor error en test. Esta comparación permite concluir que el problema presenta una señal química aprovechable, pero que las relaciones entre estructura molecular y afinidad no son estrictamente lineales.

La incorporación de variables de membrana COSMOtherm/COSMOmic no produjo una mejora clara del rendimiento predictivo frente al uso exclusivo de descriptores RDKit. El modelo con RDKit y membrana obtuvo un error muy similar al modelo `RDKit_solo`, mientras que el bloque `Membrana_solo` presentó un rendimiento inferior. Esto indica que las variables de membrana aportan información fisicoquímica real, pero no son las más directamente relacionadas con la afinidad ligando-proteína calculada por docking. Esta interpretación es razonable, ya que las variables de membrana describen

partición, permeabilidad, distribución y difusión en una bicapa modelo de DMPC, mientras que el modelo predictivo intenta estimar interacciones con proteínas plasmáticas.

Aun así, las variables de membrana no deben considerarse irrelevantes. En un contexto biomédico, un agente de recubrimiento no solo debe presentar determinada afinidad frente a proteínas plasmáticas, sino también un comportamiento compatible con entornos lipídicos y membranas celulares. Por ello, en este trabajo las variables de membrana se interpretan como una capa complementaria de caracterización fisicoquímica. Su valor principal no fue mejorar claramente el modelo de afinidad, sino aportar información adicional sobre el comportamiento global de los ligandos en un entorno biológico simplificado.

El análisis de variables relevantes mostró que muchas de las variables más relacionadas con las afinidades pertenecen al bloque RDKit o a descriptores geométricos. Esto indica que, en el conjunto estudiado, propiedades como tamaño molecular, número de átomos pesados, superficie, forma y polaridad tienen un papel importante en la puntuación de docking. Esta tendencia es habitual, ya que moléculas más grandes o con mayor superficie pueden establecer más contactos con la proteína. Sin embargo, también supone una limitación, porque una mejor energía de docking no implica necesariamente mayor especificidad ni mejor comportamiento biológico.

El rendimiento no fue idéntico en todas las proteínas. Algunas salidas fueron predichas con menor error que otras, lo que puede deberse a diferencias en la forma y accesibilidad de las regiones de unión, a la distribución de afinidades de cada proteína o a la variabilidad química de los ligandos. Las gráficas real-predicho muestran una concordancia general razonable, aunque con desviaciones en algunos compuestos. Estas desviaciones son esperables en un dataset de tamaño moderado y con moléculas químicamente diversas.

Los resultados de docking nanopartícula-proteína mostraron que ZnO_12_0 presentó energías más negativas que Ag_13 y Au_13 frente a las proteínas evaluadas. Esto hizo que ZnO_12_0 tuviera un peso dominante en el análisis contextual. Sin embargo, esta conclusión debe interpretarse con cautela, ya que las nanopartículas se representaron mediante modelos simplificados y el docking no reproduce completamente fenómenos como hidratación, carga superficial real, agregación, recubrimiento dinámico o formación experimental de corona proteica.

La reformulación del ranking contextual como Índice Contextual Nano-Bio permitió presentar esta parte del trabajo de forma más clara. El ICNB integra la afinidad ligando-proteína y la interacción nanopartícula-proteína

mediante puntuaciones normalizadas en una escala 0-100. Su utilidad es comparativa: permite priorizar combinaciones ligando-nanopartícula-proteína sin interpretar la suma de energías como una magnitud física absoluta. Los resultados mostraron que las primeras posiciones estuvieron dominadas por combinaciones **Folic_acid-ZnO_12_0**, especialmente frente a **2hav**, **1ao6** y **1hzh**. Esto se debe a la combinación de dos factores: el buen comportamiento del ácido fólico como ligando y la fuerte contribución de **ZnO_12_0** en el docking nanopartícula-proteína.

El análisis PLIP añadió una capa estructural al estudio de los complejos mejor posicionados. Mientras que el docking proporciona una puntuación de afinidad, PLIP permite identificar los tipos de contactos que estabilizan las poses, como contactos hidrofóbicos y puentes de hidrógeno. En los complejos analizados predominaron los contactos hidrofóbicos, aunque el ácido fólico mostró un patrón más completo, combinando contactos hidrofóbicos con varios puentes de hidrógeno frente a **1ao6**, **1hzh** y **2hav**. Este resultado refuerza su papel como ligando destacado, ya que su buena posición en el ranking no parece depender únicamente del tamaño molecular, sino también de interacciones más específicas.

No obstante, el análisis PLIP debe considerarse preliminar. Los reportes indican tamaños de ligando superiores a los esperados para algunas moléculas, lo que sugiere que en ciertos archivos podrían haberse incluido varias poses de Vina dentro del mismo complejo estructural. Por ello, los contactos detectados se interpretan de forma cualitativa, como apoyo estructural al docking, y no como una cuantificación definitiva de una única pose. Una mejora inmediata sería repetir PLIP extrayendo exclusivamente la primera pose de docking de cada complejo.

La aplicación Streamlit desarrollada inicialmente como herramienta de visualización se amplió con una pestaña de predicción desde SMILES. Esta función permite introducir una nueva molécula, calcular sus descriptores RDKit y estimar su perfil de afinidad frente a las cuatro proteínas plasmáticas mediante el modelo ExtraTrees final. Esto transforma la aplicación en una herramienta de cribado preliminar de agentes de recubrimiento. Sin embargo, sus predicciones deben interpretarse dentro del dominio químico del dataset utilizado. Moléculas muy diferentes en tamaño, carga, funcionalidad o geometría podrían quedar fuera del rango de aplicabilidad del modelo.

La principal limitación del trabajo es el tamaño del dataset. Aunque permitió entrenar modelos con rendimiento razonable, sigue siendo reducido para aprendizaje automático, lo que limita la generalización y obliga a interpretar con cautela diferencias pequeñas entre modelos. Otra limita-

ción es que las afinidades utilizadas proceden de docking molecular, por lo que representan puntuaciones computacionales aproximadas y no medidas experimentales. Además, no se dispone todavía de docking completo nanopartícula-ligando-proteína para todas las combinaciones, de modo que el ICNB debe entenderse como una métrica exploratoria y no como una energía real de complejos nano-bio completos.

Finalmente, el trabajo carece de validación experimental. Para confirmar las tendencias observadas sería necesario compararlas con datos de adsorción proteica, formación de corona, estabilidad coloidal, potencial zeta, DLS, espectrometría de masas o ensayos de interacción proteína-nanopartícula. A pesar de estas limitaciones, el flujo desarrollado es modular, trazable y ampliable. Los resultados muestran que los descriptores RDKit explican gran parte de la afinidad de docking, que las variables de membrana aportan caracterización complementaria, que ZnO_12_0 domina el análisis nanopartícula-proteína y que el ICNB permite priorizar combinaciones de forma clara sin confundirlas con energías físicas absolutas.

Conclusiones

1. Se desarrolló un flujo computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas, integrando docking molecular, descriptores RDKit, variables de membrana COSMOtherm/COSMOmic, modelos de aprendizaje automático y análisis nanopartícula-proteína.
2. El mejor rendimiento se obtuvo con ExtraTrees utilizando únicamente descriptores RDKit, con un RMSE medio en test de 0,412 y un R^2 medio de 0,884.
3. La incorporación de variables de membrana no produjo una mejora clara del rendimiento predictivo frente al uso exclusivo de descriptores RDKit. No obstante, estas variables aportaron información fisicoquímica complementaria sobre partición, permeabilidad y comportamiento de los ligandos en una bicapa modelo de DMPC.
4. Los resultados nanopartícula-proteína mostraron que ZnO_12_0 presentó energías de interacción más negativas que Ag_13 y Au_13 frente a las proteínas evaluadas. Por ello, ZnO_12_0 tuvo un peso dominante en las combinaciones mejor posicionadas del análisis contextual.
5. El ácido fólico es el ligando con comportamiento más consistente dentro del análisis contextual, y ZnO_12_0 es la nanopartícula que más favorece el índice en el conjunto estudiado.
6. El análisis estructural mediante PLIP aporta una interpretación estructural complementaria al docking y reforzó la relevancia del ácido fólico como ligando destacado.
7. La incorporación de una pestaña en la aplicación Streamlit basada en SMILES permitió calcular descriptores RDKit de nuevos ligandos y estimar su perfil de afinidad mediante el modelo ExtraTrees final.

Líneas futuras

Puesto que los resultados de este TFM deben considerarse como una primera aproximación, una continuación natural sería realizar el docking completo de los sistemas nanopartícula-ligando-proteína. En este trabajo el modelo principal se centró en la interacción ligando-proteína, mientras que el docking nanopartícula-proteína se trató como una capa contextual independiente. Esta decisión fue metodológicamente necesaria para no mezclar unidades de análisis distintas dentro del mismo modelo. Sin embargo, disponer de complejos completos permitiría evaluar de forma más realista el efecto combinado del núcleo inorgánico, el agente de recubrimiento y la proteína plasmática.

Otra línea de mejora sería ampliar el número de ligandos estudiados. El tamaño del dataset condiciona de forma importante la capacidad de generalización de los modelos de aprendizaje automático. Aunque los modelos evaluados mostraron un rendimiento aceptable, un conjunto de datos mayor permitiría entrenar algoritmos más robustos, reducir la dependencia de la partición entrenamiento-test y explorar con mayor seguridad relaciones no lineales entre estructura química y afinidad de docking. Esto también permitiría ampliar el conjunto de descriptores moleculares utilizados, como fingerprints moleculares, descriptores Mordred, descriptores cuánticos derivados de los cálculos de optimización y frecuencias, o variables relacionadas con HOMO.

También sería conveniente profundizar en las variables de membrana. En el presente trabajo las propiedades COSMOtherm/COSMOmic se utilizaron como bloque complementario y no produjeron una mejora clara del rendimiento predictivo frente a los descriptores RDKit. Sin embargo, estas variables pueden ser relevantes para interpretar el comportamiento global de los recubrimientos en entornos biológicos, especialmente en procesos relacionados con permeabilidad, partición lipídica o interacción con membranas celulares.

Desde el punto de vista del modelado, un aumento del número de moléculas permitiría explorar métodos más complejos, como gradient boosting, modelos basados en kernels, redes neuronales o enfoques de aprendizaje profundo molecular. También sería posible plantear estrategias de validación externa, división por familias químicas y análisis de dominio de aplicabilidad.

Bibliografía

- Ban, Z. et al. (2020). Machine learning predicts the functional composition of the protein corona and the cellular recognition of nanoparticles. *Proceedings of the National Academy of Sciences*, 117(19):10492–10499.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45:5–32.
- Dridi, N., Jin, Z., Perng, W., et al. (2024). Probing protein corona formation around gold nanoparticles: Effects of surface coating. *ACS Nano*, 18(12).
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). Auto-dock vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Fatima, H., Jin, Z. Y., Shao, Z., Chen, X. J., et al. (2022). Recent advances in zno-based photosensitizers: Synthesis, modification, and applications in photodynamic cancer therapy. *Journal of Colloid and Interface Science*, 621:440–463.
- Findlay, M. R., Freitas, D. N., Mobed-Miremadi, M., and Wheeler, K. E. (2018). Machine learning provides predictive analysis into silver nanoparticle protein corona formation from physicochemical properties. *Environmental Science: Nano*, 5:64–71.
- Geurts, P., Ernst, D., and Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63:3–42.
- Grimme, S., Antony, J., Ehrlich, S., and Krieg, H. (2010). A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H-Pu. *The Journal of Chemical Physics*, 132(15):154104.
- Ingram, T. et al. (2013). Prediction of micelle/water and liposome/water partition coefficients based on molecular dynamics simulations, cosmo-rs, and cosmomic. *Langmuir*, 29(11):3527–3537.
- Jakobtorweihen, S., Ingram, T., and Smirnova, I. (2013). Combination of cosmomic and molecular dynamics simulations for the calculation of membrane-water partition coefficients. *Journal of Computational Chemistry*, 34(15):1332–1340.

- Klamt, A. (1995). Conductor-like screening model for real solvents: A new approach to the quantitative calculation of solvation phenomena. *Journal of Physical Chemistry*, 99(7):2224–2235.
- Klamt, A., Huniar, U., Spycher, S., and Keldenich, J. (2008). Cosmomic: A mechanistic approach to the calculation of membrane-water partition coefficients and internal distributions within membranes and micelles. *Journal of Physical Chemistry B*, 112(38):12148–12157.
- Monopoli, M. P., Åberg, C., Salvati, A., and Dawson, K. A. (2012). Biomolecular coronas provide the biological identity of nanosized materials. *Nature Nanotechnology*, 7(12):779–786.
- Monopoli, M. P., Pitek, A. S., Lynch, I., and Dawson, K. A. (2013). Formation and characterization of the nanoparticle-protein corona. *Methods in Molecular Biology*, 1025:137–155.
- Neese, F. (2022). Software update: The orca program system—version 5.0. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, 12(5):e1606.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- RDKit Developers (2026). RDKit: Open-source cheminformatics software. Zenodo software release. Version 2026.03.3.
- Trott, O. and Olson, A. J. (2010). Autodock vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461.
- TURBOMOLE GmbH (2023). TURBOMOLE v7.8.1. A development of University of Karlsruhe and Forschungszentrum Karlsruhe GmbH. Available from <http://www.turbomole.com>.
- Walkey, C. D. and Chan, W. C. W. (2012). Understanding and controlling the interaction of nanomaterials with proteins in a physiological environment. *Chemical Society Reviews*, 41:2780–2799.

- Weigend, F. and Ahlrichs, R. (2005). Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7(18):3297–3305.
- Zahdeh, M. et al. (2025). Gold nanoparticles in biomedical applications: Synthesis, properties, functionalization, and clinical potential. *International Journal of Molecular Sciences*.