




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Trabajo de Fin de Máster

**Máster universitario en Ingeniería
Biomédica**

**Modelización computacional de
la interacción de agentes de
recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con
proteínas plasmáticas mediante
acoplamiento molecular y
aprendizaje automático**

Presentado por Pablo Fuentes de Mateo

Universidad de Burgos


Tutores: Santiago Aparicio – Pedro A. Marcos



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Trabajo de Fin de Máster

**Máster universitario en Ingeniería
Biomédica**

**Modelización computacional de
la interacción de agentes de
recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con
proteínas plasmáticas mediante
acoplamiento molecular y
aprendizaje automático**

Presentado por Pablo Fuentes de Mateo

Universidad de Burgos

Julio de 2026

Tutores: Santiago Aparicio – Pedro A. Marcos

Resumen

Este Trabajo de Fin de Máster desarrolla un flujo computacional para estudiar la interacción de agentes de recubrimiento de nanopartículas metálicas con proteínas plasmáticas mediante acoplamiento molecular y aprendizaje automático. Se integraron resultados de docking ligando-proteína frente a cuatro proteínas, descriptores moleculares RDKit 2D/3D, variables de membrana procedentes de cálculos COSMOtherm y resultados de docking nanopartícula-proteína para sistemas de Au, Ag y ZnO. A partir de estos datos se entrenaron modelos de regresión multisalida para predecir afinidades de docking y se compararon distintos bloques de variables, incluyendo descriptores RDKit, propiedades de membrana y reducción dimensional mediante PCA.

El mejor rendimiento predictivo se obtuvo con un modelo ExtraTrees usando descriptores RDKit, mientras que la incorporación de variables de membrana no produjo una mejora clara del error de predicción. Los resultados nanopartícula-proteína se analizaron como una capa contextual independiente, permitiendo construir un ranking integrado de combinaciones ligando-nanopartícula-proteína. Este enfoque permite separar el modelo predictivo principal, basado en ligandos, del análisis exploratorio de nanopartículas, manteniendo la trazabilidad de cada fuente de datos.

Descriptores

Nanopartículas metálicas, oro, plata, óxido de zinc, agentes de recubrimiento, docking molecular, proteínas plasmáticas, COSMOtherm, membrana, aprendizaje automático, regresión multisalida.

Abstract

This Master’s Thesis develops a computational workflow to study the interaction of nanoparticle coating agents with plasma proteins using molecular docking and machine learning. Ligand-protein docking results against four proteins were integrated with RDKit 2D/3D molecular descriptors, COSMOtherm-derived membrane variables and nanoparticle-protein docking results for Au, Ag and ZnO systems. Multi-output regression models were trained to predict docking affinities and different feature blocks were compared, including RDKit descriptors, membrane properties and PCA-based dimensionality reduction.

The best predictive performance was obtained with an ExtraTrees model using RDKit descriptors, while the inclusion of membrane variables did not clearly improve the prediction error. Nanoparticle-protein docking results were analysed as an independent contextual layer, enabling an integrated ranking of ligand-nanoparticle-protein combinations. This approach separates the main ligand-based predictive model from the exploratory nanoparticle analysis while preserving data traceability.

Keywords

Metallic nanoparticles, gold nanoparticles, silver nanoparticles, zinc oxide nanoparticles, coating agents, molecular docking, plasma proteins, COSMOtherm, membrane, machine learning, multi-output regression.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vi
Introducción y fundamentos	1
1.1. Nanopartículas metálicas y de óxido metálico	2
1.2. Proteínas plasmáticas y corona proteica	2
1.3. Acoplamiento molecular y descriptores moleculares	3
1.4. Variables de membrana y comportamiento fisicoquímico complementario	4
1.5. Aprendizaje automático en interacciones nano-bio	4
Objetivos	5
3 Conceptos teóricos	7
3.1. Nanomedicina y nanopartículas metálicas	7
3.2. Agentes de recubrimiento y funcionalización superficial	8
3.3. Corona proteica e identidad biológica	8
3.4. Proteínas plasmáticas consideradas	9
3.5. Acoplamiento molecular	10
3.6. Optimización geométrica y frecuencias vibracionales	11
3.7. Descriptores moleculares y quimioinformática	11
3.8. Propiedades de membrana y modelo COSMOmic	12
3.9. Aprendizaje automático aplicado a interacciones nano-bio	13
3.10. Evaluación de modelos	14

3.11. Integración del flujo computacional	14
Metodología	17
3.1. Diseño general del flujo computacional	17
3.2. Sistemas estudiados	17
3.3. Preparación y validación estructural de ligandos	18
3.4. Preparación de receptores y docking ligando-proteína	18
3.5. Cálculo de descriptores moleculares RDKit	19
3.6. Variables de membrana COSMOtherm/COSMOmic	19
3.7. Construcción del dataset final	20
3.8. Modelos de aprendizaje automático	20
3.9. Comparación de bloques de variables	21
3.10. Docking nanopartícula-proteína	21
3.11. Ranking contextual ligando-nanopartícula-proteína	22
3.12. Generación de tablas, figuras y aplicación de visualización	22
3.13. Reproducibilidad y trazabilidad	23
Resultados	25
4.1. Comparación de modelos predictivos	25
4.2. Rendimiento por proteína	26
4.3. Predicción real frente a predicción estimada	26
4.4. Variables relevantes	26
4.5. Docking nanopartícula-proteína	30
4.6. Ranking contextual	30
4.7. Propiedades de membrana	30
Discusión	33
Conclusiones	35
Bibliografía	37

Índice de figuras

4.1. Comparación de modelos por RMSE en test.	25
4.2. Mejor RMSE por bloque de variables.	26
4.3. RMSE por proteína del mejor modelo.	27
4.4. R^2 por proteína del mejor modelo.	27
4.5. Real vs predicho para 1ao6.	28
4.6. Real vs predicho para 1hzh.	28
4.7. Real vs predicho para 2hav.	29
4.8. Real vs predicho para 3ghg.	29
4.9. Variables más correlacionadas con las afinidades.	30
4.10. Mapa de calor de docking nanopartícula-proteína.	31
4.11. Top 20 combinaciones del ranking contextual.	31
4.12. Relación entre mem_logP y mem_logPerm.	32

Índice de tablas

Introducción y fundamentos

La nanomedicina constituye una de las áreas con mayor proyección dentro de la ingeniería biomédica, ya que permite diseñar sistemas con dimensiones comparables a estructuras biológicas fundamentales y con propiedades fisico-químicas ajustables mediante el control del tamaño, la forma, la composición y la química superficial. Entre los nanomateriales más estudiados destacan las nanopartículas metálicas y de óxido metálico, como las nanopartículas de oro, plata y óxido de zinc, por su interés en diagnóstico, administración dirigida, imagen biomédica y terapias fototérmicas o fotodinámicas ([Zahdeh et al., 2025](#); [Jangid et al., 2024](#); [Fatima et al., 2022](#); [Amaral et al., 2025](#)).

Sin embargo, el comportamiento biomédico de una nanopartícula no depende únicamente de las propiedades del núcleo inorgánico. Al entrar en contacto con fluidos biológicos, la superficie del nanomaterial se recubre rápidamente de proteínas, lípidos y otras biomoléculas, formando una corona biomolecular o corona proteica. Esta corona redefine la identidad biológica del sistema: las células y tejidos no interactúan con la superficie sintética inicial, sino con una interfaz híbrida formada por el material, sus agentes de recubrimiento y las biomoléculas adsorbidas ([Monopoli et al., 2012](#); [Walkey and Chan, 2012](#)).

La corona proteica puede modificar parámetros críticos como tamaño hidrodinámico, carga superficial, estabilidad coloidal, biodistribución, captación celular, aclaramiento por el sistema mononuclear fagocítico, inmunogenicidad y toxicidad ([Monopoli et al., 2012, 2013](#)). Su composición depende de factores como tamaño, forma, composición, curvatura y carga de la nanopartícula, química del recubrimiento, concentración proteica, fuerza iónica, pH y tiempo de exposición ([Walkey and Chan, 2012](#)). Por ello, estudiar de forma sistemática la interacción entre recubrimientos y proteínas

plasmáticas es un paso relevante para el diseño racional de nanomateriales más seguros y eficaces.

1.1. Nanopartículas metálicas y de óxido metálico

En este trabajo se consideran nanopartículas de oro, plata y óxido de zinc. Las nanopartículas de oro presentan interés por su estabilidad química, facilidad de funcionalización superficial y propiedades ópticas asociadas a la resonancia de plasmón superficial localizado, lo que las convierte en plataformas atractivas para imagen, liberación dirigida y terapia fototérmica (Zahdeh et al., 2025; Amaral et al., 2025). Las nanopartículas de plata se han estudiado ampliamente por su actividad antimicrobiana, asociada a liberación de iones Ag⁺, generación de especies reactivas de oxígeno, daño a membranas y alteración de biomoléculas celulares (Jangid et al., 2024; Rodrigues et al., 2024). Las nanopartículas de óxido de zinc presentan propiedades semiconductoras y fotocatalíticas, así como capacidad para generar especies reactivas de oxígeno bajo irradiación, lo que justifica su interés en estrategias fotodinámicas (Fatima et al., 2022).

Aunque el núcleo inorgánico condiciona propiedades ópticas, electrónicas y reactivas, la superficie determina en gran medida la interacción inmediata con el medio biológico. Los agentes de recubrimiento o *capping agents* se utilizan para estabilizar las nanopartículas, controlar su carga, mejorar su dispersión, modular su solubilidad o introducir funciones de reconocimiento molecular. Pequeñas variaciones en polaridad, tamaño, carga, flexibilidad o presencia de grupos funcionales pueden alterar la adsorción proteica y, en consecuencia, la composición de la corona. Estudios recientes en nanopartículas de oro muestran que la química superficial modifica de forma apreciable la formación de corona proteica, reforzando la necesidad de evaluar de forma sistemática el recubrimiento (Dridi et al., 2024).

1.2. Proteínas plasmáticas y corona proteica

En aplicaciones intravenosas, las proteínas plasmáticas son especialmente relevantes. La albúmina sérica humana es la proteína más abundante del plasma y presenta múltiples sitios de unión para moléculas endógenas y exógenas, por lo que puede participar de forma importante en las primeras etapas de adsorción sobre nanomateriales. Otras proteínas, como fibrinógeno, transferrina e inmunoglobulinas, están asociadas a coagulación, transporte

de hierro o reconocimiento inmunitario. En este contexto, el estudio de las interacciones entre recubrimientos y proteínas plasmáticas permite aproximar tendencias de afinidad que pueden estar relacionadas con la formación inicial de la corona.

La corona no debe entenderse como una capa estática. Habitualmente se distingue entre corona blanda, formada por biomoléculas débilmente asociadas y de intercambio rápido, y corona dura, formada por componentes con mayor afinidad y tiempos de residencia más prolongados. Aunque el docking molecular no reproduce por sí solo la complejidad cinética y competitiva de una corona real, sí permite explorar interacciones moleculares específicas y generar hipótesis comparativas sobre qué recubrimientos podrían mostrar mayor tendencia a interaccionar con determinadas proteínas.

1.3. Acoplamiento molecular y descriptores moleculares

El acoplamiento molecular permite estimar modos de unión y afinidades relativas entre ligandos y proteínas mediante la exploración conformacional del ligando en una región de búsqueda del receptor y la evaluación de las poses mediante una función de puntuación. AutoDock Vina es una herramienta ampliamente utilizada por su eficiencia, función de puntuación y capacidad de multihilo ([Trott and Olson, 2010](#)). La versión 1.2 incorporó nuevas posibilidades, incluyendo soporte de la función de puntuación de AutoDock4, docking simultáneo de múltiples ligandos, modo *batch* y enlaces con Python, lo que facilita la automatización de flujos de cribado molecular ([Eberhardt et al., 2021](#)).

Los descriptores moleculares transforman la estructura química en variables numéricas interpretables. En este TFM se utilizaron descriptores 2D/3D calculados con RDKit, incluyendo masa molecular, lipofilia, área polar, número de donadores y aceptores de hidrógeno, flexibilidad, carga, descriptores topológicos y variables geométricas ([RDKit Developers, 2026](#)). Estos descriptores permiten relacionar propiedades estructurales de los agentes de recubrimiento con las afinidades estimadas mediante docking.

1.4. Variables de membrana y comportamiento fisicoquímico complementario

Además de las interacciones con proteínas, el comportamiento de un ligando en entornos lipídicos puede aportar información complementaria sobre su partición, permeabilidad y distribución en membrana. COSMO-RS permite estimar propiedades termodinámicas a partir de cálculos cuánticos de superficie de carga de apantallamiento (Klamt, 1995), mientras que COSMOmic extiende esta aproximación a sistemas anisótropos como micelas y biomembranas, permitiendo calcular perfiles de energía libre, partición membrana/agua y distribuciones internas (Klamt et al., 2008; Ingram et al., 2013). En este trabajo, las variables de membrana se emplearon como bloque adicional de caracterización fisicoquímica, no como sustituto de las variables de docking proteína-ligando.

1.5. Aprendizaje automático en interacciones nano-bio

La combinación de docking molecular, descriptores fisicoquímicos y aprendizaje automático permite pasar de un análisis caso por caso a una aproximación predictiva. En el ámbito de la corona proteica, trabajos previos han mostrado que las propiedades fisicoquímicas de nanopartículas pueden emplearse para predecir formación de corona en nanopartículas de plata (Findlay et al., 2018) y que flujos de aprendizaje automático pueden estimar la composición funcional de la corona y su relación con reconocimiento celular (Ban et al., 2020).

En este TFM, el aprendizaje automático se plantea como una herramienta complementaria al docking. A partir de una matriz de datos formada por descriptores de ligando, variables de membrana y afinidades ligando-proteína, se entrenaron modelos de regresión multisalida para predecir de forma simultánea la afinidad frente a cuatro proteínas plasmáticas. Los resultados nanopartícula-proteína se analizaron por separado como una capa contextual, evitando mezclar unidades de análisis distintas en el modelo principal.

Objetivos

El objetivo general de este Trabajo Fin de Máster es desarrollar y aplicar una metodología computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas humanas, combinando acoplamiento molecular, descriptores moleculares, variables de membrana y aprendizaje automático.

De forma específica, se plantean los siguientes objetivos:

1. Seleccionar y preparar una biblioteca de agentes de recubrimiento representativos de nanopartículas metálicas y metal-óxido.
2. Optimizar las estructuras moleculares de los ligandos y validar las geometrías mediante análisis de frecuencias vibracionales.
3. Preparar las estructuras de las proteínas plasmáticas diana y organizar los cálculos de docking ligando-proteína.
4. Construir una matriz de afinidades ligando-proteína para cuatro proteínas plasmáticas.
5. Calcular descriptores moleculares 2D/3D mediante RDKit y combinarlos con los resultados de docking.
6. Extraer variables de membrana procedentes de cálculos COSMOtherm/COSMOmic en DMPC y evaluar su utilidad como información complementaria.
7. Desarrollar modelos de regresión multisalida para predecir afinidades de docking frente a las proteínas estudiadas.
8. Comparar bloques de variables RDKit, membrana y combinaciones de ambos, incluyendo modelos lineales, PLS, métodos de árboles y reducción dimensional mediante PCA.
9. Analizar los resultados de docking nanopartícula-proteína como una capa contextual independiente.

Objetivos

10. Generar un ranking exploratorio de combinaciones ligando-nanopartícula-proteína mediante puntuaciones normalizadas.
11. Automatizar la generación de tablas, figuras y una aplicación de visualización para facilitar la trazabilidad y reproducibilidad del flujo de trabajo.
12. Discutir las limitaciones del enfoque y proponer líneas futuras orientadas a complejos ligando-nanopartícula-proteína completos.

Capítulo 3

Conceptos teóricos

3.1. Nanomedicina y nanopartículas metálicas

La nanomedicina aplica materiales y sistemas de tamaño nanométrico al diagnóstico, seguimiento y tratamiento de enfermedades. En esta escala, las propiedades fisicoquímicas de un material no dependen únicamente de su composición química, sino también de su tamaño, forma, curvatura, estado de agregación, carga superficial y química de superficie. Esto permite diseñar plataformas con comportamiento óptico, catalítico, antimicrobiano o de transporte distinto al del material macroscópico equivalente.

En este trabajo se consideran tres familias de nanomateriales: nanopartículas de oro, nanopartículas de plata y nanopartículas de óxido de zinc. Las nanopartículas de oro presentan elevada estabilidad química, facilidad de funcionalización superficial y propiedades ópticas asociadas a la resonancia de plasmón superficial, lo que las convierte en sistemas relevantes para imagen, transporte de fármacos y terapia fototérmica ([Zahdeh et al., 2025](#)). Las nanopartículas de plata destacan por su actividad antimicrobiana, atribuida a mecanismos que incluyen liberación de iones Ag^+ , generación de especies reactivas de oxígeno e interacción con membranas y biomoléculas celulares ([Jangid et al., 2024](#)). Por su parte, el óxido de zinc es un semiconductor con propiedades fotocatalíticas y capacidad para generar especies reactivas de oxígeno, por lo que se ha estudiado como fotosensibilizador y como plataforma de interés en terapia fotodinámica ([Fatima et al., 2022](#)).

No obstante, en un medio biológico el comportamiento de estas nanopartículas no viene determinado únicamente por el núcleo inorgánico. La

superficie es el primer punto de contacto con proteínas, lípidos, sales y metabolitos, por lo que los grupos químicos presentes en ella condicionan la estabilidad coloidal, la adsorción de biomoléculas, el reconocimiento celular y la posible toxicidad. Por ello, el estudio de los agentes de recubrimiento resulta esencial para interpretar y modular las interacciones nano-bio.

3.2. Agentes de recubrimiento y funcionalización superficial

Los agentes de recubrimiento, también denominados *capping agents* o ligandos superficiales, son moléculas empleadas para estabilizar nanopartículas y ajustar sus propiedades superficiales. Pueden evitar la agregación, modificar la solubilidad, controlar la carga superficial, aportar grupos funcionales reactivos o introducir motivos de reconocimiento biológico. Entre ellos se encuentran moléculas pequeñas, ligandos tiolados, ácidos orgánicos, surfactantes, polímeros, péptidos, biomoléculas y fármacos conjugables.

Desde el punto de vista químico, pequeñas variaciones en polaridad, carga, aromaticidad, flexibilidad o número de grupos donadores y aceptores de enlaces de hidrógeno pueden modificar de forma relevante la interacción con proteínas plasmáticas. En nanopartículas metálicas, los grupos azufrados son especialmente importantes por su afinidad hacia superficies de oro y plata, mientras que grupos carboxilato, amino, fosfato o hidroxilo pueden alterar la hidratación, el estado de protonación y las interacciones electrostáticas con biomoléculas.

En un enfoque computacional, estos recubrimientos pueden abordarse a diferentes niveles de aproximación. Una primera estrategia consiste en estudiarlos como ligandos moleculares individuales frente a proteínas plasmáticas. Este planteamiento permite analizar cómo la estructura química del recubrimiento se relaciona con su afinidad relativa por diferentes proteínas. Una segunda estrategia consiste en considerar modelos simplificados de nanopartícula-recubrimiento o nanopartícula-proteína. Este nivel incorpora parcialmente el efecto del núcleo inorgánico, aunque incrementa la complejidad del sistema y puede exigir parametrizaciones específicas.

3.3. Corona proteica e identidad biológica

Cuando una nanopartícula entra en contacto con fluidos biológicos, su superficie se recubre rápidamente de proteínas y otras biomoléculas,

formando una corona biomolecular. En plasma sanguíneo, esta corona está dominada por proteínas plasmáticas y se denomina habitualmente corona proteica. Este fenómeno es clave en nanomedicina, ya que las células no interactúan únicamente con la nanopartícula sintética original, sino con una interfaz híbrida formada por el núcleo inorgánico, el recubrimiento superficial y las biomoléculas adsorbidas ([Monopoli et al., 2012](#)).

La corona proteica puede modificar el tamaño hidrodinámico, el potencial zeta, la estabilidad coloidal, la biodistribución, la captación celular, el aclaramiento por el sistema mononuclear fagocítico, la inmunogenicidad y la toxicidad. Por ello, se considera que la corona contribuye de manera decisiva a la identidad biológica de la nanopartícula ([Monopoli et al., 2012](#); [Walkey and Chan, 2012](#)).

La composición de la corona depende de múltiples factores: tamaño, forma, composición y curvatura de la nanopartícula; naturaleza del recubrimiento; concentración relativa de proteínas; afinidad de adsorción; pH; fuerza iónica; temperatura; y tiempo de exposición ([Walkey and Chan, 2012](#)). De forma conceptual puede distinguirse entre una corona blanda, formada por proteínas de interacción débil y recambio rápido, y una corona dura, compuesta por proteínas con mayor afinidad y mayor tiempo de residencia ([Monopoli et al., 2013](#)). Esta distinción es útil, aunque en sistemas reales la corona es dinámica y puede evolucionar por intercambio competitivo de proteínas.

El diseño racional de nanopartículas biomédicas requiere, por tanto, comprender cómo la química superficial afecta a la adsorción proteica. Estudios recientes en nanopartículas de oro han mostrado que la química del recubrimiento influye de forma significativa en la formación de la corona y en la interacción con proteínas séricas ([Dridi et al., 2024](#)). Este punto justifica el estudio sistemático de recubrimientos mediante docking molecular, descriptores fisicoquímicos y modelos predictivos.

3.4. Proteínas plasmáticas consideradas

En aplicaciones intravenosas, las proteínas plasmáticas son especialmente relevantes porque constituyen el primer entorno biomolecular que encuentra una nanopartícula. En este trabajo se consideran cuatro proteínas de interés: albúmina sérica humana, transferrina, fibrinógeno e inmunoglobulina G. Cada una representa un tipo de función biológica distinta y, por tanto, un posible efecto diferente sobre la identidad biológica de la nanopartícula.

La albúmina sérica humana es la proteína más abundante del plasma y posee múltiples regiones de unión para moléculas endógenas y exógenas. Su capacidad de transporte y su elevada concentración hacen que pueda participar de forma importante en las etapas iniciales de adsorción sobre nanomateriales. La transferrina está implicada en el transporte de hierro y resulta relevante en estrategias de direccionamiento hacia células con elevada expresión del receptor de transferrina. El fibrinógeno participa en procesos de coagulación y activación plaquetaria, por lo que su adsorción sobre nanopartículas puede tener implicaciones hemocompatibles. Las inmunoglobulinas, especialmente IgG, están relacionadas con reconocimiento inmunitario, opsonización y eliminación por células fagocíticas.

Desde el punto de vista del modelado, estudiar estas proteínas permite cubrir varios escenarios de interacción: transporte plasmático, coagulación, reconocimiento inmunitario y posible direccionamiento celular. Las afinidades calculadas por docking no deben interpretarse como una medida directa de la composición real de la corona, pero sí como una aproximación útil para comparar tendencias relativas entre ligandos, proteínas y recubrimientos.

3.5. Acoplamiento molecular

El acoplamiento molecular o *molecular docking* es una técnica computacional utilizada para predecir orientaciones plausibles de unión entre un ligando y una macromolécula, generalmente una proteína. El método explora posiciones, orientaciones y conformaciones del ligando dentro de una región de búsqueda definida y las ordena mediante una función de puntuación. El resultado habitual es un conjunto de poses y una energía o puntuación de afinidad aproximada.

AutoDock Vina es una de las herramientas más utilizadas para este propósito. Introdujo una función de puntuación empírica, un algoritmo de optimización eficiente y multihilo, permitiendo acelerar cálculos de docking frente a aproximaciones previas ([Trott and Olson, 2010](#)). La versión 1.2 amplió sus capacidades incorporando compatibilidad con la función de puntuación de AutoDock4, docking simultáneo de múltiples ligandos, modo *batch* y enlaces con Python, lo que facilita flujos de trabajo automatizados ([Eberhardt et al., 2021](#)).

La energía de docking debe interpretarse como una puntuación relativa, no como una energía libre de unión experimental exacta. Valores más negativos sugieren una interacción más favorable dentro del protocolo utilizado, pero la comparación debe realizarse con cautela cuando se emplean

programas, funciones de puntuación o parametrizaciones diferentes. En este TFM, las energías ligando-proteína se emplean como variables objetivo para aprendizaje automático, mientras que los resultados nanopartícula-proteína se tratan como una capa contextual independiente.

3.6. Optimización geométrica y frecuencias vibracionales

Antes de calcular descriptores moleculares o realizar docking, las estructuras de los ligandos deben presentar geometrías químicamente razonables. La optimización geométrica busca localizar un mínimo de energía en la superficie de energía potencial. Posteriormente, el cálculo de frecuencias vibracionales permite verificar la naturaleza del punto estacionario: una geometría optimizada como mínimo local no debe presentar frecuencias imaginarias.

En este trabajo, las frecuencias se consideran principalmente una etapa de validación estructural. Es decir, su función principal es comprobar que las geometrías optimizadas son compatibles con mínimos de energía antes de utilizarlas para generar descriptores o archivos de entrada. Los archivos de tipo Molden contienen información de geometría, orbitales y modos vibracionales, pero no constituyen por sí mismos variables directas del modelo predictivo. En caso de ampliación futura, podrían extraerse descriptores cuánticos escalares, como energía total, frecuencias mínimas, número de frecuencias imaginarias, energías HOMO/LUMO o brecha HOMO-LUMO. ORCA proporciona un entorno general para cálculos de química cuántica, incluyendo optimizaciones y frecuencias, y es ampliamente utilizado en flujos de trabajo de química computacional ([Neese et al., 2020](#); [Neese, 2022](#)).

3.7. Descriptores moleculares y quimioinformática

Los descriptores moleculares son variables numéricas que codifican propiedades estructurales, topológicas o fisicoquímicas de una molécula. Permiten transformar una estructura química en una matriz de datos apta para análisis estadístico o aprendizaje automático. Entre los descriptores habituales se encuentran el peso molecular, LogP, área de superficie polar topológica, número de donadores y aceptores de enlaces de hidrógeno, número de enlaces

rotables, número de anillos, carga formal, índices topológicos y descriptores geométricos tridimensionales.

RDKit es una biblioteca de quimioinformática ampliamente utilizada para manipulación de estructuras, cálculo de propiedades moleculares, generación de fingerprints y análisis de datos químicos ([RDKit Developers, 2026](#)). En este trabajo, los descriptores RDKit representan la base del dataset ligando-proteína. De forma complementaria, herramientas como Mordred permiten calcular un número muy elevado de descriptores moleculares, aunque en datasets pequeños un exceso de variables puede aumentar el riesgo de sobreajuste ([Moriwaki et al., 2018](#)).

La utilidad de los descriptores depende de su relación con el fenómeno que se desea modelar. En el contexto de este TFM, propiedades como tamaño, polaridad, flexibilidad o superficie molecular pueden influir en el modo de unión de los recubrimientos a proteínas plasmáticas. Sin embargo, un descriptor individual rara vez explica por completo la afinidad. Por ello, se emplean modelos multivariantes capaces de combinar información de múltiples variables.

3.8. Propiedades de membrana y modelo COSMOmic

Además de la interacción con proteínas plasmáticas, el comportamiento de los recubrimientos en entornos lipídicos puede aportar información fisicoquímica complementaria. La permeabilidad, partición y distribución de moléculas en membranas dependen de su polaridad, hidrofobicidad, tamaño, capacidad de formar enlaces de hidrógeno y coste energético de transferencia entre agua y la fase lipídica.

COSMO-RS es un modelo termodinámico basado en superficies de carga de apantallamiento obtenidas a partir de cálculos cuánticos en un conductor ideal. A partir de estas superficies, estima propiedades de solvatación y partición en fases líquidas ([Klamt, 1995](#)). COSMOmic extiende esta aproximación al estudio de micelas y biomembranas, permitiendo estimar coeficientes membrana/agua y distribuciones internas de solutos dentro de bicapas o sistemas micelares ([Klamt et al., 2008](#)).

En este TFM se utilizaron variables derivadas de perfiles en una bicapa modelo de DMPC. Entre ellas se incluyen descriptores como `mem_logP`, `mem_logPerm`, barreras de energía libre, distribución en función de la profundidad de la membrana, entropía media y difusión estimada. Estas variables

no describen directamente la afinidad proteína-ligando, sino el comportamiento del recubrimiento en un entorno lipídico. Por tanto, su incorporación al aprendizaje automático permite evaluar si la información de membrana añade señal predictiva a los descriptores moleculares clásicos.

3.9. Aprendizaje automático aplicado a interacciones nano-bio

El aprendizaje automático permite construir modelos que relacionan variables de entrada con una o varias salidas de interés. En química computacional, estas entradas suelen ser descriptores moleculares, fingerprints, propiedades fisicoquímicas o resultados de simulación. Las salidas pueden ser afinidades de unión, actividad biológica, toxicidad, permeabilidad o composición de corona proteica.

En el contexto de la corona proteica, ya se han propuesto modelos de aprendizaje automático para predecir la formación o composición funcional de coronas a partir de propiedades de nanopartículas, recubrimientos y condiciones experimentales (Findlay et al., 2018; Ban et al., 2020). En este TFM, el problema se plantea como una regresión multisalida: para cada ligando se predicen simultáneamente las afinidades de docking frente a varias proteínas plasmáticas.

Scikit-learn proporciona implementaciones estandarizadas de numerosos algoritmos supervisados y no supervisados, junto con herramientas para validación cruzada, preprocesado, selección de variables y evaluación de modelos (Pedregosa et al., 2011). En este trabajo se comparan modelos lineales regularizados, PLSRegression, Random Forest, ExtraTrees y aproximaciones con reducción dimensional. Random Forest combina múltiples árboles de decisión entrenados con aleatoriedad para reducir varianza y mejorar generalización (Breiman, 2001). ExtraTrees incrementa la aleatorización en la selección de variables y puntos de corte, lo que puede resultar útil en problemas con relaciones no lineales y datasets de tamaño moderado (Geurts et al., 2006).

La regresión PLS (*partial least squares*) es especialmente habitual en quimiometría porque proyecta las variables de entrada y las salidas en componentes latentes que maximizan su covarianza, tolerando colinealidad entre descriptores (Wold et al., 2001). PCA, en cambio, reduce la dimensionalidad de las variables de entrada sin utilizar directamente la salida, conservando direcciones de máxima varianza (Jolliffe, 2002). Por ello, PCA puede ser útil

para exploración o regularización, aunque no garantiza mejorar la predicción si la varianza principal no coincide con la información más relacionada con la afinidad.

3.10. Evaluación de modelos

El rendimiento de los modelos de regresión se evalúa mediante métricas continuas. En este trabajo se emplean el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2). Para un conjunto de n observaciones, con valores reales y_i y predicciones $\hat{y}_i$, estas métricas se definen como:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

El MAE mide el error medio en las mismas unidades que la variable objetivo y es relativamente interpretable. El RMSE penaliza más los errores grandes, por lo que resulta útil para detectar modelos con desviaciones importantes en algunos ligandos. El R^2 expresa la proporción de variabilidad explicada por el modelo respecto a un predictor constante. En problemas con pocos datos, la validación cruzada y la separación de un conjunto de test son necesarias para reducir el riesgo de interpretar como generalización un ajuste específico del conjunto de entrenamiento.

3.11. Integración del flujo computacional

La integración de preparación molecular, docking, cálculo de descriptores, variables de membrana, análisis nanopartícula-proteína y aprendizaje automático requiere un flujo de trabajo reproducible. En este TFM, cada etapa produce archivos intermedios y tablas finales que pueden regenerarse mediante scripts. Esta organización permite auditar el origen de cada variable, repetir análisis tras corregir datos de entrada y generar automáticamente figuras, tablas y visualizaciones.

El resultado conceptual del flujo de trabajo es una separación clara entre tres capas de información. La primera corresponde al modelo principal ligando-proteína, basado en descriptores moleculares y afinidades de docking. La segunda corresponde a variables de membrana, utilizadas para comprobar si añaden información predictiva. La tercera corresponde al análisis nanopartícula-proteína, tratado como contexto adicional para priorizar combinaciones ligando-nanopartícula-proteína sin mezclar directamente energías procedentes de protocolos distintos. Esta separación evita sobreinterpretar los datos y facilita una discusión metodológicamente coherente.

Metodología

3.1. Diseño general del flujo computacional

El trabajo se estructuró como un flujo computacional reproducible basado en archivos CSV, scripts de Python/R y una plantilla Quarto para la generación de memoria y anexos. La unidad principal del modelo predictivo fue el ligando, entendido como agente de recubrimiento o molécula funcional asociable a nanopartículas. Para cada ligando se integraron descriptores moleculares, variables de membrana y cuatro valores de afinidad de docking ligando-proteína.

El flujo se dividió en seis bloques: preparación y validación estructural de ligandos, docking ligando-proteína, cálculo de descriptores RDKit, extracción de variables de membrana, entrenamiento de modelos de aprendizaje automático y análisis contextual de docking nanopartícula-proteína. Esta separación evitó mezclar directamente entidades distintas dentro de un mismo modelo: el modelo principal trabaja con filas de ligando, mientras que la información nanopartícula-proteína se analiza como una capa independiente.

3.2. Sistemas estudiados

La biblioteca de trabajo incluyó agentes de recubrimiento y moléculas con interés biomédico, abarcando compuestos pequeños, grupos con afinidad por superficies metálicas, moléculas polares, moléculas aromáticas y algunos fármacos o aproximaciones estructurales de fármacos. Las proteínas plasmáticas se identificaron mediante sus códigos estructurales: **1ao6**, **1hzh**, **2hav** y **3ghg**. Los resultados de docking ligando-proteína se almacenaron como cuatro variables objetivo: **y_1ao6**, **y_1hzh**, **y_2hav** y **y_3ghg**.

Las nanopartículas se consideraron mediante modelos simplificados de oro, plata y óxido de zinc. Para el análisis nanopartícula-proteína se emplearon los sistemas Ag_13, Au_13 y ZnO_12_0. Estos resultados no se añadieron al dataset de ligandos como variables ordinarias, ya que representan interacciones nanopartícula-proteína y no propiedades intrínsecas del ligando.

3.3. Preparación y validación estructural de ligandos

Las estructuras moleculares de los ligandos fueron preparadas y optimizadas antes de su uso en el flujo de docking y cálculo de descriptores. La optimización geométrica se complementó con cálculos de frecuencias vibracionales. La ausencia de frecuencias imaginarias se utilizó como criterio de validación de mínimo local, de forma que las frecuencias actuaron como control de estabilidad estructural y no como variables principales del modelo predictivo.

Los cálculos cuánticos se organizaron para generar estructuras compatibles con los pasos posteriores y, cuando fue necesario, archivos de tipo Molden para inspección estructural. El programa ORCA se utilizó como herramienta de química cuántica para la generación de estructuras optimizadas y archivos compatibles con COSMO-RS/COSMOtherm (Neese, 2022). En el flujo de membrana se partió de archivos COSMO/ORCACOSMO asociados a los solutos, necesarios para el cálculo posterior de propiedades termodinámicas mediante COSMO-RS (Klamt, 1995).

3.4. Preparación de receptores y docking ligando-proteína

El acoplamiento molecular ligando-proteína se realizó con AutoDock Vina, empleando estructuras de proteínas preparadas en formato PDBQT y ligandos también convertidos a PDBQT. AutoDock Vina explora poses del ligando en la región de búsqueda definida y estima una afinidad de unión aproximada mediante su función de puntuación (Trott and Olson, 2010). La versión moderna de Vina permite automatizar cálculos en modo *batch* y facilita la integración en flujos de cribado mediante interfaces de scripting (Eberhardt et al., 2021).

Para cada combinación ligando-proteína se conservó la mejor afinidad calculada por docking. Los valores se almacenaron en una tabla final con

una fila por ligando y una columna objetivo por proteína. Dado que las cuatro salidas son continuas y se predicen de forma simultánea, el problema de aprendizaje automático se formuló como una regresión multisalida.

3.5. Cálculo de descriptores moleculares RDKit

A partir de las estructuras optimizadas se calcularon descriptores moleculares con RDKit ([RDKit Developers, 2026](#)). El bloque RDKit incluyó variables de tamaño y composición, como `MolWt`, `ExactMolWt`, `NumHeavyAtoms` y `NumAtoms`; variables de polaridad y capacidad de interacción, como `TPSA`, `NumHDonors` y `NumHAcceptors`; variables de lipofilia, como `MolLogP`; variables de flexibilidad, como `NumRotatableBonds`; y descriptores topológicos y geométricos, como `Chi0n`, `Chi1n`, `Kappa1`, `Kappa2`, `LabuteASA`, momentos principales de inercia, radio de giro y esfericidad.

Estos descriptores permitieron transformar cada ligando en un vector numérico comparable. El uso de variables interpretables facilita relacionar propiedades como tamaño, polaridad, hidrofobicidad o forma molecular con las afinidades calculadas por docking.

3.6. Variables de membrana COSMOtherm/COSMOmic

Las variables de membrana se extrajeron a partir de cálculos en una bicapa de dimiristoilfosfatidilcolina (DMPC) en agua a 37 °C. El fundamento teórico se basa en COSMO-RS, que utiliza densidades de carga de apantallamiento obtenidas a partir de cálculos cuánticos para predecir propiedades termodinámicas en fase líquida ([Klamt, 1995](#)). Para entornos anisótropos como micelas y biomembranas, COSMOmic permite describir perfiles dependientes de la profundidad en la membrana y calcular propiedades como partición membrana/agua y distribuciones internas ([Klamt et al., 2008](#); [Jakobtorweihen et al., 2013](#); [Ingram et al., 2013](#)).

Del archivo de permeabilidad se extrajeron variables globales y estadísticas resumen. Entre las variables globales se incluyeron `mem_logP`, correspondiente al logaritmo de partición micela/agua; `mem_logP_kg_1`, versión ajustada en unidades kg/L; y `mem_logPerm`, asociado a la permeabilidad de membrana. Además, se resumieron perfiles dependientes de la profundidad para energía libre, distribución, entropía media y difusión. Para cada perfil

se calcularon estadísticos como media, mínimo, máximo, valor en la zona central de la membrana y, cuando procedía, profundidad asociada a máximos o mínimos.

Las variables de membrana se incorporaron como bloque complementario al dataset de ligandos. Su objetivo fue evaluar si la información de partición y permeabilidad aportaba mejora predictiva frente a los descriptores RDKit. Metodológicamente, se mantuvieron separadas para poder comparar modelos RDKit-solo, membrana-solo y RDKit+membrana.

3.7. Construcción del dataset final

El dataset final se construyó mediante la unión de tres fuentes: descriptores RDKit, variables de membrana y afinidades de docking ligando-proteína. La tabla principal mantuvo una fila por ligando. Las columnas objetivo fueron `y_1ao6`, `y_1hzh`, `y_2hav` y `y_3ghg`.

Antes del entrenamiento se sustituyeron valores infinitos por valores perdidos y se aplicó imputación por la mediana dentro del flujo de modelado. Las variables de varianza nula se eliminaron mediante un filtro de varianza. En los modelos lineales y en PCA se aplicó escalado estándar para evitar que variables con distinta magnitud dominaran el ajuste. En los modelos basados en árboles no fue necesario escalar las variables, aunque se mantuvo un flujo homogéneo de preprocesado para asegurar comparaciones reproducibles.

3.8. Modelos de aprendizaje automático

Se compararon distintos modelos de regresión multisalida usando scikit-learn ([Pedregosa et al., 2011](#)). Los modelos evaluados fueron Ridge, PLS-Regression, RandomForestRegressor, ExtraTreesRegressor y PCA seguido de Ridge. Ridge se incluyó como modelo lineal regularizado; PLSRegression como modelo útil en escenarios con variables correlacionadas y tamaño muestral reducido; Random Forest y ExtraTrees como métodos no lineales basados en ensamblados de árboles; y PCA_Ridge como estrategia de reducción dimensional previa al ajuste lineal.

El modelo ExtraTrees se basa en árboles extremadamente aleatorizados, que incrementan la aleatoriedad tanto en la selección de variables como en los puntos de corte, pudiendo reducir varianza y mejorar generalización en problemas tabulares ([Geurts et al., 2006](#)). Random Forest se incluyó como

referencia de ensamblado basado en árboles de decisión entrenados sobre subconjuntos y agregados por promediado (Breiman, 2001).

La evaluación se realizó mediante partición entrenamiento-test y validación cruzada en el conjunto de entrenamiento. Para comparar de forma justa los bloques de variables, se mantuvieron la misma partición, las mismas salidas y las mismas métricas entre modelos. Las métricas principales fueron el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación R^2 . Estas métricas se calcularon de forma global y por proteína.

3.9. Comparación de bloques de variables

La comparación se organizó por bloques de entrada:

- `RDKit_solo`: únicamente descriptores moleculares RDKit.
- `RDKit_membrana_seleccionada`: descriptores RDKit más variables de membrana con señal fisicoquímica clara.
- `Membrana_solo`: únicamente variables COSMOtherm/COSMOmic.
- `RDKit_membrana_filtrada_auto`: combinación RDKit+membrana con filtrado automático de variables no informativas.

Esta organización permitió responder a una pregunta metodológica central: si las variables de membrana mejoraban la predicción de afinidad proteína-ligando o si actuaban principalmente como caracterización fisicoquímica complementaria. Dado el tamaño reducido del dataset, la interpretación se basó en el conjunto de métricas y no en una única cifra aislada.

3.10. Docking nanopartícula-proteína

Los resultados de docking nanopartícula-proteína se obtuvieron a partir de archivos DLG. Para cada archivo se extrajeron las energías detectadas y se generó una tabla con nanopartícula, proteína, energía mínima y número de energías identificadas. Estos cálculos se trataron como un análisis independiente del modelo ligando-proteína.

La razón es que una energía nanopartícula-proteína no varía por ligando, sino por combinación nanopartícula-proteína. Incluirla directamente como descriptor en una tabla donde cada fila representa un ligando generaría una mezcla de unidades de análisis. Por ello, se utilizó como capa contextual

para construir rankings exploratorios, pero no como variable del modelo principal.

3.11. Ranking contextual ligando-nanopartícula-proteína

Para integrar de forma exploratoria la información ligando-proteína y nanopartícula-proteína se construyó una tabla en formato largo con una fila por combinación ligando-nanopartícula-proteína. La afinidad ligando-proteína se denotó como $(E^{\wedge}\{LP\}\{i,p\})$, donde (i) es el ligando y (p) la proteína. La afinidad nanopartícula-proteína se denotó como $(E^{\wedge}\{NP\}\{n,p\})$, donde (n) es la nanopartícula.

Como valores más negativos indican interacciones más favorables, se transformaron las energías en puntuaciones normalizadas por proteína:

$$S_{i,p}^{LP} = -z_p(E_{i,p}^{LP})$$

$$S_{n,p}^{NP} = -z_p(E_{n,p}^{NP})$$

donde (z_p) representa el z-score calculado dentro de cada proteína. A continuación, se definió un score contextual medio:

$$S_{i,n,p}^{contexto} = \frac{S_{i,p}^{LP} + S_{n,p}^{NP}}{2}$$

Este score no representa una energía física total. Su función es ordenar combinaciones de forma comparativa, integrando dos tendencias: ligandos con afinidad favorable frente a una proteína y nanopartículas con interacción favorable frente a esa misma proteína.

3.12. Generación de tablas, figuras y aplicación de visualización

Los resultados finales se organizaron mediante scripts de R para generar tablas en CSV y figuras en PNG. Las figuras incluyeron comparación de modelos por RMSE, rendimiento por proteína, gráficos real-predicho,

correlaciones de variables, mapas de calor nanopartícula-proteína, ranking contextual y relaciones entre variables de membrana.

Además, se desarrolló una aplicación Streamlit para revisar de forma interactiva los CSV generados. La aplicación permite explorar modelos, métricas, predicciones, variables de membrana, docking nanopartícula-proteína y ranking contextual. Esta aplicación se considera una herramienta auxiliar de visualización, mientras que los análisis reproducibles quedan definidos por los scripts y los archivos CSV generados.

3.13. Reproducibilidad y trazabilidad

La estructura final del proyecto separó datos, scripts, resultados, aplicación y documentación. Los datasets se almacenaron en `datasets/`; los scripts en `scripts/modelos`, `scripts/membrana`, `scripts/nanoparticulas` y `scripts/utilidades`; las salidas en `resultados/`; y la memoria en una plantilla Quarto. Esta organización permite regenerar tablas y figuras a partir de los CSV base y facilita la ampliación futura del flujo a nuevos ligandos, nuevas proteínas o complejos ligando-nanopartícula-proteína completos.

Resultados

4.1. Comparación de modelos predictivos

La comparación de modelos permitió evaluar el efecto de distintos bloques de variables sobre la predicción de afinidades de docking. La Figura 4.1 muestra el ranking de modelos ordenado por RMSE en test.




Figura 4.1: Comparación de modelos por RMSE en test.

La comparación por bloques de variables se resume en la Figura 4.2. Este análisis permite valorar de forma directa si la inclusión de variables de membrana mejora el modelo frente al uso exclusivo de descriptores RDKit.




Figura 4.2: Mejor RMSE por bloque de variables.

4.2. Rendimiento por proteína

El rendimiento por proteína del mejor modelo se evaluó mediante RMSE y R^2 . Las Figuras Figura 4.3 y Figura 4.4 muestran la variabilidad de rendimiento entre las cuatro proteínas.

4.3. Predicción real frente a predicción estimada

La concordancia entre valores reales de docking y valores predichos se inspeccionó mediante diagramas de dispersión proteína a proteína.

4.4. Variables relevantes

La Figura Figura 4.9 muestra las variables más correlacionadas con las afinidades de docking. Este análisis se utilizó como exploración descriptiva, no como criterio único de selección de variables.




Figura 4.3: RMSE por proteína del mejor modelo.




Figura 4.4: R² por proteína del mejor modelo.




Figura 4.5: Real vs predicho para 1ao6.




Figura 4.6: Real vs predicho para 1hzh.




Figura 4.7: Real vs predicho para 2hav.




Figura 4.8: Real vs predicho para 3ghg.




Figura 4.9: Variables más correlacionadas con las afinidades.

4.5. Docking nanopartícula-proteína

Los resultados nanopartícula-proteína se resumen en la Figura Figura 4.10. Las energías más negativas indican interacciones más favorables dentro del protocolo de docking utilizado.

4.6. Ranking contextual

El score contextual permitió combinar, de forma normalizada, la afinidad ligando-proteína y la afinidad nanopartícula-proteína. La Figura Figura 4.11 muestra las combinaciones mejor posicionadas.

4.7. Propiedades de membrana

Las variables de membrana se analizaron como información fisicoquímica complementaria. La Figura Figura 4.12 muestra la relación entre partición y permeabilidad derivadas de COSMOtherm.




Figura 4.10: Mapa de calor de docking nanopartícula-proteína.




Figura 4.11: Top 20 combinaciones del ranking contextual.




Figura 4.12: Relación entre mem_logP y mem_logPerm.

Discusión

Conclusiones

Bibliografía

- Amaral, M. N. et al. (2025). Gold nanoparticle-mediated photothermal therapy. *Biomedicine and Pharmacotherapy*.
- Ban, Z. et al. (2020). Machine learning predicts the functional composition of the protein corona and the cellular recognition of nanoparticles. *Proceedings of the National Academy of Sciences*, 117(19):10492–10499.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45:5–32.
- Dridi, N., Jin, Z., Perng, W., et al. (2024). Probing protein corona formation around gold nanoparticles: Effects of surface coating. *ACS Nano*, 18(12).
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). Auto-dock vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Fatima, H., Jin, Z. Y., Shao, Z., Chen, X. J., et al. (2022). Recent advances in zno-based photosensitizers: Synthesis, modification, and applications in photodynamic cancer therapy. *Journal of Colloid and Interface Science*, 621:440–463.
- Findlay, M. R., Freitas, D. N., Mobed-Miremadi, M., and Wheeler, K. E. (2018). Machine learning provides predictive analysis into silver nanoparticle protein corona formation from physicochemical properties. *Environmental Science: Nano*, 5:64–71.
- Geurts, P., Ernst, D., and Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63:3–42.

- Ingram, T. et al. (2013). Prediction of micelle/water and liposome/water partition coefficients based on molecular dynamics simulations, cosmo-rs, and cosmomic. *Langmuir*, 29(11):3527–3537.
- Jakobtorweihen, S., Ingram, T., and Smirnova, I. (2013). Combination of cosmomic and molecular dynamics simulations for the calculation of membrane-water partition coefficients. *Journal of Computational Chemistry*, 34(15):1332–1340.
- Jangid, H., Singh, S. S., Kashyap, P., Singh, A., and Kumar, G. (2024). Advancing biomedical applications: an in-depth analysis of silver nanoparticles in antimicrobial, anticancer, and wound healing roles. *Frontiers in Pharmacology*, 15.
- Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer, 2 edition.
- Klamt, A. (1995). Conductor-like screening model for real solvents: A new approach to the quantitative calculation of solvation phenomena. *Journal of Physical Chemistry*, 99(7):2224–2235.
- Klamt, A., Huniar, U., Spycher, S., and Keldenich, J. (2008). Cosmomic: A mechanistic approach to the calculation of membrane-water partition coefficients and internal distributions within membranes and micelles. *Journal of Physical Chemistry B*, 112(38):12148–12157.
- Monopoli, M. P., Åberg, C., Salvati, A., and Dawson, K. A. (2012). Biomolecular coronas provide the biological identity of nanosized materials. *Nature Nanotechnology*, 7(12):779–786.
- Monopoli, M. P., Pitek, A. S., Lynch, I., and Dawson, K. A. (2013). Formation and characterization of the nanoparticle-protein corona. *Methods in Molecular Biology*, 1025:137–155.
- Moriwaki, H., Tian, Y.-S., Kawashita, N., and Takagi, T. (2018). Mordred: a molecular descriptor calculator. *Journal of Cheminformatics*, 10:4.
- Neese, F. (2022). Software update: The orca program system—version 5.0. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, 12(5):e1606.
- Neese, F., Wennmohs, F., Becker, U., and Riplinger, C. (2020). The orca quantum chemistry program package. *Journal of Chemical Physics*, 152(22):224108.

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- RDKit Developers (2026). RDKit: Open-source cheminformatics software. Zenodo software release. Version 2026.03.3.
- Rodrigues, A. S. et al. (2024). Advances in silver nanoparticles: a comprehensive review on their potential as antimicrobial agents and their mechanisms of action elucidated by proteomics. *Frontiers in Microbiology*, 15.
- Trott, O. and Olson, A. J. (2010). Autodock vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461.
- Walkey, C. D. and Chan, W. C. W. (2012). Understanding and controlling the interaction of nanomaterials with proteins in a physiological environment. *Chemical Society Reviews*, 41:2780–2799.
- Wold, S., Sjöström, M., and Eriksson, L. (2001). Pls-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2):109–130.
- Zahdeh, M. et al. (2025). Gold nanoparticles in biomedical applications: Synthesis, properties, functionalization, and clinical potential. *International Journal of Molecular Sciences*.