




**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Trabajo de Fin de Máster

**Máster universitario en Ingeniería
Biomédica**

**Modelización computacional de
la interacción de agentes de
recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con
proteínas plasmáticas mediante
acoplamiento molecular y
aprendizaje automático**

Presentado por Pablo Fuentes de Mateo

Universidad de Burgos


Tutores: Santiago Aparicio – Pedro A. Marcos



**UNIVERSIDAD
DE BURGOS**

Escuela Politécnica Superior

Grado en Ingeniería de la Salud



Trabajo de Fin de Máster

**Máster universitario en Ingeniería
Biomédica**

**Modelización computacional de
la interacción de agentes de
recubrimiento de nanopartículas
metálicas (Au, Ag, ZnO) con
proteínas plasmáticas mediante
acoplamiento molecular y
aprendizaje automático**

Presentado por Pablo Fuentes de Mateo

Universidad de Burgos

Julio de 2026

Tutores: Santiago Aparicio – Pedro A. Marcos

Resumen

Este Trabajo de Fin de Máster desarrolla un flujo computacional para estudiar la interacción de agentes de recubrimiento de nanopartículas metálicas con proteínas plasmáticas mediante acoplamiento molecular y aprendizaje automático. Se integraron resultados de docking ligando-proteína frente a cuatro proteínas, descriptores moleculares RDKit 2D/3D, variables de membrana procedentes de cálculos COSMOtherm y resultados de docking nanopartícula-proteína para sistemas de Au, Ag y ZnO. A partir de estos datos se entrenaron modelos de regresión multisalida para predecir afinidades de docking y se compararon distintos bloques de variables, incluyendo descriptores RDKit, propiedades de membrana y reducción dimensional mediante PCA.

El mejor rendimiento predictivo se obtuvo con un modelo ExtraTrees usando descriptores RDKit, mientras que la incorporación de variables de membrana no produjo una mejora clara del error de predicción. Los resultados nanopartícula-proteína se analizaron como una capa contextual independiente, permitiendo construir un ranking integrado de combinaciones ligando-nanopartícula-proteína. Este enfoque permite separar el modelo predictivo principal, basado en ligandos, del análisis exploratorio de nanopartículas, manteniendo la trazabilidad de cada fuente de datos.

Descriptores

Nanopartículas metálicas, oro, plata, óxido de zinc, agentes de recubrimiento, docking molecular, proteínas plasmáticas, COSMOtherm, membrana, aprendizaje automático, regresión multisalida.

Abstract

This Master’s Thesis develops a computational workflow to study the interaction of nanoparticle coating agents with plasma proteins using molecular docking and machine learning. Ligand-protein docking results against four proteins were integrated with RDKit 2D/3D molecular descriptors, COSMOtherm-derived membrane variables and nanoparticle-protein docking results for Au, Ag and ZnO systems. Multi-output regression models were trained to predict docking affinities and different feature blocks were compared, including RDKit descriptors, membrane properties and PCA-based dimensionality reduction.

The best predictive performance was obtained with an ExtraTrees model using RDKit descriptors, while the inclusion of membrane variables did not clearly improve the prediction error. Nanoparticle-protein docking results were analysed as an independent contextual layer, enabling an integrated ranking of ligand-nanoparticle-protein combinations. This approach separates the main ligand-based predictive model from the exploratory nanoparticle analysis while preserving data traceability.

Keywords

Metallic nanoparticles, gold nanoparticles, silver nanoparticles, zinc oxide nanoparticles, coating agents, molecular docking, plasma proteins, COSMOtherm, membrane, machine learning, multi-output regression.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vi
Introducción	1
Objetivos	5
Conceptos teóricos	7
3.1. Nanomedicina y nanopartículas metálicas	7
3.2. Agentes de recubrimiento y funcionalización superficial . . .	8
3.3. Corona proteica e identidad biológica	8
3.4. Proteínas plasmáticas consideradas	9
3.5. Acoplamiento molecular	10
3.6. Optimización geométrica y frecuencias vibracionales	11
3.7. Descriptores moleculares y quimioinformática	11
3.8. Propiedades de membrana y modelo COSMOmic	12
3.9. Aprendizaje automático aplicado a interacciones nano-bio . .	13
3.10. Evaluación de modelos	14
3.11. Integración del flujo computacional	14
Metodología	17
4.1. Diseño general del flujo computacional	17
4.2. Sistemas estudiados	17
4.3. Preparación y validación estructural de ligandos	18

4.4. Preparación de receptores y docking ligando-proteína	18
4.5. Cálculo de descriptores moleculares RDKit	19
4.6. Variables de membrana COSMOtherm/COSMOmic	19
4.7. Construcción del dataset final	20
4.8. Modelos de aprendizaje automático	20
4.9. Comparación de bloques de variables	21
4.10. Docking nanopartícula-proteína	21
4.11. Generación de tablas, figuras y aplicación de visualización	23
4.12. Reproducibilidad y trazabilidad	23
Resultados	25
5.1. Comparación de modelos predictivos	25
5.2. Rendimiento por proteína	27
5.3. Predicción real frente a predicción estimada	28
5.4. Variables relevantes	29
5.5. Docking nanopartícula-proteína	30
5.6. Índice Contextual Nano-Bio	31
5.7. Análisis PLIP de complejos representativos	33
5.8. Propiedades de membrana	34
5.9. Aplicación de visualización y predicción	35
Discusión	37
6.1. Interpretación del modelo predictivo	37
6.2. Papel de las variables de membrana	38
6.3. Diferencias de rendimiento entre proteínas	39
6.4. Docking nanopartícula-proteína	40
6.5. Índice Contextual Nano-Bio	41
6.6. Análisis estructural mediante PLIP	41
6.7. Aplicación predictiva desde SMILES	42
6.8. Limitaciones del estudio	43
6.9. Síntesis final	44
7 Conclusiones	45
Lineas futuras	47
Bibliografía	49

Índice de figuras

5.1. Comparación de modelos por RMSE en test.	26
5.2. Mejor RMSE por bloque de variables.	27
5.3. RMSE por proteína del mejor modelo.	28
5.4. R^2 por proteína del mejor modelo.	28
5.5. Comparación real vs predicho para las cuatro proteínas.	29
5.6. Variables más correlacionadas con las afinidades.	30
5.7. Mapa de calor de docking nanopartícula-proteína.	31
5.8. Top 20 combinaciones según el Índice Contextual Nano-Bio.	32
5.9. Relación entre mem_logP y mem_logPerm.	35

Índice de tablas

Introducción

La nanomedicina constituye una de las áreas con mayor proyección dentro de la ingeniería biomédica, al permitir el diseño de sistemas con dimensiones comparables a estructuras biológicas fundamentales y con propiedades fisicoquímicas ajustables mediante cambios en tamaño, forma, composición y química superficial. Entre los nanomateriales más estudiados destacan las nanopartículas metálicas y metal-óxido, como las nanopartículas de oro, plata y óxido de zinc, debido a su interés en aplicaciones de diagnóstico, terapia, administración dirigida de fármacos, biosensado, imagen biomédica y terapias fototérmicas o fotodinámicas ([Zahdeh et al., 2025](#), [Fatima et al. \(2022\)](#)).

Sin embargo, la eficacia biomédica de una nanopartícula no depende únicamente de sus propiedades sintéticas iniciales. Al entrar en contacto con fluidos biológicos, como el plasma sanguíneo, la superficie del nanomaterial se recubre rápidamente de proteínas, lípidos y otras biomoléculas, formando la denominada corona biomolecular o corona proteica ([Monopoli et al., 2012](#)). Esta corona modifica la “identidad biológica” de la nanopartícula, de modo que las células y tejidos no interactúan con la superficie original diseñada en el laboratorio, sino con una interfaz híbrida formada por el nanomaterial, sus agentes de recubrimiento y las biomoléculas adsorbidas ([Monopoli et al., 2012](#), [Walkey and Chan \(2012\)](#)). Como consecuencia, la corona proteica puede alterar parámetros críticos como el tamaño hidrodinámico, la carga superficial, la estabilidad coloidal, la biodistribución, la captación celular, el aclaramiento por el sistema mononuclear fagocítico, la inmunogenicidad y la toxicidad ([Walkey and Chan, 2012](#), [Monopoli et al. \(2013\)](#)).

La composición de la corona proteica depende de múltiples factores, incluyendo las propiedades intrínsecas de la nanopartícula —tamaño, forma, composición, curvatura y carga superficial—, la naturaleza química de los

agentes de recubrimiento y las condiciones del medio biológico, como concentración proteica, fuerza iónica, pH y tiempo de exposición ([Walkey and Chan, 2012](#), [Monopoli et al. \(2013\)](#)). En el caso de aplicaciones intravenosas, las proteínas plasmáticas desempeñan un papel especialmente relevante. La albúmina sérica humana, proteína más abundante del plasma, presenta múltiples sitios de unión para moléculas endógenas y exógenas, por lo que puede participar de forma importante en las primeras etapas de adsorción sobre nanomateriales. Otras proteínas, como fibrinógeno, transferrina e inmunoglobulinas, están asociadas a procesos de coagulación, transporte de hierro o reconocimiento inmunitario. Por ello, comprender cómo los recubrimientos superficiales de nanopartículas interactúan con estas proteínas resulta esencial para el diseño racional de nanomateriales más seguros y eficaces.

Los agentes de recubrimiento o capping agents constituyen un elemento clave, se emplean habitualmente para estabilizar nanopartículas, modular su solubilidad, controlar su carga superficial o introducir funciones de direccionamiento biológico. No obstante, estos mismos grupos químicos condicionan las interacciones iniciales con las proteínas plasmáticas y, por tanto, la composición final de la corona. Estudios recientes han mostrado que variaciones en la química superficial de nanopartículas de oro modifican de forma significativa la formación de corona proteica, lo que confirma la necesidad de analizar de forma sistemática la relación entre recubrimiento, afinidad proteica y respuesta biológica [9]. El estudio experimental de la corona proteica proporciona información directa y de gran valor, pero suele requerir técnicas costosas y laboriosas, como espectrometría de masas, electroforesis, dispersión dinámica de luz, microscopía electrónica, resonancia de plasmones superficiales o calorimetría. Además, la enorme diversidad de combinaciones posibles entre nanomateriales, recubrimientos, proteínas y condiciones biológicas dificulta una exploración puramente experimental. Por este motivo, los métodos computacionales se han consolidado como herramientas complementarias para estudiar interacciones nano-bio, priorizar candidatos y generar hipótesis mecanísticas antes de la validación experimental.

Dentro de estas aproximaciones, el acoplamiento o docking molecular permite estimar modos de unión y afinidades relativas entre ligandos y proteínas, identificando residuos implicados en interacciones de hidrógeno, contactos hidrofóbicos, interacciones electrostáticas o apilamiento aromático. La integración de docking molecular con descriptores fisicoquímicos y técnicas de aprendizaje automático ofrece una vía prometedora para modelizar de forma predictiva las interacciones entre recubrimientos de nanopartículas y proteínas plasmáticas. A partir de propiedades como peso molecular, polari-

dad, carga, LogP, área de superficie polar, número de donadores y aceptores de enlaces de hidrógeno, flexibilidad molecular y fingerprints estructurales, es posible entrenar modelos que relacionen la estructura química de los ligandos con su afinidad estimada por proteínas relevantes. Estudios recientes han demostrado que el aprendizaje automático puede contribuir a predecir la composición y abundancia relativa de proteínas en la corona a partir de propiedades de nanopartículas y condiciones experimentales ([Findlay et al., 2018](#), [Ban et al. \(2020\)](#)).

Objetivos

El objetivo general de este Trabajo Fin de Máster es desarrollar y aplicar una metodología computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas humanas, combinando acoplamiento molecular, descriptores moleculares, variables de membrana y aprendizaje automático.

De forma específica, se plantean los siguientes objetivos:

1. Seleccionar y preparar una biblioteca de agentes de recubrimiento representativos de nanopartículas metálicas y metal-óxido.
2. Optimizar las estructuras moleculares de los ligandos y validar las geometrías mediante análisis de frecuencias vibracionales.
3. Preparar las estructuras de las proteínas plasmáticas diana y organizar los cálculos de docking ligando-proteína.
4. Construir una matriz de afinidades ligando-proteína para cuatro proteínas plasmáticas.
5. Calcular descriptores moleculares 2D/3D mediante RDKit y combinarlos con los resultados de docking.
6. Extraer variables de membrana procedentes de cálculos COSMOtherm/COSMOmic en DMPC y evaluar su utilidad como información complementaria.
7. Desarrollar modelos de regresión multisalida para predecir afinidades de docking frente a las proteínas estudiadas.
8. Comparar bloques de variables RDKit, membrana y combinaciones de ambos, incluyendo modelos lineales, PLS, métodos de árboles y reducción dimensional mediante PCA.
9. Analizar los resultados de docking nanopartícula-proteína como una capa contextual independiente.

Objetivos

10. Generar un ranking exploratorio de combinaciones ligando-nanopartícula-proteína mediante puntuaciones normalizadas.
11. Automatizar la generación de tablas, figuras y una aplicación de visualización para facilitar la trazabilidad y reproducibilidad del flujo de trabajo.
12. Discutir las limitaciones del enfoque y proponer líneas futuras orientadas a complejos ligando-nanopartícula-proteína completos.

Conceptos teóricos

3.1. Nanomedicina y nanopartículas metálicas

La nanomedicina aplica materiales y sistemas de tamaño nanométrico al diagnóstico, seguimiento y tratamiento de enfermedades. En esta escala, las propiedades fisicoquímicas de un material no dependen únicamente de su composición química, sino también de su tamaño, forma, curvatura, estado de agregación, carga superficial y química de superficie. Esto permite diseñar plataformas con comportamiento óptico, catalítico, antimicrobiano o de transporte distinto al del material macroscópico equivalente.

En este trabajo se consideran tres familias de nanomateriales: nanopartículas de oro, nanopartículas de plata y nanopartículas de óxido de zinc. Las nanopartículas de oro presentan elevada estabilidad química, facilidad de funcionalización superficial y propiedades ópticas asociadas a la resonancia de plasmón superficial, lo que las convierte en sistemas relevantes para imagen, transporte de fármacos y terapia fototérmica ([Zahdeh et al., 2025](#)). Las nanopartículas de plata destacan por su actividad antimicrobiana, atribuida a mecanismos que incluyen liberación de iones Ag^+ , generación de especies reactivas de oxígeno e interacción con membranas y biomoléculas celulares ([Jangid et al., 2024](#)). Por su parte, el óxido de zinc es un semiconductor con propiedades fotocatalíticas y capacidad para generar especies reactivas de oxígeno, por lo que se ha estudiado como fotosensibilizador y como plataforma de interés en terapia fotodinámica (?).

No obstante, en un medio biológico el comportamiento de estas nanopartículas no viene determinado únicamente por el núcleo inorgánico. La superficie es el primer punto de contacto con proteínas, lípidos, sales y

metabolitos, por lo que los grupos químicos presentes en ella condicionan la estabilidad coloidal, la adsorción de biomoléculas, el reconocimiento celular y la posible toxicidad. Por ello, el estudio de los agentes de recubrimiento resulta esencial para interpretar y modular las interacciones nano-bio.

3.2. Agentes de recubrimiento y funcionalización superficial

Los agentes de recubrimiento, también denominados *capping agents* o ligandos superficiales, son moléculas empleadas para estabilizar nanopartículas y ajustar sus propiedades superficiales. Pueden evitar la agregación, modificar la solubilidad, controlar la carga superficial, aportar grupos funcionales reactivos o introducir motivos de reconocimiento biológico. Entre ellos se encuentran moléculas pequeñas, ligandos tiolados, ácidos orgánicos, surfactantes, polímeros, péptidos, biomoléculas y fármacos conjugables.

Desde el punto de vista químico, pequeñas variaciones en polaridad, carga, aromaticidad, flexibilidad o número de grupos donadores y aceptores de enlaces de hidrógeno pueden modificar de forma relevante la interacción con proteínas plasmáticas. En nanopartículas metálicas, los grupos azufrados son especialmente importantes por su afinidad hacia superficies de oro y plata, mientras que grupos carboxilato, amino, fosfato o hidroxilo pueden alterar la hidratación, el estado de protonación y las interacciones electrostáticas con biomoléculas.

En un enfoque computacional, estos recubrimientos pueden abordarse a diferentes niveles de aproximación. Una primera estrategia consiste en estudiarlos como ligandos moleculares individuales frente a proteínas plasmáticas. Este planteamiento permite analizar cómo la estructura química del recubrimiento se relaciona con su afinidad relativa por diferentes proteínas. Una segunda estrategia consiste en considerar modelos simplificados de nanopartícula-recubrimiento o nanopartícula-proteína. Este nivel incorpora parcialmente el efecto del núcleo inorgánico, aunque incrementa la complejidad del sistema y puede exigir parametrizaciones específicas.

3.3. Corona proteica e identidad biológica

Cuando una nanopartícula entra en contacto con fluidos biológicos, su superficie se recubre rápidamente de proteínas y otras biomoléculas, formando una corona biomolecular. En plasma sanguíneo, esta corona está

dominada por proteínas plasmáticas y se denomina habitualmente corona proteica. Este fenómeno es clave en nanomedicina, ya que las células no interactúan únicamente con la nanopartícula sintética original, sino con una interfaz híbrida formada por el núcleo inorgánico, el recubrimiento superficial y las biomoléculas adsorbidas ([Monopoli et al., 2012](#)).

La corona proteica puede modificar el tamaño hidrodinámico, el potencial zeta, la estabilidad coloidal, la biodistribución, la captación celular, el aclaramiento por el sistema mononuclear fagocítico, la inmunogenicidad y la toxicidad. Por ello, se considera que la corona contribuye de manera decisiva a la identidad biológica de la nanopartícula ([Monopoli et al., 2012](#); [Walkey and Chan, 2012](#)).

La composición de la corona depende de múltiples factores: tamaño, forma, composición y curvatura de la nanopartícula; naturaleza del recubrimiento; concentración relativa de proteínas; afinidad de adsorción; pH; fuerza iónica; temperatura; y tiempo de exposición ([Walkey and Chan, 2012](#)). De forma conceptual puede distinguirse entre una corona blanda, formada por proteínas de interacción débil y recambio rápido, y una corona dura, compuesta por proteínas con mayor afinidad y mayor tiempo de residencia ([Monopoli et al., 2013](#)). Esta distinción es útil, aunque en sistemas reales la corona es dinámica y puede evolucionar por intercambio competitivo de proteínas.

El diseño racional de nanopartículas biomédicas requiere, por tanto, comprender cómo la química superficial afecta a la adsorción proteica. Estudios recientes en nanopartículas de oro han mostrado que la química del recubrimiento influye de forma significativa en la formación de la corona y en la interacción con proteínas séricas ([Dridi et al., 2024](#)). Este punto justifica el estudio sistemático de recubrimientos mediante docking molecular, descriptores fisicoquímicos y modelos predictivos.

3.4. Proteínas plasmáticas consideradas

En aplicaciones intravenosas, las proteínas plasmáticas son especialmente relevantes porque constituyen el primer entorno biomolecular que encuentra una nanopartícula. En este trabajo se consideran cuatro proteínas de interés: albúmina sérica humana, transferrina, fibrinógeno e inmunoglobulina G. Cada una representa un tipo de función biológica distinta y, por tanto, un posible efecto diferente sobre la identidad biológica de la nanopartícula.

La albúmina sérica humana es la proteína más abundante del plasma y posee múltiples regiones de unión para moléculas endógenas y exógenas. Su capacidad de transporte y su elevada concentración hacen que pueda participar de forma importante en las etapas iniciales de adsorción sobre nanomateriales. La transferrina está implicada en el transporte de hierro y resulta relevante en estrategias de direccionamiento hacia células con elevada expresión del receptor de transferrina. El fibrinógeno participa en procesos de coagulación y activación plaquetaria, por lo que su adsorción sobre nanopartículas puede tener implicaciones hemocompatibles. Las inmunoglobulinas, especialmente IgG, están relacionadas con reconocimiento inmunitario, opsonización y eliminación por células fagocíticas.

Desde el punto de vista del modelado, estudiar estas proteínas permite cubrir varios escenarios de interacción: transporte plasmático, coagulación, reconocimiento inmunitario y posible direccionamiento celular. Las afinidades calculadas por docking no deben interpretarse como una medida directa de la composición real de la corona, pero sí como una aproximación útil para comparar tendencias relativas entre ligandos, proteínas y recubrimientos.

3.5. Acoplamiento molecular

El acoplamiento molecular o *molecular docking* es una técnica computacional utilizada para predecir orientaciones plausibles de unión entre un ligando y una macromolécula, generalmente una proteína. El método explora posiciones, orientaciones y conformaciones del ligando dentro de una región de búsqueda definida y las ordena mediante una función de puntuación. El resultado habitual es un conjunto de poses y una energía o puntuación de afinidad aproximada.

AutoDock Vina es una de las herramientas más utilizadas para este propósito. Introdujo una función de puntuación empírica, un algoritmo de optimización eficiente y multihilo, permitiendo acelerar cálculos de docking frente a aproximaciones previas ([Trott and Olson, 2010](#)). La versión 1.2 amplió sus capacidades incorporando compatibilidad con la función de puntuación de AutoDock4, docking simultáneo de múltiples ligandos, modo *batch* y enlaces con Python, lo que facilita flujos de trabajo automatizados ([Eberhardt et al., 2021](#)).

La energía de docking debe interpretarse como una puntuación relativa, no como una energía libre de unión experimental exacta. Valores más negativos sugieren una interacción más favorable dentro del protocolo utilizado, pero la comparación debe realizarse con cautela cuando se emplean

programas, funciones de puntuación o parametrizaciones diferentes. En este TFM, las energías ligando-proteína se emplean como variables objetivo para aprendizaje automático, mientras que los resultados nanopartícula-proteína se tratan como una capa contextual independiente.

3.6. Optimización geométrica y frecuencias vibracionales

Antes de calcular descriptores moleculares o realizar docking, las estructuras de los ligandos deben presentar geometrías químicamente razonables. La optimización geométrica busca localizar un mínimo de energía en la superficie de energía potencial. Posteriormente, el cálculo de frecuencias vibracionales permite verificar la naturaleza del punto estacionario: una geometría optimizada como mínimo local no debe presentar frecuencias imaginarias.

En este trabajo, las frecuencias se consideran principalmente una etapa de validación estructural. Es decir, su función principal es comprobar que las geometrías optimizadas son compatibles con mínimos de energía antes de utilizarlas para generar descriptores o archivos de entrada. Los archivos de tipo Molden contienen información de geometría, orbitales y modos vibracionales, pero no constituyen por sí mismos variables directas del modelo predictivo. En caso de ampliación futura, podrían extraerse descriptores cuánticos escalares, como energía total, frecuencias mínimas, número de frecuencias imaginarias, energías HOMO/LUMO o brecha HOMO-LUMO. ORCA proporciona un entorno general para cálculos de química cuántica, incluyendo optimizaciones y frecuencias, y es ampliamente utilizado en flujos de trabajo de química computacional ([Neese et al., 2020](#); [Neese, 2022](#)).

3.7. Descriptores moleculares y quimioinformática

Los descriptores moleculares son variables numéricas que codifican propiedades estructurales, topológicas o fisicoquímicas de una molécula. Permiten transformar una estructura química en una matriz de datos apta para análisis estadístico o aprendizaje automático. Entre los descriptores habituales se encuentran el peso molecular, LogP, área de superficie polar topológica, número de donadores y aceptores de enlaces de hidrógeno, número de enlaces

rotables, número de anillos, carga formal, índices topológicos y descriptores geométricos tridimensionales.

RDKit es una biblioteca de quimioinformática ampliamente utilizada para manipulación de estructuras, cálculo de propiedades moleculares, generación de fingerprints y análisis de datos químicos ([RDKit Developers, 2026](#)). En este trabajo, los descriptores RDKit representan la base del dataset ligando-proteína. De forma complementaria, herramientas como Mordred permiten calcular un número muy elevado de descriptores moleculares, aunque en datasets pequeños un exceso de variables puede aumentar el riesgo de sobreajuste ([Moriwaki et al., 2018](#)).

La utilidad de los descriptores depende de su relación con el fenómeno que se desea modelar. En el contexto de este TFM, propiedades como tamaño, polaridad, flexibilidad o superficie molecular pueden influir en el modo de unión de los recubrimientos a proteínas plasmáticas. Sin embargo, un descriptor individual rara vez explica por completo la afinidad. Por ello, se emplean modelos multivariantes capaces de combinar información de múltiples variables.

3.8. Propiedades de membrana y modelo COSMOmic

Además de la interacción con proteínas plasmáticas, el comportamiento de los recubrimientos en entornos lipídicos puede aportar información fisicoquímica complementaria. La permeabilidad, partición y distribución de moléculas en membranas dependen de su polaridad, hidrofobicidad, tamaño, capacidad de formar enlaces de hidrógeno y coste energético de transferencia entre agua y la fase lipídica.

COSMO-RS es un modelo termodinámico basado en superficies de carga de apantallamiento obtenidas a partir de cálculos cuánticos en un conductor ideal. A partir de estas superficies, estima propiedades de solvatación y partición en fases líquidas ([Klamt, 1995](#)). COSMOmic extiende esta aproximación al estudio de micelas y biomembranas, permitiendo estimar coeficientes membrana/agua y distribuciones internas de solutos dentro de bicapas o sistemas micelares ([Klamt et al., 2008](#)).

En este TFM se utilizaron variables derivadas de perfiles en una bicapa modelo de DMPC. Entre ellas se incluyen descriptores como `mem_logP`, `mem_logPerm`, barreras de energía libre, distribución en función de la profundidad de la membrana, entropía media y difusión estimada. Estas variables

no describen directamente la afinidad proteína-ligando, sino el comportamiento del recubrimiento en un entorno lipídico. Por tanto, su incorporación al aprendizaje automático permite evaluar si la información de membrana añade señal predictiva a los descriptores moleculares clásicos.

3.9. Aprendizaje automático aplicado a interacciones nano-bio

El aprendizaje automático permite construir modelos que relacionan variables de entrada con una o varias salidas de interés. En química computacional, estas entradas suelen ser descriptores moleculares, fingerprints, propiedades fisicoquímicas o resultados de simulación. Las salidas pueden ser afinidades de unión, actividad biológica, toxicidad, permeabilidad o composición de corona proteica.

En el contexto de la corona proteica, ya se han propuesto modelos de aprendizaje automático para predecir la formación o composición funcional de coronas a partir de propiedades de nanopartículas, recubrimientos y condiciones experimentales (Findlay et al., 2018; Ban et al., 2020). En este TFM, el problema se plantea como una regresión multisalida: para cada ligando se predicen simultáneamente las afinidades de docking frente a varias proteínas plasmáticas.

Scikit-learn proporciona implementaciones estandarizadas de numerosos algoritmos supervisados y no supervisados, junto con herramientas para validación cruzada, preprocesado, selección de variables y evaluación de modelos (Pedregosa et al., 2011). En este trabajo se comparan modelos lineales regularizados, PLSRegression, Random Forest, ExtraTrees y aproximaciones con reducción dimensional. Random Forest combina múltiples árboles de decisión entrenados con aleatoriedad para reducir varianza y mejorar generalización (Breiman, 2001). ExtraTrees incrementa la aleatorización en la selección de variables y puntos de corte, lo que puede resultar útil en problemas con relaciones no lineales y datasets de tamaño moderado (Geurts et al., 2006).

La regresión PLS (*partial least squares*) es especialmente habitual en quimiometría porque proyecta las variables de entrada y las salidas en componentes latentes que maximizan su covarianza, tolerando colinealidad entre descriptores (Wold et al., 2001). PCA, en cambio, reduce la dimensionalidad de las variables de entrada sin utilizar directamente la salida, conservando direcciones de máxima varianza (Jolliffe, 2002). Por ello, PCA puede ser útil

para exploración o regularización, aunque no garantiza mejorar la predicción si la varianza principal no coincide con la información más relacionada con la afinidad.

3.10. Evaluación de modelos

El rendimiento de los modelos de regresión se evalúa mediante métricas continuas. En este trabajo se emplean el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2). Para un conjunto de n observaciones, con valores reales y_i y predicciones $\hat{y}_i$, estas métricas se definen como:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

El MAE mide el error medio en las mismas unidades que la variable objetivo y es relativamente interpretable. El RMSE penaliza más los errores grandes, por lo que resulta útil para detectar modelos con desviaciones importantes en algunos ligandos. El R^2 expresa la proporción de variabilidad explicada por el modelo respecto a un predictor constante. En problemas con pocos datos, la validación cruzada y la separación de un conjunto de test son necesarias para reducir el riesgo de interpretar como generalización un ajuste específico del conjunto de entrenamiento.

3.11. Integración del flujo computacional

La integración de preparación molecular, docking, cálculo de descriptores, variables de membrana, análisis nanopartícula-proteína y aprendizaje automático requiere un flujo de trabajo reproducible. En este TFM, cada etapa produce archivos intermedios y tablas finales que pueden regenerarse mediante scripts. Esta organización permite auditar el origen de cada variable, repetir análisis tras corregir datos de entrada y generar automáticamente figuras, tablas y visualizaciones.

El resultado conceptual del flujo de trabajo es una separación clara entre tres capas de información. La primera corresponde al modelo principal ligando-proteína, basado en descriptores moleculares y afinidades de docking. La segunda corresponde a variables de membrana, utilizadas para comprobar si añaden información predictiva. La tercera corresponde al análisis nanopartícula-proteína, tratado como contexto adicional para priorizar combinaciones ligando-nanopartícula-proteína sin mezclar directamente energías procedentes de protocolos distintos. Esta separación evita sobreinterpretar los datos y facilita una discusión metodológicamente coherente.

Metodología

4.1. Diseño general del flujo computacional

El trabajo se estructuró como un flujo computacional reproducible basado en archivos CSV, scripts de Python/R y una plantilla Quarto para la generación de memoria y anexos. La unidad principal del modelo predictivo fue el ligando, entendido como agente de recubrimiento o molécula funcional asociable a nanopartículas. Para cada ligando se integraron descriptores moleculares, variables de membrana y cuatro valores de afinidad de docking ligando-proteína.

El flujo se dividió en seis bloques: preparación y validación estructural de ligandos, docking ligando-proteína, cálculo de descriptores RDKit, extracción de variables de membrana, entrenamiento de modelos de aprendizaje automático y análisis contextual de docking nanopartícula-proteína. Esta separación evitó mezclar directamente entidades distintas dentro de un mismo modelo: el modelo principal trabaja con filas de ligando, mientras que la información nanopartícula-proteína se analiza como una capa independiente.

4.2. Sistemas estudiados

La biblioteca de trabajo incluyó agentes de recubrimiento y moléculas con interés biomédico, abarcando compuestos pequeños, grupos con afinidad por superficies metálicas, moléculas polares, moléculas aromáticas y algunos fármacos o aproximaciones estructurales de fármacos. Las proteínas plasmáticas se identificaron mediante sus códigos estructurales: **1ao6**, **1hzh**, **2hav** y **3ghg**. Los resultados de docking ligando-proteína se almacenaron como cuatro variables objetivo: **y_1ao6**, **y_1hzh**, **y_2hav** y **y_3ghg**.

Las nanopartículas se consideraron mediante modelos simplificados de oro, plata y óxido de zinc. Para el análisis nanopartícula-proteína se emplearon los sistemas Ag_13, Au_13 y ZnO_12_0. Estos resultados no se añadieron al dataset de ligandos como variables ordinarias, ya que representan interacciones nanopartícula-proteína y no propiedades intrínsecas del ligando.

4.3. Preparación y validación estructural de ligandos

Las estructuras moleculares de los ligandos fueron preparadas y optimizadas antes de su uso en el flujo de docking y cálculo de descriptores. La optimización geométrica se complementó con cálculos de frecuencias vibracionales. La ausencia de frecuencias imaginarias se utilizó como criterio de validación de mínimo local, de forma que las frecuencias actuaron como control de estabilidad estructural y no como variables principales del modelo predictivo.

Los cálculos cuánticos se organizaron para generar estructuras compatibles con los pasos posteriores y, cuando fue necesario, archivos de tipo Molden para inspección estructural. El programa ORCA se utilizó como herramienta de química cuántica para la generación de estructuras optimizadas y archivos compatibles con COSMO-RS/COSMOtherm (Neese, 2022). En el flujo de membrana se partió de archivos COSMO/ORCACOSMO asociados a los solutos, necesarios para el cálculo posterior de propiedades termodinámicas mediante COSMO-RS (Klamt, 1995).

4.4. Preparación de receptores y docking ligando-proteína

El acoplamiento molecular ligando-proteína se realizó con AutoDock Vina, empleando estructuras de proteínas preparadas en formato PDBQT y ligandos también convertidos a PDBQT. AutoDock Vina explora poses del ligando en la región de búsqueda definida y estima una afinidad de unión aproximada mediante su función de puntuación (Trott and Olson, 2010). La versión moderna de Vina permite automatizar cálculos en modo *batch* y facilita la integración en flujos de cribado mediante interfaces de scripting (Eberhardt et al., 2021).

Para cada combinación ligando-proteína se conservó la mejor afinidad calculada por docking. Los valores se almacenaron en una tabla final con

una fila por ligando y una columna objetivo por proteína. Dado que las cuatro salidas son continuas y se predicen de forma simultánea, el problema de aprendizaje automático se formuló como una regresión multisalida.

4.5. Cálculo de descriptores moleculares RDKit

A partir de las estructuras optimizadas se calcularon descriptores moleculares con RDKit ([RDKit Developers, 2026](#)). El bloque RDKit incluyó variables de tamaño y composición, como `MolWt`, `ExactMolWt`, `NumHeavyAtoms` y `NumAtoms`; variables de polaridad y capacidad de interacción, como `TPSA`, `NumHDonors` y `NumHAcceptors`; variables de lipofilia, como `MolLogP`; variables de flexibilidad, como `NumRotatableBonds`; y descriptores topológicos y geométricos, como `Chi0n`, `Chi1n`, `Kappa1`, `Kappa2`, `LabuteASA`, momentos principales de inercia, radio de giro y esfericidad.

Estos descriptores permitieron transformar cada ligando en un vector numérico comparable. El uso de variables interpretables facilita relacionar propiedades como tamaño, polaridad, hidrofobicidad o forma molecular con las afinidades calculadas por docking.

4.6. Variables de membrana COSMOtherm/COSMOmic

Las variables de membrana se extrajeron a partir de cálculos en una bicapa de dimiristoilfosfatidilcolina (DMPC) en agua a 37 °C. El fundamento teórico se basa en COSMO-RS, que utiliza densidades de carga de apantallamiento obtenidas a partir de cálculos cuánticos para predecir propiedades termodinámicas en fase líquida ([Klamt, 1995](#)). Para entornos anisótropos como micelas y biomembranas, COSMOmic permite describir perfiles dependientes de la profundidad en la membrana y calcular propiedades como partición membrana/agua y distribuciones internas ([Klamt et al., 2008](#); [Jakobtorweihen et al., 2013](#); [Ingram et al., 2013](#)).

Del archivo de permeabilidad se extrajeron variables globales y estadísticas resumen. Entre las variables globales se incluyeron `mem_logP`, correspondiente al logaritmo de partición micela/agua; `mem_logP_kg_1`, versión ajustada en unidades kg/L; y `mem_logPerm`, asociado a la permeabilidad de membrana. Además, se resumieron perfiles dependientes de la profundidad para energía libre, distribución, entropía media y difusión. Para cada perfil

se calcularon estadísticos como media, mínimo, máximo, valor en la zona central de la membrana y, cuando procedía, profundidad asociada a máximos o mínimos.

Las variables de membrana se incorporaron como bloque complementario al dataset de ligandos. Su objetivo fue evaluar si la información de partición y permeabilidad aportaba mejora predictiva frente a los descriptores RDKit. Metodológicamente, se mantuvieron separadas para poder comparar modelos RDKit-solo, membrana-solo y RDKit+membrana.

4.7. Construcción del dataset final

El dataset final se construyó mediante la unión de tres fuentes: descriptores RDKit, variables de membrana y afinidades de docking ligando-proteína. La tabla principal mantuvo una fila por ligando. Las columnas objetivo fueron `y_1ao6`, `y_1hzh`, `y_2hav` y `y_3ghg`.

Antes del entrenamiento se sustituyeron valores infinitos por valores perdidos y se aplicó imputación por la mediana dentro del flujo de modelado. Las variables de varianza nula se eliminaron mediante un filtro de varianza. En los modelos lineales y en PCA se aplicó escalado estándar para evitar que variables con distinta magnitud dominaran el ajuste. En los modelos basados en árboles no fue necesario escalar las variables, aunque se mantuvo un flujo homogéneo de preprocesado para asegurar comparaciones reproducibles.

4.8. Modelos de aprendizaje automático

Se compararon distintos modelos de regresión multisalida usando scikit-learn ([Pedregosa et al., 2011](#)). Los modelos evaluados fueron Ridge, PLS-Regression, RandomForestRegressor, ExtraTreesRegressor y PCA seguido de Ridge. Ridge se incluyó como modelo lineal regularizado; PLSRegression como modelo útil en escenarios con variables correlacionadas y tamaño muestral reducido; Random Forest y ExtraTrees como métodos no lineales basados en ensamblados de árboles; y PCA_Ridge como estrategia de reducción dimensional previa al ajuste lineal.

El modelo ExtraTrees se basa en árboles extremadamente aleatorizados, que incrementan la aleatoriedad tanto en la selección de variables como en los puntos de corte, pudiendo reducir varianza y mejorar generalización en problemas tabulares ([Geurts et al., 2006](#)). Random Forest se incluyó como

referencia de ensamblado basado en árboles de decisión entrenados sobre subconjuntos y agregados por promediado (Breiman, 2001).

La evaluación se realizó mediante partición entrenamiento-test y validación cruzada en el conjunto de entrenamiento. Para comparar de forma justa los bloques de variables, se mantuvieron la misma partición, las mismas salidas y las mismas métricas entre modelos. Las métricas principales fueron el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación R^2 . Estas métricas se calcularon de forma global y por proteína.

4.9. Comparación de bloques de variables

La comparación se organizó por bloques de entrada:

- `RDKit_solo`: únicamente descriptores moleculares RDKit.
- `RDKit_membrana_seleccionada`: descriptores RDKit más variables de membrana con señal fisicoquímica clara.
- `Membrana_solo`: únicamente variables COSMOtherm/COSMOmic.
- `RDKit_membrana_filtrada_auto`: combinación RDKit+membrana con filtrado automático de variables no informativas.

Esta organización permitió responder a una pregunta metodológica central: si las variables de membrana mejoraban la predicción de afinidad proteína-ligando o si actuaban principalmente como caracterización fisicoquímica complementaria. Dado el tamaño reducido del dataset, la interpretación se basó en el conjunto de métricas y no en una única cifra aislada.

4.10. Docking nanopartícula-proteína

Los resultados de docking nanopartícula-proteína se obtuvieron a partir de archivos DLG. Para cada archivo se extrajeron las energías detectadas y se generó una tabla con nanopartícula, proteína, energía mínima y número de energías identificadas. Estos cálculos se trataron como un análisis independiente del modelo ligando-proteína.

La razón es que una energía nanopartícula-proteína no varía por ligando, sino por combinación nanopartícula-proteína. Incluirla directamente como descriptor en una tabla donde cada fila representa un ligando generaría una mezcla de unidades de análisis. Por ello, se utilizó como capa contextual

para construir rankings exploratorios, pero no como variable del modelo principal.

Análisis estructural de complejos representativos

Como ampliación interpretativa del análisis de docking, se seleccionaron los complejos ligando-proteína mejor posicionados para cada proteína y se prepararon estructuras proteína-ligando en formato PDB. La selección se realizó tomando los tres ligandos con afinidad de docking más favorable frente a cada proteína, generando un conjunto de 12 complejos representativos.

Los complejos seleccionados incluyeron principalmente ácido fólico, curcumina, el proxy de doxorubicina/daunorrubicina aglicona y ácido tánico aproximado, que fueron los ligandos con mejores energías de docking en las proteínas estudiadas. Esta selección permitió definir un *case study* estructural centrado en los candidatos más relevantes del cribado ligando-proteína.

El objetivo de esta etapa fue preparar los complejos para un análisis posterior de interacciones no covalentes mediante herramientas como PLIP (*Protein-Ligand Interaction Profiler*), que permite identificar de forma automática puentes de hidrógeno, contactos hidrofóbicos, puentes salinos, interacciones aromáticas y otros contactos proteína-ligando. En el presente flujo, esta etapa se consideró una ampliación estructural del docking, orientada a validar químicamente las poses mejor puntuadas y a interpretar si las afinidades más favorables se deben a interacciones específicas o a efectos más generales como tamaño, polaridad o superficie molecular.

Índice Contextual Nano-Bio

Para integrar de forma exploratoria la información de docking ligando-proteína y nanopartícula-proteína se definió el Índice Contextual Nano-Bio (ICNB). Este índice no representa una energía física absoluta, sino una métrica de priorización comparativa que combina dos contribuciones normalizadas: la afinidad ligando-proteína y la interacción nanopartícula-proteína.

En primer lugar, las energías de docking ligando-proteína y nanopartícula-proteína se transformaron en puntuaciones normalizadas dentro de cada proteína. Dado que valores más negativos indican interacciones más favorables, se invirtió el signo de las puntuaciones normalizadas:

$$S_{i,p}^{LP} = -z_p(E_{i,p}^{LP})$$

$$S_{n,p}^{NP} = -z_p(E_{n,p}^{NP})$$

donde $(E^{\{LP\}}\{i,p\})$ representa la energía de docking del ligando (i) frente a la proteína (p), $(E^{\{NP\}}\{n,p\})$ la energía de docking de la nanopartícula (n) frente a la proteína (p), y (z_p) el z-score calculado dentro de cada proteína.

A continuación, se calculó una puntuación contextual media:

$$S_{i,n,p}^{contexto} = \frac{S_{i,p}^{LP} + S_{n,p}^{NP}}{2}$$

Finalmente, esta puntuación se reescaló a un intervalo 0–100 para facilitar su interpretación, obteniendo el ICNB. Valores altos de ICNB indican combinaciones ligando-nanopartícula-proteína más favorables dentro del conjunto analizado. Esta formulación permitió integrar la contribución del ligando y de la nanopartícula sin mezclar directamente energías procedentes de unidades de análisis distintas.

4.11. Generación de tablas, figuras y aplicación de visualización

Los resultados finales se organizaron mediante scripts de R para generar tablas en CSV y figuras en PNG. Las figuras incluyeron comparación de modelos por RMSE, rendimiento por proteína, gráficos real-predicho, correlaciones de variables, mapas de calor nanopartícula-proteína, ranking contextual y relaciones entre variables de membrana.

Además, se desarrolló una aplicación Streamlit para revisar de forma interactiva los CSV generados. La aplicación permite explorar modelos, métricas, predicciones, variables de membrana, docking nanopartícula-proteína y ranking contextual. Esta aplicación se considera una herramienta auxiliar de visualización, mientras que los análisis reproducibles quedan definidos por los scripts y los archivos CSV generados.

4.12. Reproducibilidad y trazabilidad

La estructura final del proyecto separó datos, scripts, resultados, aplicación y documentación. Los datasets se almacenaron en `datasets/`; los scripts

en `scripts/modelos`, `scripts/membrana`, `scripts/nanoparticulas` y `scripts/utilidades`; las salidas en `resultados/`; y la memoria en una plantilla Quarto. Esta organización permite regenerar tablas y figuras a partir de los CSV base y facilita la ampliación futura del flujo a nuevos ligandos, nuevas proteínas o complejos ligando-nanopartícula-proteína completos.

Resultados

5.1. Comparación de modelos predictivos

La comparación de modelos permitió evaluar el efecto de distintos bloques de variables sobre la predicción de afinidades de docking. La Figura 5.1 muestra el ranking de modelos ordenado por RMSE en el conjunto de test. El mejor resultado global correspondió a ExtraTrees utilizando únicamente descriptores RDKit, con un RMSE de test de 0,4117, un MAE de 0,3188 y un R^2 medio de 0,8840. El modelo equivalente con descriptores RDKit y variables de membrana seleccionadas obtuvo un RMSE prácticamente idéntico, de 0,4117, aunque con un MAE ligeramente superior.




Figura 5.1: Comparación de modelos por RMSE en test.

La comparación por bloques de variables se resume en la Figura 5.2. Este análisis permite valorar de forma directa si la inclusión de variables de membrana mejora el modelo frente al uso exclusivo de descriptores RDKit. La diferencia entre RDKit_solo y RDKit+membrana fue mínima, mientras que el bloque Membrana_solo presentó un error claramente superior. Por tanto, las variables de membrana contienen información fisicoquímica útil, pero no suficiente para sustituir a los descriptores moleculares estructurales en la predicción de afinidades proteína-ligando.




Figura 5.2: Mejor RMSE por bloque de variables.

5.2. Rendimiento por proteína

El rendimiento por proteína del mejor modelo se evaluó mediante RMSE y R^2 . Las Figuras Figura 5.3 y Figura 5.4 muestran la variabilidad de rendimiento entre las cuatro proteínas. El error no fue homogéneo en todas las salidas: y_{2hav} presentó el menor RMSE, mientras que y_{1hzh} mostró el mayor error relativo. Aun así, los valores de R^2 se mantuvieron elevados para las cuatro proteínas, lo que indica que el modelo capturó una parte importante de la variabilidad de las afinidades de docking.




Figura 5.3: RMSE por proteína del mejor modelo.




Figura 5.4: R² por proteína del mejor modelo.

5.3. Predicción real frente a predicción estimada

La concordancia entre valores reales de docking y valores predichos se inspeccionó mediante diagramas de dispersión proteína a proteína. La Figura 5.5 reúne las cuatro salidas en una única representación para facilitar la comparación visual. En general, los puntos se distribuyen próximos a la

diagonal, especialmente para y_2hav y y_1ao6 . Las desviaciones observadas en algunos ligandos indican que el modelo mantiene limitaciones para casos concretos, previsiblemente asociados a moléculas con tamaños, polaridades o geometrías menos representadas en el conjunto de entrenamiento.




Figura 5.5: Comparación real vs predicho para las cuatro proteínas.

5.4. Variables relevantes

La Figura 5.6 muestra las variables más correlacionadas con las afinidades de docking. Este análisis se utilizó como exploración descriptiva, no como criterio único de selección de variables. Las variables más correlacionadas fueron principalmente descriptores RDKit relacionados con tamaño molecular, número de átomos pesados, peso molecular, superficie y forma molecular. También aparecieron variables de membrana, especialmen-

Resultados

te relacionadas con difusión y entropía, lo que indica que estas propiedades contienen señal asociada a características fisicoquímicas generales de los ligandos.




Figura 5.6: Variables más correlacionadas con las afinidades.

5.5. Docking nanopartícula-proteína

Los resultados nanopartícula-proteína se resumen en la Figura 5.7. Las energías más negativas indican interacciones más favorables dentro del protocolo de docking utilizado. Zn0_12_0 presentó energías de interacción mucho más negativas que Ag_13 y Au_13 frente a las tres proteínas evaluadas, especialmente frente a 2hav. Esta diferencia sugiere que, dentro de los modelos simplificados considerados, la nanopartícula de óxido de zinc muestra una mayor tendencia a interactuar con las proteínas plasmáticas analizadas.




Figura 5.7: Mapa de calor de docking nanopartícula-proteína.

5.6. Índice Contextual Nano-Bio

El ranking contextual se reformuló como Índice Contextual Nano-Bio (ICNB), expresado en una escala 0–100. Este índice permitió priorizar combinaciones ligando-nanopartícula-proteína integrando, de forma normalizada, la afinidad ligando-proteína y la interacción nanopartícula-proteína.

Los resultados mostraron una dominancia clara de la nanopartícula ZnO_12_0 en las combinaciones mejor puntuadas. Esto se debe a que ZnO_12_0 presentó energías nanopartícula-proteína mucho más negativas que Ag_13 y Au_13 frente a las tres proteínas evaluadas en el docking nanopartícula-proteína. Como consecuencia, las primeras posiciones del ICNB estuvieron ocupadas por combinaciones que incluyen ZnO_12_0.

La mejor combinación global fue Folic_acid–ZnO_12_0–2hav, con un ICNB global de 100. También alcanzaron valores máximos dentro de cada proteína las combinaciones Folic_acid–ZnO_12_0–1ao6 y Folic_acid–ZnO_12_0–1hzh. En conjunto, el ácido fólico apareció como el ligando mejor posicionado de forma consistente en las tres proteínas con datos nanopartícula-proteína.

Las combinaciones mejor posicionadas fueron:

Resultados

Ligando	Nanopartícula	Proteína	ICNB global	ICNB por proteína	Energía ligando-proteína	Energía nanopartícula-proteína
Folic_acid	ZnO_12_02hav		100.00	100.00	-10.09	-8.44
Folic_acid	ZnO_12_01ao6		99.83	100.00	-9.21	-7.76
Folic_acid	ZnO_12_01hzh		97.78	100.00	-8.75	-7.38
Doxorubicin	ZnO_12_01ao6	daunorubicin	91.24	91.36	-8.36	-7.76
Curcumin	ZnO_12_02hav		89.46	89.44	-8.93	-8.44
Doxorubicin	ZnO_12_01hzh	daunorubicin	89.24	91.27	-7.94	-7.38
Doxorubicin	ZnO_12_02hav	daunorubicin	85.58	85.56	-8.50	-8.44
Curcumin	ZnO_12_01ao6		84.96	85.08	-7.74	-7.76
Tannic_acid	ZnO_12_01hzh		84.86	86.79	-7.52	-7.38
Tannic_acid	ZnO_12_02hav		84.00	83.97	-8.33	-8.44




Figura 5.8: Top 20 combinaciones según el Índice Contextual Nano-Bio.

Debe remarcarse que el ICNB no es una energía de unión total ni una magnitud termodinámica. Su utilidad es comparativa: permite priorizar combinaciones que reúnen simultáneamente ligandos con buena afinidad frente a proteínas plasmáticas y nanopartículas con interacción favorable frente a esas mismas proteínas.

5.7. Análisis PLIP de complejos representativos

Como ampliación estructural del análisis de docking, se analizaron mediante PLIP los complejos proteína-ligando mejor posicionados. Se seleccionaron los tres ligandos con mejor energía de docking para cada una de las cuatro proteínas, generando un conjunto de 12 complejos representativos. Para evitar interferencias de otros ligandos presentes en algunos receptores, la interpretación se centró en la entrada **LIG** correspondiente al ligando de interés.

El análisis PLIP permitió identificar contactos no covalentes entre ligando y proteína, principalmente contactos hidrofóbicos y puentes de hidrógeno. En 11 de los 12 complejos se detectaron interacciones proteína-ligando. El único sistema sin contactos detectados para **LIG** fue **Tannic_acid_approx** frente a **1hzh**. En conjunto, los resultados muestran que las poses mejor puntuadas no dependen únicamente de la energía de docking, sino que presentan contactos estructurales identificables con residuos de las proteínas.

Para mantener una interpretación conservadora, la tabla resume los contactos hidrofóbicos y los puentes de hidrógeno, que fueron las categorías más robustas en los reportes. Las interacciones metálicas detectadas en algunos complejos con ácido fólico no se utilizaron para el recuento total, ya que pueden estar influenciadas por la preparación estructural y por la presencia de varias poses en el archivo de docking.

Proteína	Ligando	Contactos hidrofóbicos	Puentes de hidrógeno	Total considerado
1ao6	Curcumin	18	0	18
1ao6	Doxorubicin_proxy_daunorubicin_aglycone	18	0	18
1ao6	Folic_acid	19	7	26
1hzh	Doxorubicin_proxy_daunorubicin_aglycone	12	0	12
1hzh	Folic_acid	13	8	21
1hzh	Tannic_acid_approx	0	0	0
2hav	Curcumin	13	0	13
2hav	Doxorubicin_proxy_daunorubicin_aglycone	10	0	10
2hav	Folic_acid	18	4	22
3ghg	Curcumin	12	0	12
3ghg	Doxorubicin_proxy_daunorubicin_aglycone	9	0	9
3ghg	Folic_acid	11	0	11

El ácido fólico fue el ligando que presentó el patrón de interacción más completo. En **1ao6** mostró 26 interacciones consideradas, incluyendo 19 contactos hidrofóbicos y 7 puentes de hidrógeno. En **1hzh** presentó 21 interacciones, con 13 contactos hidrofóbicos y 8 puentes de hidrógeno, mientras que en **2hav** presentó 22 interacciones, con 18 contactos hidrofóbicos y 4 puentes de hidrógeno. Este comportamiento es coherente con su posición destacada en el ICNB.

Los residuos con mayor número de contactos acumulados fueron LYS137, ARG186, LEU115 y LEU182 en **1ao6**; GLN166, PHE83, GLU165 y LYS103 en **1hzh**; LYS591, ARG590, LEU228 y LEU134 en **2hav**; y MET78, ILE79, VAL132 y ALA101 en **3ghg**. Estos residuos definen regiones de interacción recurrentes en las poses mejor puntuadas y aportan una interpretación estructural complementaria a la energía de docking.

Debe señalarse que este análisis PLIP se considera preliminar, ya que los complejos proceden de archivos de salida de docking y pueden contener varias poses de Vina en un mismo archivo estructural. Por ello, los recuentos de interacciones se interpretan de forma cualitativa, como apoyo estructural al ranking de docking, y no como una cuantificación definitiva de contactos para una única pose.

5.8. Propiedades de membrana

Las variables de membrana se analizaron como información fisicoquímica complementaria. La Figura 5.9 muestra la relación entre partición y permeabilidad derivadas de COSMOtherm/COSMOmic. Se observó una relación positiva general entre `mem_logP` y `mem_logPerm`, aunque con dispersión considerable. Esto indica que la partición en el entorno lipídico contribuye a la permeabilidad estimada, pero no la determina de forma exclusiva. La información de membrana resultó útil para caracterizar el comportamiento de los ligandos en un entorno lipídico modelo, aunque no produjo una mejora clara del modelo predictivo de afinidad proteína-ligando.




Figura 5.9: Relación entre `mem_logP` y `mem_logPerm`.

5.9. Aplicación de visualización y predicción

Además de las tablas y figuras generadas automáticamente, se desarrolló una aplicación Streamlit para facilitar la exploración de los resultados. La aplicación permite revisar la comparación de modelos, las métricas por proteína, las predicciones del conjunto de test, las variables de membrana, los resultados nanopartícula-proteína y el ICNB.

Como ampliación del flujo, la aplicación incorporó una pestaña de predicción de nuevos ligandos a partir de SMILES. En esta sección, el usuario puede introducir una molécula, calcular sus descriptores RDKit y aplicar el modelo ExtraTrees final para estimar su perfil de afinidad frente a las cuatro proteínas plasmáticas. Esta funcionalidad convierte la app en una herramienta de cribado preliminar, aunque sus predicciones deben interpretarse dentro del dominio químico del dataset de entrenamiento.

Discusión

Los resultados obtenidos muestran que el flujo computacional desarrollado permite integrar de forma reproducible información procedente de docking molecular, descriptores moleculares, variables de membrana, modelos de aprendizaje automático, docking nanopartícula-proteína y análisis estructural de complejos representativos. La separación entre estas capas de información fue una decisión metodológica importante: el modelo principal se construyó con una fila por ligando y cuatro salidas de afinidad ligando-proteína, mientras que los resultados nanopartícula-proteína se analizaron como una capa contextual independiente. Esta separación evita mezclar directamente magnitudes que proceden de entidades diferentes y de protocolos de cálculo no equivalentes.

6.1. Interpretación del modelo predictivo

El mejor modelo predictivo fue ExtraTrees utilizando únicamente descriptores RDKit. Este resultado es coherente con la naturaleza del problema, ya que la afinidad de docking ligando-proteína depende en gran medida de propiedades moleculares como tamaño, polaridad, superficie, forma, flexibilidad y capacidad de formar interacciones no covalentes. Los modelos basados en árboles son adecuados para capturar relaciones no lineales y combinaciones de variables sin imponer una relación lineal estricta entre descriptores y afinidad ([Geurts et al., 2006](#); [Breiman, 2001](#)). En este caso, ExtraTrees obtuvo el menor RMSE en test, lo que justificó su selección como modelo final.

El rendimiento obtenido indica que los descriptores moleculares clásicos capturan una parte importante de la variabilidad de las afinidades calculadas por docking. Este resultado no implica que las energías de docking

sean equivalentes a energías libres experimentales, pero sí demuestra que existe una relación reproducible entre la estructura molecular de los agentes de recubrimiento y su afinidad relativa frente a las proteínas plasmáticas consideradas.

No obstante, PLSRegression mostró también un rendimiento competitivo, especialmente en validación cruzada. Esto es relevante porque PLS es un método ampliamente utilizado en quimiometría y puede comportarse bien cuando existen muchas variables correlacionadas entre sí ([Wold et al., 2001](#)). La diferencia entre PLS y ExtraTrees no debe interpretarse como una superioridad absoluta de un enfoque sobre otro, sino como una indicación de que el dataset contiene una señal relativamente consistente entre estructura molecular y afinidad de docking. ExtraTrees fue seleccionado por su mejor rendimiento en test, mientras que PLS aporta una referencia lineal latente útil para interpretar la estabilidad del problema.

6.2. Papel de las variables de membrana

La incorporación de variables de membrana no mejoró de forma clara el rendimiento predictivo. El modelo `RDKit+membrana` obtuvo un RMSE prácticamente equivalente al modelo `RDKit_solo`, pero con un MAE ligeramente superior. Esta observación sugiere que las variables `COSMOtherm`/`COSMOmic` aportan información fisicoquímica real, pero no necesariamente información adicional relevante para predecir afinidades ligando-proteína en el tamaño de muestra disponible.

Esta interpretación es coherente con la naturaleza de las variables utilizadas. Las variables de membrana describen partición, permeabilidad, distribución, difusión y perfiles energéticos en una bicapa modelo de DMPC, mientras que el objetivo del modelo es una afinidad de docking frente a proteínas plasmáticas. Por tanto, ambas capas describen fenómenos relacionados con el comportamiento biomolecular de los ligandos, pero no exactamente el mismo proceso físico.

El bloque `Membrana_solo` presentó un rendimiento inferior al de `RDKit_solo`. Esta diferencia refuerza la idea de que las variables de membrana no sustituyen a los descriptores moleculares estructurales para modelizar afinidad proteína-ligando. Sin embargo, su inclusión sigue siendo útil en el trabajo porque permite caracterizar los recubrimientos desde una perspectiva complementaria. En un contexto biomédico, un agente de recubrimiento no solo debe mostrar baja o alta interacción con proteínas plasmáticas, sino también un comportamiento adecuado en medios lipídicos

y membranas celulares. En este sentido, las variables de membrana deben interpretarse como una capa de caracterización adicional, no como el principal determinante del modelo de afinidad.

Los resultados de correlación apoyan esta interpretación. Las variables más asociadas con las afinidades fueron principalmente descriptores relacionados con tamaño molecular, número de átomos pesados, peso molecular, superficie y forma. Esto indica que, en el conjunto estudiado, los ligandos de mayor tamaño o con mayor superficie molecular tienden a presentar afinidades de docking más favorables. Esta tendencia es razonable, ya que moléculas más grandes pueden establecer un mayor número de contactos con la superficie proteica. No obstante, también implica una posible limitación: el modelo puede estar capturando parcialmente una relación general entre tamaño y puntuación de docking, por lo que la interpretación química debe realizarse con cautela.

Las variables de membrana que aparecieron entre las más correlacionadas estuvieron relacionadas principalmente con difusión, entropía y perfiles de distribución. Este resultado sugiere que las propiedades de membrana están conectadas con características globales de los ligandos, como tamaño, polaridad o lipofilia. Sin embargo, la comparación de modelos demuestra que esta señal no fue suficiente para mejorar de forma robusta el rendimiento frente al bloque RDKit. Por ello, en este trabajo las propiedades de membrana se consideran útiles para discusión fisicoquímica, pero no como el bloque de variables más determinante para la predicción de docking proteína-ligando.

6.3. Diferencias de rendimiento entre proteínas

El análisis por proteína mostró diferencias de rendimiento entre las cuatro salidas. Algunas proteínas fueron predichas con menor error que otras, lo que puede deberse a diferencias en la distribución de afinidades, en la naturaleza de los sitios de unión o en la variabilidad de los ligandos frente a cada proteína. Las gráficas real-predicho muestran una concordancia general razonable, aunque con desviaciones en moléculas concretas.

Estas desviaciones son esperables en un dataset de tamaño moderado y con ligandos químicamente diversos. Además, las energías de docking son puntuaciones aproximadas y no medidas experimentales de afinidad; por tanto, el modelo aprende a reproducir el comportamiento del protocolo de docking, no necesariamente una constante termodinámica real ([Trott](#)

and Olson, 2010; Eberhardt et al., 2021). Este punto es importante para evitar una sobreinterpretación de los valores numéricos: el modelo predice afinidades de docking, no constantes experimentales de unión.

La variabilidad entre proteínas también sugiere que, en futuros estudios, podría ser útil entrenar modelos específicos por proteína o incorporar descriptores derivados de las poses de docking. Estos descriptores podrían incluir el número de puentes de hidrógeno, contactos hidrofóbicos, residuos implicados o distancia a regiones funcionales de la proteína, enriqueciendo la información disponible para el modelo.

6.4. Docking nanopartícula-proteína

El docking nanopartícula-proteína mostró un patrón claro: ZnO_12_0 presentó energías más negativas que Ag_13 y Au_13 frente a las tres proteínas evaluadas. Este resultado convirtió a ZnO_12_0 en la nanopartícula dominante dentro del análisis contextual. Sin embargo, esta conclusión debe interpretarse dentro de las limitaciones del modelo simplificado y del protocolo de docking utilizado.

Las nanopartículas no son ligandos orgánicos convencionales y su parametrización, tamaño, carga, superficie y estado de funcionalización pueden influir de forma importante en los resultados. Por ello, estos cálculos son útiles como comparación exploratoria entre modelos de nanopartícula, pero no deben interpretarse como una predicción definitiva de la corona proteica real. En particular, el docking nanopartícula-proteína permite comparar tendencias relativas, pero no reproduce por sí solo procesos como adsorción competitiva, hidratación superficial, agregación, formación dinámica de corona o reorganización del recubrimiento.

Aun así, el resultado es útil dentro del diseño del flujo. Al mantener el docking nanopartícula-proteína separado del modelo principal, se evita introducir una variable que no depende del ligando en una tabla donde cada fila representa un agente de recubrimiento. Esta decisión mantiene la coherencia de las unidades de análisis y permite utilizar la información nanopartícula-proteína como contexto, no como descriptor directo del ligando.

6.5. Índice Contextual Nano-Bio

La reformulación del ranking contextual como Índice Contextual Nano-Bio permitió convertir el análisis ligando-nanopartícula-proteína en una métrica más clara y comparable. A diferencia de una suma directa de energías, que no sería adecuada porque las energías ligando-proteína y nanopartícula-proteína proceden de sistemas y protocolos distintos, el ICNB trabaja con puntuaciones normalizadas dentro de cada proteína. De esta forma, se evita interpretar el índice como una energía física y se utiliza únicamente como herramienta de priorización.

Los resultados del ICNB refuerzan dos tendencias observadas previamente. En primer lugar, el ácido fólico presentó afinidades ligando-proteína muy favorables en las proteínas estudiadas, situándose como el ligando más destacado en el análisis contextual. En segundo lugar, ZnO_12_0 mostró una interacción nanopartícula-proteína claramente más intensa que Ag_13 y Au_13. La combinación de ambas tendencias explica que las primeras posiciones del ICNB estén dominadas por sistemas Folic_acid-ZnO_12_0.

Este resultado no implica necesariamente que ZnO_12_0 sea siempre la mejor nanopartícula desde un punto de vista biomédico global, ya que el índice no incorpora toxicidad, estabilidad coloidal, síntesis, recubrimiento real ni validación experimental. Sin embargo, sí indica que, dentro del protocolo computacional utilizado, ZnO_12_0 es la nanopartícula que más contribuye a generar combinaciones con alta prioridad contextual.

El ICNB aporta una ventaja práctica: resume en una única métrica dos fuentes de información que no deben mezclarse directamente en el modelo de aprendizaje automático. Por tanto, permite priorizar combinaciones sin perder la trazabilidad de cada contribución. No obstante, debe insistirse en que el ICNB no representa una energía de unión total ni una magnitud termodinámica. Su función es ordenar candidatos de forma exploratoria y seleccionar sistemas prioritarios para análisis posteriores.

6.6. Análisis estructural mediante PLIP

La incorporación del análisis PLIP permitió añadir una capa estructural a la interpretación de los resultados de docking. Mientras que las energías de docking proporcionan una puntuación comparativa de afinidad, PLIP permite identificar qué tipos de contactos estabilizan las poses mejor puntuadas y qué residuos participan en la interacción.

Los resultados mostraron que los complejos seleccionados están dominados por contactos hidrofóbicos, acompañados en algunos casos por puentes de hidrógeno. Este patrón es razonable para ligandos como curcumina o el proxy de doxorrubicina/daunorrubicina aglicona, cuya interacción puede estar favorecida por superficies aromáticas y regiones apolares. En cambio, el ácido fólico presentó un perfil más rico, combinando contactos hidrofóbicos con varios puentes de hidrógeno frente a 1ao6, 1hzh y 2hav.

Este resultado refuerza la relevancia del ácido fólico en el trabajo. No solo aparece como uno de los ligandos con mejores energías de docking y como componente dominante en las combinaciones con mayor ICNB, sino que además muestra interacciones proteína-ligando más diversas que otros candidatos. La presencia de puentes de hidrógeno sugiere que su afinidad no depende únicamente del tamaño molecular o de la superficie de contacto, sino también de interacciones direccionales con residuos de la proteína.

En 1ao6 destacaron residuos como LYS137, ARG186, LEU115 y LEU182; en 1hzh, GLN166, PHE83, GLU165 y LYS103; en 2hav, LYS591, ARG590, LEU228 y LEU134; y en 3ghg, MET78, ILE79, VAL132 y ALA101. La aparición repetida de residuos cargados o polares en varios complejos es coherente con la presencia de ligandos con grupos funcionales capaces de formar contactos electrostáticos o puentes de hidrógeno.

No obstante, el análisis debe interpretarse con cautela. Los complejos empleados proceden de archivos de salida de docking y los reportes PLIP indican tamaños de ligando superiores a los esperados para algunas moléculas, lo que sugiere que en ciertos casos podrían haberse incluido varias poses de Vina dentro del mismo archivo estructural. Por este motivo, los resultados PLIP se consideran un case study estructural preliminar y no una cuantificación definitiva de contactos para una única pose. La mejora metodológica inmediata sería repetir el análisis extrayendo exclusivamente la primera pose de docking de cada ligando.

6.7. Aplicación predictiva desde SMILES

La ampliación de la aplicación Streamlit con una pestaña de predicción desde SMILES mejora la utilidad práctica del flujo computacional. Mientras que la versión inicial funcionaba principalmente como herramienta de visualización de resultados, la versión ampliada permite introducir una nueva molécula, calcular sus descriptores RDKit y obtener una predicción de afinidad frente a las cuatro proteínas plasmáticas mediante el modelo ExtraTrees final.

Esta funcionalidad transforma la app en una herramienta de cribado preliminar de agentes de recubrimiento. Sin embargo, sus predicciones deben interpretarse con cautela. El modelo solo es fiable dentro del dominio químico cubierto por el dataset de entrenamiento; moléculas muy alejadas en tamaño, carga, funcionalidad o geometría pueden producir predicciones menos robustas. Por tanto, la app no sustituye a nuevos cálculos de docking ni a validación experimental, pero sí permite priorizar candidatos antes de realizar cálculos más costosos.

Desde el punto de vista del trabajo, esta ampliación aporta una salida práctica al flujo computacional. El modelo no queda únicamente como una comparación retrospectiva de algoritmos, sino que puede utilizarse para evaluar de forma preliminar nuevos posibles recubrimientos. Esto refuerza el carácter reproducible y ampliable del proyecto.

6.8. Limitaciones del estudio

La principal limitación del trabajo es el tamaño del dataset. Aunque el número de ligandos permitió entrenar modelos con rendimiento razonable, sigue siendo un conjunto pequeño para aprendizaje automático. Esto limita la capacidad de generalización, aumenta la sensibilidad a la partición entrenamiento-test y obliga a interpretar con cautela cualquier diferencia pequeña entre modelos.

Otra limitación es que las afinidades utilizadas como salidas proceden de docking molecular. AutoDock Vina proporciona puntuaciones aproximadas y comparativas, pero no energías libres experimentales. Por tanto, los modelos entrenados predicen la salida del protocolo de docking, no directamente la afinidad experimental real. Esta distinción es importante para evitar sobreinterpretar los valores numéricos.

También debe considerarse la ausencia de docking completo nanopartícula-ligando-proteína para todas las combinaciones. En este trabajo, el análisis principal se basa en ligandos individuales y el docking nanopartícula-proteína se emplea como contexto. Esta estrategia es coherente con los datos disponibles, pero no captura explícitamente el efecto combinado del núcleo inorgánico, el recubrimiento y la proteína en un único complejo. Por ello, el ICNB debe interpretarse como una métrica exploratoria y no como sustituto de cálculos nano-bio completos.

Las variables de membrana representan otra aproximación complementaria, pero no describen directamente la interacción proteína-ligando. Aunque

aportan información sobre partición y permeabilidad en un entorno lipídico, su relación con la afinidad de docking es indirecta. Esto explica que no hayan mejorado claramente el modelo predictivo principal.

Finalmente, el trabajo carece de validación experimental. Para confirmar las tendencias observadas sería necesario compararlas con datos de adsorción proteica, formación de corona, estabilidad coloidal, potencial zeta, DLS, espectrometría de masas o ensayos de interacción proteína-nanopartícula. Esta validación permitiría determinar si las tendencias computacionales se traducen en diferencias reales de comportamiento biológico.

6.9. Síntesis final

En conjunto, los resultados muestran que los descriptores moleculares RDKit explican gran parte de la variabilidad de las afinidades de docking, que las variables de membrana aportan una caracterización complementaria pero no mejoran claramente la predicción, y que el análisis nanopartícula-proteína permite construir una capa contextual útil para priorizar combinaciones. El ICNB proporciona una forma clara de integrar esa información sin confundirla con una energía física absoluta, mientras que el análisis PLIP aporta una primera interpretación estructural de los complejos mejor posicionados.

El flujo desarrollado es modular, ampliable y trazable, lo que facilita su aplicación futura a nuevas bibliotecas de ligandos, nuevas proteínas plasmáticas y complejos nanopartícula-ligando-proteína más realistas. La combinación de modelo predictivo, análisis contextual, case study estructural y aplicación interactiva constituye una base sólida para continuar el estudio hacia sistemas nano-bio más completos.

Conclusiones

1. Se desarrolló un flujo computacional reproducible para estudiar la interacción entre agentes de recubrimiento de nanopartículas metálicas y proteínas plasmáticas, integrando docking molecular, descriptores RDKit, variables de membrana COSMOtherm/COSMOmic, modelos de aprendizaje automático y análisis nanopartícula-proteína.
2. El modelo predictivo principal se formuló como una regresión multivariada para predecir simultáneamente las afinidades de docking frente a cuatro proteínas plasmáticas. El mejor rendimiento se obtuvo con ExtraTrees utilizando únicamente descriptores RDKit, con un RMSE medio en test de 0,412 y un R^2 medio de 0,884.
3. La incorporación de variables de membrana no produjo una mejora clara del rendimiento predictivo frente al uso exclusivo de descriptores RDKit. No obstante, estas variables aportaron información fisicoquímica complementaria sobre partición, permeabilidad y comportamiento de los ligandos en una bicapa modelo de DMPC.
4. Los resultados nanopartícula-proteína mostraron que Zn0_12_0 presentó energías de interacción más negativas que Ag_13 y Au_13 frente a las proteínas evaluadas. Por ello, Zn0_12_0 tuvo un peso dominante en las combinaciones mejor posicionadas del análisis contextual.
5. El ranking contextual se reformuló como Índice Contextual Nano-Bio (ICNB), una métrica 0–100 que integra la afinidad ligando-proteína y la interacción nanopartícula-proteína mediante puntuaciones normalizadas. El ICNB permitió priorizar combinaciones ligando-nanopartícula-

proteína sin interpretar la suma de energías como una magnitud física absoluta.

6. Las combinaciones mejor posicionadas por ICNB estuvieron dominadas por `Folic_acid-ZnO_12_0`, especialmente frente a `2hav`, `1ao6` y `1hzh`. Este resultado indica que el ácido fólico es el ligando con comportamiento más consistente dentro del análisis contextual y que `ZnO_12_0` es la nanopartícula que más favorece el índice en el conjunto estudiado.
7. El análisis estructural mediante PLIP permitió estudiar 12 complejos proteína-ligando representativos. En 11 de ellos se detectaron interacciones no covalentes, dominadas por contactos hidrofóbicos y, en el caso del ácido fólico, también por puentes de hidrógeno. Este resultado aporta una interpretación estructural complementaria al docking y refuerza la relevancia del ácido fólico como ligando destacado. No obstante, el análisis se considera preliminar porque los archivos estructurales pueden contener varias poses de docking, por lo que los contactos deben interpretarse de forma cualitativa.
8. La aplicación Streamlit se amplió como herramienta de visualización y predicción preliminar. La incorporación de una pestaña basada en SMILES permite calcular descriptores RDKit de nuevos ligandos y estimar su perfil de afinidad mediante el modelo ExtraTrees final.
9. La principal limitación del estudio es que no se dispone todavía de docking completo nanopartícula-ligando-proteína para todas las combinaciones. Por ello, el ICNB debe interpretarse como una herramienta de priorización exploratoria y no como una energía de unión real de complejos nano-bio completos.
10. Como líneas futuras, el trabajo debería ampliarse mediante docking completo de sistemas nanopartícula-ligando-proteína, repetición del análisis PLIP sobre la pose mejor puntuada de cada complejo, ampliación de la biblioteca de ligandos, incorporación de nuevos descriptores moleculares y validación experimental de las tendencias computacionales observadas.

Lineas futuras

El presente trabajo establece una base computacional reproducible para estudiar la interacción entre agentes de recubrimiento, nanopartículas metálicas y proteínas plasmáticas. No obstante, los resultados obtenidos deben interpretarse como una primera aproximación, por lo que existen varias líneas futuras que permitirían ampliar y reforzar el alcance del estudio.

En primer lugar, una continuación natural consistiría en realizar el docking completo de los sistemas nanopartícula-ligando-proteína. En este trabajo, el modelo principal se centró en la interacción ligando-proteína, mientras que el docking nanopartícula-proteína se trató como una capa contextual independiente. Esta decisión fue metodológicamente necesaria para no mezclar unidades de análisis distintas dentro del mismo modelo. Sin embargo, disponer de complejos completos permitiría evaluar de forma más realista el efecto combinado del núcleo inorgánico, el agente de recubrimiento y la proteína plasmática.

Otra línea de mejora sería ampliar el número de ligandos estudiados. El tamaño del dataset condiciona de forma importante la capacidad de generalización de los modelos de aprendizaje automático. Aunque los modelos evaluados mostraron un rendimiento aceptable, un conjunto de datos mayor permitiría entrenar algoritmos más robustos, reducir la dependencia de la partición entrenamiento-test y explorar con mayor seguridad relaciones no lineales entre estructura química y afinidad de docking.

Además, sería interesante ampliar el conjunto de descriptores moleculares utilizados. En este trabajo se emplearon descriptores RDKit 2D/3D, variables de membrana y algunos descriptores geométricos. En futuros estudios podrían incorporarse fingerprints moleculares, descriptores Mordred, descriptores

cuánticos derivados de los cálculos de optimización y frecuencias, o variables relacionadas con HOMO.

También sería conveniente profundizar en las variables de membrana. En el presente trabajo, las propiedades COSMOtherm/COSMOmic se utilizaron como bloque complementario y no produjeron una mejora clara del rendimiento predictivo frente a los descriptores RDKit. Sin embargo, estas variables pueden ser relevantes para interpretar el comportamiento global de los recubrimientos en entornos biológicos, especialmente en procesos relacionados con permeabilidad, partición lipídica o interacción con membranas celulares.

Desde el punto de vista del modelado, un aumento del número de moléculas permitiría explorar métodos más complejos, como gradient boosting, modelos basados en kernels, redes neuronales o enfoques de aprendizaje profundo molecular. También sería posible plantear estrategias de validación externa, división por familias químicas y análisis de dominio de aplicabilidad.

Bibliografía

- Ban, Z. et al. (2020). Machine learning predicts the functional composition of the protein corona and the cellular recognition of nanoparticles. *Proceedings of the National Academy of Sciences*, 117(19):10492–10499.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45:5–32.
- Dridi, N., Jin, Z., Perng, W., et al. (2024). Probing protein corona formation around gold nanoparticles: Effects of surface coating. *ACS Nano*, 18(12).
- Eberhardt, J., Santos-Martins, D., Tillack, A. F., and Forli, S. (2021). Auto-dock vina 1.2.0: New docking methods, expanded force field, and python bindings. *Journal of Chemical Information and Modeling*, 61(8):3891–3898.
- Fatima, H., Jin, Z. Y., Shao, Z., Chen, X. J., et al. (2022). Recent advances in zno-based photosensitizers: Synthesis, modification, and applications in photodynamic cancer therapy. *Journal of Colloid and Interface Science*, 621:440–463.
- Findlay, M. R., Freitas, D. N., Mobed-Miremadi, M., and Wheeler, K. E. (2018). Machine learning provides predictive analysis into silver nanoparticle protein corona formation from physicochemical properties. *Environmental Science: Nano*, 5:64–71.
- Geurts, P., Ernst, D., and Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63:3–42.
- Ingram, T. et al. (2013). Prediction of micelle/water and liposome/water partition coefficients based on molecular dynamics simulations, cosmo-rs, and cosmomic. *Langmuir*, 29(11):3527–3537.

- Jakobtorweihen, S., Ingram, T., and Smirnova, I. (2013). Combination of cosmomic and molecular dynamics simulations for the calculation of membrane-water partition coefficients. *Journal of Computational Chemistry*, 34(15):1332–1340.
- Jangid, H., Singh, S. S., Kashyap, P., Singh, A., and Kumar, G. (2024). Advancing biomedical applications: an in-depth analysis of silver nanoparticles in antimicrobial, anticancer, and wound healing roles. *Frontiers in Pharmacology*, 15.
- Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer, 2 edition.
- Klamt, A. (1995). Conductor-like screening model for real solvents: A new approach to the quantitative calculation of solvation phenomena. *Journal of Physical Chemistry*, 99(7):2224–2235.
- Klamt, A., Huniar, U., Spycher, S., and Keldenich, J. (2008). Cosmomic: A mechanistic approach to the calculation of membrane-water partition coefficients and internal distributions within membranes and micelles. *Journal of Physical Chemistry B*, 112(38):12148–12157.
- Monopoli, M. P., Åberg, C., Salvati, A., and Dawson, K. A. (2012). Biomolecular coronas provide the biological identity of nanosized materials. *Nature Nanotechnology*, 7(12):779–786.
- Monopoli, M. P., Pitek, A. S., Lynch, I., and Dawson, K. A. (2013). Formation and characterization of the nanoparticle-protein corona. *Methods in Molecular Biology*, 1025:137–155.
- Moriwaki, H., Tian, Y.-S., Kawashita, N., and Takagi, T. (2018). Mordred: a molecular descriptor calculator. *Journal of Cheminformatics*, 10:4.
- Neese, F. (2022). Software update: The orca program system—version 5.0. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, 12(5):e1606.
- Neese, F., Wennmohs, F., Becker, U., and Riplinger, C. (2020). The orca quantum chemistry program package. *Journal of Chemical Physics*, 152(22):224108.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.

- RDKit Developers (2026). RDKit: Open-source cheminformatics software. Zenodo software release. Version 2026.03.3.
- Trott, O. and Olson, A. J. (2010). Autodock vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *Journal of Computational Chemistry*, 31(2):455–461.
- Walkey, C. D. and Chan, W. C. W. (2012). Understanding and controlling the interaction of nanomaterials with proteins in a physiological environment. *Chemical Society Reviews*, 41:2780–2799.
- Wold, S., Sjöström, M., and Eriksson, L. (2001). Pls-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2):109–130.
- Zahdeh, M. et al. (2025). Gold nanoparticles in biomedical applications: Synthesis, properties, functionalization, and clinical potential. *International Journal of Molecular Sciences*.